

UNIVERSITÉ DE CAEN NORMANDIE
UFR HUMANITÉS ET SCIENCES SOCIALES

Le troisième mode de genèse

*Mécanisme et explication dans les grands modèles de
langage*

Mémoire présenté en vue de l'obtention du grade de

Master II de Philosophie

mention Philosophie des sciences

par

François Branger

Sous la direction de

Pascal Bertin

Année universitaire 2025–2026

Remerciements

Merci à mon directeur de mémoire Pascal Bertin, pour son soutien sans faille et son enthousiasme à l'égard de ce projet. Ses précieux conseils et nos discussions ont fortement influencé certains aspects essentiels de ce travail. Merci à lui d'avoir cru en moi et de m'avoir épaulé à chaque étape de ce parcours.

Merci aussi à Maud Pouradier, que nulle obligation ne liait, et qui a pourtant accepté de soutenir ma candidature au prestigieux concours de l'ENACT. Merci encore à elle de m'avoir, en fin de licence, mis sur la voie de la philosophie des sciences, d'avoir pris le temps de m'écouter et de m'avoir prodigué des conseils qui se sont révélés décisifs pour mon orientation.

Merci enfin à mon meilleur ami Ismaël Rousseau, aujourd'hui ingénieur et doctorant en intelligence artificielle, pour les discussions quotidiennes qui nous animent depuis quinze ans.

Résumé

Résumé. Les grands modèles de langage sont à la fois très performants et opaques, et leur opacité n'est pas un simple défaut d'accès, puisqu'elle subsiste même lorsque le code, les paramètres et la trace des calculs sont disponibles. Ce mémoire prend pour objet l'interprétabilité mécaniste, le programme de recherche qui entend expliquer ces modèles en reconstruisant les mécanismes causaux internes dont émergent leurs sorties. La question directrice est de savoir si les stratégies d'explication mécaniste héritées des sciences du vivant, au sens de Machamer, Darden et Craver, conviennent à de tels systèmes. Nous soutenons une thèse en deux temps. D'une part, ces stratégies produisent des explications authentiquement mécanistes quant à leur forme, car elles décomposent le système, localisent ses fonctions et établissent ses relations causales par l'intervention. D'autre part, leur réussite même oblige à enrichir les catégories d'explication, de fonction et de composant, parce que l'organisation d'un modèle entraîné ne provient ni de l'évolution ni de la conception, mais d'un troisième mode de genèse, l'entraînement. Nous montrons enfin que ce résultat retourne la question de départ, puisqu'il met en cause l'équivalence tacite entre expliquer mécaniquement un système et le rendre intelligible. La démarche relève à cet égard de l'ingénierie conceptuelle, comprise comme une adaptation de nos concepts à un objet nouveau plutôt que comme la correction d'un défaut.

Mots-clés. interprétabilité mécaniste ; explicabilité ; grands modèles de langage ; explication mécaniste ; opacité épistémique ; fonction ; compréhension ; ingénierie conceptuelle ; intervention ; abstraction causale.

Abstract. Large language models are at once highly capable and opaque, and their opacity is not a mere lack of access, since it persists even when the code, the parameters and the full computational trace are available. This thesis takes as its object mechanistic interpretability, the research program that seeks to explain these models by reconstructing the internal causal mechanisms from which their outputs emerge. The guiding question is whether the strategies of

mechanistic explanation inherited from the life sciences, in the sense of Machamer, Darden and Craver, are adequate to such systems. We defend a two-part thesis. On the one hand, these strategies yield explanations that are genuinely mechanistic in form, for they decompose the system, localise its functions and establish its causal relations through intervention. On the other hand, their very success requires enriching the concepts of explanation, function and component, because the organisation of a trained model arises neither from evolution nor from design, but from a third mode of genesis, training. We finally show that this result reverses the initial question, since it challenges the tacit equivalence between mechanistically explaining a system and rendering it intelligible. In this respect the approach is a piece of conceptual engineering, understood as an adaptation of our concepts to a new object rather than as the correction of a defect.

Keywords. mechanistic interpretability; explainability; large language models; mechanistic explanation; epistemic opacity; function; understanding; conceptual engineering; intervention; causal abstraction.

Abréviations et sigles

Les sigles sont, par convention, conservés sous leur forme anglaise lorsque c’est l’usage du domaine ; leur première occurrence dans le corps du texte est explicitée.

IA	Intelligence artificielle.
LLM	<i>Large Language Model</i> , grand modèle de langage.
XAI	<i>Explainable Artificial Intelligence</i> , intelligence artificielle explicable. Désigne le champ des techniques d’explication appliquées aux systèmes opaques.
MI	<i>Mechanistic Interpretability</i> , interprétabilité mécaniste. Programme visant à expliquer un modèle par ses mécanismes causaux internes.
SAE	<i>Sparse Autoencoder</i> , auto-encodeur parcimonieux. Méthode de <i>dictionary learning</i> servant à extraire des traits interprétables.
LIME	<i>Local Interpretable Model-agnostic Explanations</i> , méthode d’attribution post-hoc qui approxime localement le modèle par un modèle simple et interprétable.
SHAP	<i>SHapley Additive exPlanations</i> , méthode d’attribution post-hoc fondée sur les valeurs de Shapley, qui répartit la contribution de chaque variable à une prédiction.
RISE	<i>Randomized Input Sampling for Explanation</i> , méthode d’attribution par perturbation qui masque aléatoirement des régions de l’entrée pour produire une carte de saillance.
ACAFA	Agent Cognitif Artificiel Fonctionnellement Autonome.
CIT	<i>Criterion for the Intelligibility of Theories</i> , critère d’intelligibilité des théories, au sens de de Regt (2017).

MDC	Machamer, Darden et Craver (2000), référence canonique du cadre néo-mécaniste.
TVD	<i>Total Variation Distance</i> , distance en variation totale (mobilisée dans le débat sur l'attention).
JSD	<i>Jensen-Shannon Divergence</i> , divergence de Jensen-Shannon.

Table des matières

Remerciements	ii
Résumé	iii
Abréviations et sigles	v
Introduction	1
Partie I — Le problème de l’opacité : de Dennett au projet de l’XAI	5
1.1 De l’ontologie à l’épistémologie : la nature du problème de l’opacité	5
1.2 Le programme de l’XAI : explicabilité, interprétabilité et stratégie du « diviser pour régner »	12
1.3 Les limites des explications locales et l’exigence d’une compréhension holistique	17
Partie II — L’interprétabilité mécaniste : stratégies et fondements philosophiques	24
2.1 La prémisses organique	25
2.2 Le cadre néo-mécaniste : expliquer le pourquoi par le comment	28
2.3 L’interventionnisme : la cause comme ce qui change sous l’intervention	30
2.4 Les traductions concrètes : décomposer, intervenir, abstraire	32
2.5 Le statut des explications de la MI : l’esquisse de mécanisme	39
2.6 Bilan : la MI produit des explications authentiquement mécanistes	41

Partie III — Les limites de l’analogie : ce que les LLM font à l’explication mécaniste	45
3.1 Un troisième mode de genèse : l’entraînement . . .	46
3.2 La superposition : quand les composants cessent d’être des parties	50
3.3 Le pluralisme : existe-t-il une décomposition vraie?	56
3.4 L’indifférence mécanique : la fonction attribuée et la fonction réalisée	61
3.5 Le gain constructif : la fonction sélectionnée par l’entraînement	68
3.6 Objections et réponses	72
Conclusion	78
Annexe A — Extraits du mémoire de Master 1	85
Glossaire	88
Bibliographie	94
Bibliographie secondaire	100

Introduction

Les grands modèles de langage se sont imposés, en quelques années, comme les systèmes d'intelligence artificielle les plus capables et les plus répandus. Ils rédigent, traduisent, résument, écrivent du code, et soutiennent une conversation suivie sur presque n'importe quel sujet. Leur compétence est manifeste, et elle se mesure chaque jour à l'usage. Ils ne restent pourtant pas confinés à des tâches anodines, puisqu'on les déploie désormais dans des domaines où leurs sorties engagent des conséquences réelles, qu'il s'agisse d'assister un diagnostic, de filtrer une candidature ou d'orienter une décision administrative. Or, à mesure que leur emploi s'étend, une difficulté se fait plus pressante : nous ne savons pas comment ils parviennent à leurs réponses. Entre la performance que nous observons et le fonctionnement interne qui la produit s'ouvre un écart que ni leurs concepteurs ni leurs utilisateurs ne comblent. Cet écart porte un nom, l'opacité, et il soulève à la fois un problème éthique, celui de la confiance et de la responsabilité, et un problème épistémologique, celui de l'intelligibilité, qui fait l'objet du présent travail.

Il importe d'emblée de préciser de quelle opacité nous parlons, car le terme en recouvre plusieurs. On pourrait croire que la difficulté tient à un défaut d'accès, et qu'elle se lèverait dès lors qu'on disposerait du code, des paramètres et de la trace de chaque calcul. Nous montrerons qu'il n'en est rien. Quand bien même on disposerait de tout cela, on demeurerait incapable de dire pourquoi le modèle a répondu de telle manière, ni en quoi consiste la compétence qu'il manifeste, ni comment il se comporterait dans un cas nouveau. L'opacité qui nous occupe n'est par conséquent pas un défaut d'accès, mais un défaut d'intelligibilité, et c'est ce qui en fait un problème proprement philosophique, puisqu'elle touche à la nature même de l'explication¹. La question de savoir si cette opacité est seulement difficile à lever, ou si elle est insurmontable par principe,

¹Nous réservons le terme d'opacité à son sens épistémique, celui d'un défaut d'intelligibilité, et nous laissons de côté son sens juridique et normatif, celui d'un droit à l'explication. Sur l'opacité épistémique propre aux méthodes computationnelles, Humphreys (2004 ; 2009, p. 618).

commandera d'ailleurs toute l'évaluation qui suit.

Ce travail prolonge un mémoire de première année, consacré à la question ontologique : *En quoi l'émergence des nouvelles intelligences artificielles nous amène-t-elle à reconsidérer notre conception du vivant ?* Nous y avons soutenu, en suivant Dennett, que ces systèmes sont le mieux compris, prédits et expliqués lorsqu'on adopte à leur endroit la perspective intentionnelle, et nous les avons regroupés sous la catégorie de l'agent cognitif artificiel fonctionnellement autonome². Cette position reposait sur deux thèses dennettiennes, le réalisme des patterns, qui tient les régularités comportementales pour des faits objectifs, et la distinction entre compétence et compréhension, qui dissocie la performance de toute vie intérieure. Elle nous permettait ainsi d'attribuer aux LLM des états fonctionnels, sans leur prêter pour autant une compréhension humaine ni une conscience. Elle laissait cependant une dette, et c'est de cette dette que part la présente recherche. En effet, la perspective intentionnelle ressemble à l'établissement d'un cahier des charges, dans la mesure où elle spécifie ce qu'un système doit faire, sans rien dire de la manière dont il le fait. Reconnaître ce qu'un LLM accomplit ne nous apprend donc rien sur les mécanismes qui les mettent en oeuvre. Ce travail antérieur se limitait à caractériser l'esprit artificiel du point de vue fonctionnel, sans en explorer les mécanismes sous-jacents, et c'est précisément cette dimension mécaniste, ainsi que l'opacité qui l'entoure, que nous prenons désormais pour objet.

Le passage de l'ontologie à l'épistémologie ne constitue pas un simple changement de sujet, car il hérite d'une analogie que le premier mémoire de Master avait posée. L'organisation interne d'un LLM n'a pas été assignée par un concepteur, puisqu'elle a été trouvée par une procédure d'optimisation portant sur des milliards de paramètres, au cours d'un entraînement automatisé. Sur ce point, un tel système ressemble bien davantage à un organisme, dont l'organisation a émergé d'un processus de sélection aveugle, qu'à un artefact ordinaire, dont la structure se laisse lire sur un plan. Or les sciences du vivant ont précisément forgé, pour rendre intelligibles des objets que nul concepteur n'a dessinés, une famille de stratégies, celles de l'explication mécaniste, qui décomposent un système, localisent ses fonctions, et établissent ses relations causales par l'intervention. Il devient dès lors naturel de se demander si ces

²Pour le développement complet de cette argumentation, voir Branger (2025), en particulier les chapitres consacrés à la légitimité de la perspective intentionnelle et à la catégorie de l'agent cognitif artificiel fonctionnellement autonome (ACAFA). Les passages dont la présente recherche hérite sont reproduits à l'Annexe A, extraits [A] et [B].

mêmes stratégies conviennent aux LLM.

La question directrice de ce mémoire en découle, et nous la formulons ainsi : si l'on prend au sérieux l'analogie fonctionnelle entre les LLM et les organismes, les stratégies d'explication mécaniste héritées des sciences du vivant sont-elles épistémiquement adéquates pour rendre les LLM intelligibles ?

Cette question rencontre un champ de recherche déjà constitué, celui de l'intelligence artificielle explicable, ou XAI. Ce champ a produit une abondance de méthodes, qui mettent en évidence les parties de l'entrée les plus corrélées à une sortie donnée, ou qui en proposent une approximation locale. Nous montrerons toutefois que ces méthodes, aussi utiles soient-elles, demeurent locales et corrélationnelles, et qu'elles ne livrent pas la compréhension d'ensemble que le problème de l'opacité réclame. Une part de la littérature reconnaît d'ailleurs que le champ souffre d'un déficit de fondements conceptuels, faute d'avoir relié ses méthodes aux théories établies de l'explication scientifique. C'est en ce point qu'un mémoire de philosophie, et non de seule ingénierie, peut apporter quelque chose, car l'objet manque moins de techniques que de concepts pour penser ce que ces techniques produisent. Un programme plus récent, l'interprétabilité mécaniste, déplace justement l'ambition, puisqu'il ne cherche plus à éclairer une décision isolée, mais à reconstruire l'organisation fonctionnelle interne des modèles, en empruntant aux sciences du vivant leurs stratégies de découverte. C'est ce programme que nous examinerons, et c'est à son endroit que se joue notre thèse.

Cette thèse se déploie en deux moitiés. La première est que l'interprétabilité mécaniste produit des explications authentiquement mécanistes, au sens que Craver et Bechtel ont fixé à ce terme, de sorte que l'analogie avec le vivant, sur ce plan, tient. La seconde moitié est plus inattendue, et elle constitue l'apport propre de ce travail. La réussite même de l'interprétabilité mécaniste révèle en effet que les catégories classiques de l'explication mécaniste, forgées pour des systèmes issus de l'évolution ou de la conception, doivent être enrichies pour rendre compte d'un système dont l'organisation a émergé de l'entraînement. Nous procéderons alors par étapes. Nous dégagerons d'abord des enrichissements que l'on peut accepter séparément, puis nous risquerons, à titre plus exploratoire, un concept susceptible de les unifier, dont nous réservons l'élaboration à la troisième partie.

Deux traits de méthode méritent enfin d'être annoncés. D'une part, ce mémoire avance par un fil dennettien continu, qui relie l'ontologie du premier mémoire à l'épistémologie de la présente, de sorte que les outils du M1, le réa-

lisme des patterns et les trois perspectives de Dennett y jouent un rôle effectif et non décoratif. D'autre part, il prend pour matériau les résultats techniques les plus récents de l'interprétabilité, comme la superposition, l'abstraction causale ou l'indifférence morale des modèles, qu'il s'attache à lire philosophiquement plutôt qu'à seulement rapporter. Ce parti pris a une exigence. Le domaine est en effet en renouvellement rapide, et certaines de ses sources sont des rapports techniques plutôt que des articles établis. Nous avons donc vérifié nos sources autant que possible, et précisé en note, pour les publications en ligne dépourvues de pagination, le mode de localisation retenu.

Notre parcours comporte trois parties, suivies d'une conclusion. La première partie établit la nature du problème de l'opacité. Elle le conduit de l'ontologie héritée du M1 jusqu'aux limites de l'XAI classique, et elle dégage le besoin d'un programme mécaniste. La deuxième partie expose ce programme, l'interprétabilité mécaniste, et elle établit la première moitié de notre thèse, en montrant que ses pratiques instancient effectivement le cadre néo-mécaniste et l'interventionnisme de Woodward. La troisième partie éprouve l'analogie sur laquelle ce programme repose, et elle établit la seconde moitié de notre thèse, en montrant comment les LLM, objets d'un type nouveau, exercent une pression sur les catégories de l'explication mécaniste et appellent leur enrichissement. La conclusion, enfin, renversera la question. Après avoir interrogé ce que l'interprétabilité nous enseigne sur les LLM, nous demanderons ce que les LLM, ainsi compris, nous apprennent de la compréhension, et de la nôtre.

Le problème de l'opacité : de Dennett au projet de l'XAI

L'introduction a posé la question directrice du présent travail et en a annoncé la thèse. Pour cela, elle a caractérisé en quelques traits le problème de l'opacité, et elle a esquissé le paysage des recherches en intelligence artificielle explicable. Cette première partie reprend ces éléments afin de les établir.

Elle poursuit trois objectifs, que l'on peut énoncer séparément. Le premier est de montrer que l'opacité des grands modèles de langage, les LLM, constitue un problème proprement épistémologique. Cette opacité est en effet héritée du résultat ontologique du précédent mémoire, et elle ne se réduit pas à une difficulté d'ingénierie qui se résorberait avec le progrès technique. Le deuxième objectif est de présenter le programme de l'XAI, d'en fixer le vocabulaire, et d'en dégager la posture méthodologique dominante, que Kästner et Crook (2024) nomment la stratégie du «diviser pour régner». La troisième visée consiste à démontrer que cette approche, par sa seule structure, ne satisfait pas l'exigence explicative soulevée par la première. Nous nous appuyerons pour cela sur les diagnostics convergents de Kästner et Crook et de Rabiza (2026). La partie se referme enfin sur le besoin d'un programme plus ambitieux, l'interprétabilité mécaniste, dont l'examen occupera la deuxième partie.

1.1 De l'ontologie à l'épistémologie : la nature du problème de l'opacité

Un héritage et une dette

Notre mémoire de Master 1 a soutenu une thèse : les systèmes d'IA contemporains, et les LLM au premier chef, sont le mieux compris, prédits et expliqués

lorsqu'on adopte à leur endroit la perspective intentionnelle de Dennett³. Nous proposons de regrouper ces systèmes sous la catégorie de l'ACAFA, l'agent cognitif artificiel fonctionnellement autonome. Nous le définissons comme une entité dont le comportement, complexe et adaptatif, justifie l'attribution de « croyances » et de « désirs » au sens fonctionnel, sans qu'il soit pour autant requis de lui postuler une compréhension sémantique humaine ni une conscience phénoménale. Cette position s'autorisait de deux thèses centrales de Dennett. La première est le réalisme des patterns, qui tient les régularités comportementales pour des faits objectifs, au même titre qu'un centre de gravité est une abstraction réelle et utile. La seconde est la distinction entre compétence et compréhension, qui dissocie la performance cognitive de toute vie intérieure.

Or la perspective intentionnelle a une portée délibérément limitée. Elle livre, selon la formule de Dennett, les spécifications d'un esprit, et elle laisse pour plus tard la question de sa réalisation. Adopter la perspective intentionnelle envers un LLM, c'est en effet prédire son comportement en lui attribuant des états contentifs, sans rien dire de la manière dont ces états sont effectivement réalisés dans l'architecture du modèle. Cette perspective réussit comme stratégie prédictive précisément parce qu'elle fait l'économie de la réalisation, et c'est là sa force autant que la borne de ce qu'elle nous apprend. Dennett insiste d'ailleurs sur ce point, lorsqu'il compare l'attribution intentionnelle à l'établissement d'un cahier des charges : on y spécifie les compétences requises pour détecter et traiter l'information de l'environnement, et l'on renvoie à plus tard la question de l'implémentation.

Cette limitation ne constituait pas un défaut de notre travail antérieur, puisqu'elle en marquait simplement la frontière. Elle engage toutefois une dette. En accordant aux LLM le statut de systèmes intentionnels, nous avons noté en conclusion que cette reconnaissance ouvrait la voie à ce que l'on pourrait appeler une « psychologie » des agents artificiels, c'est-à-dire l'équivalent fonctionnel d'une psychologie ou d'une neuropsychologie humaine. L'analogie était suggestive, mais elle restait programmatique. En effet, reconnaître en un système un sujet d'attributions intentionnelles ne procure encore aucun savoir sur les mécanismes qui sous-tendent son comportement. Un clinicien qui tient son patient pour un agent rationnel ne dispose pas, par ce seul fait, d'une

³Voir Branger (2025), ch. 11 et 14, et l'Annexe A, extraits [A], [B] et [C], qui reproduisent respectivement la définition de l'ACAFA, le réalisme des patterns et la distinction de la compétence et de la compréhension.

connaissance des processus à l'œuvre dans sa cognition. Il lui faut, pour y accéder, des méthodes d'investigation, des modèles explicatifs, et des critères pour évaluer la qualité des explications qu'il produit. La situation des LLM est analogue, à une différence près qui en aggrave la portée. L'opacité du cerveau humain est contingente, car elle tient à la difficulté d'accéder à un organe vivant. Celle d'un LLM, en revanche, tient à la nature même d'un système dont l'organisation fonctionnelle résulte d'un apprentissage automatisé portant sur des milliards de paramètres. C'est donc ce passage de la spécification à la réalisation, de ce que le système fait à la manière dont il le fait, qui définit la tâche épistémologique du présent mémoire, et c'est exactement là que l'opacité fait obstacle.

Trois sens de la transparence

Le terme d'opacité recouvre des réalités hétérogènes qu'il convient de séparer, car les confondre fausse le diagnostic et conduit à proposer des remèdes inopérants. En suivant la typologie de la transparence proposée par Creel (2020), que l'introduction a déjà mobilisée, on peut distinguer trois sens.⁴

Le premier est ce que Creel nomme la transparence fonctionnelle, c'est-à-dire la connaissance de la logique générale selon laquelle un système transforme ses entrées en sorties. Pour un LLM, cette transparence consiste à savoir qu'il s'agit d'un transformeur autorégressif, qui estime à chaque pas une distribution de probabilité sur le prochain token, conditionnellement au contexte. Or cette logique générale est publiquement documentée, de sorte qu'à ce niveau le modèle n'est pas opaque. Le deuxième sens est la transparence structurelle, soit la connaissance de la manière dont cette logique est effectivement réalisée dans le code et dans les poids du modèle. Le troisième sens est la transparence d'exécution, soit la connaissance de ce qui s'est produit au cours d'un passage particulier, pour une entrée donnée et sur un matériel donné, c'est-à-dire la trace complète des activations qui ont conduit à une sortie.

Cette tripartition rend un service que l'introduction ne pouvait que suggérer, car elle permet de constater que les trois transparences sont, en droit, accessibles, sans que leur acquisition dissolve pour autant le problème qui nous occupe. La transparence fonctionnelle est en effet donnée par la description de

⁴Creel, K. (2020), «Transparency in Complex Computational Systems», *Philosophy of Science*, 87(4). Les trois formes sont annoncées en introduction (§1) puis développées aux sections §3a (transparence fonctionnelle), §3b (transparence structurelle) et §3c (transparence d'exécution). Nous renvoyons aux sections plutôt qu'aux pages, le texte que nous suivons étant la version preprint.

l'architecture. La transparence structurelle est donnée par la publication des poids, comme c'est le cas pour les modèles dits à poids ouverts. La transparence d'exécution, enfin, est donnée par l'instrumentation du modèle, qui permet de journaliser chaque activation intermédiaire au cours d'une inférence. Imaginons à présent un chercheur qui disposerait des trois. Il aurait l'artefact tout entier sous les yeux, soit l'architecture, les paramètres, et la trace de chaque calcul. Il resterait pourtant incapable de dire pourquoi le modèle a produit cette sortie plutôt qu'une autre, en quoi consiste la compétence qu'il manifeste, ou comment il se comporterait dans un contexte nouveau. La transparence des trois niveaux de Creel laisse donc intacte l'opacité qui nous intéresse.

De l'accès à l'intelligibilité

Il faut par conséquent nommer cette opacité résiduelle, et la distinguer fermement des précédentes. Les trois transparences de Creel concernent en effet l'accès, c'est-à-dire le fait d'avoir ou non les éléments du système à disposition. L'opacité qui résiste à l'accès concerne tout autre chose, à savoir l'intelligibilité, c'est-à-dire le fait de pouvoir ou non comprendre ces éléments une fois qu'on les a. Cette distinction est décisive pour le mémoire dans son ensemble, puisqu'elle interdit de traiter le problème comme une affaire de transparence, que l'ouverture des modèles ou l'augmentation des moyens de calcul résoudrait, et qu'elle l'identifie comme une affaire d'explication.

Deux auteurs permettent de préciser cette opacité d'intelligibilité. Burrell (2016) distingue d'abord trois formes d'opacité dans les systèmes d'apprentissage automatique.⁵ La première est le secret intentionnel, lorsqu'une entreprise dissimule le fonctionnement de ses systèmes pour des raisons commerciales ou de propriété intellectuelle. La deuxième est l'illettrisme technique, lorsqu'un système n'est opaque que parce que celui qui l'examine ne maîtrise pas le code ou les mathématiques requises. Ces deux formes sont contingentes, puisque la première se lève par la divulgation et la seconde par la formation. La troisième forme, en revanche, est d'une autre nature, dans la mesure où elle tient à l'inadéquation entre la manière dont un système optimisé par apprentissage calcule et les modes humains du raisonnement sémantique. Un classifieur peut en effet exploiter des régularités statistiques réparties sur des milliers de dimensions, sans que ces régularités correspondent à une quelconque catégo-

⁵Burrell, J. (2016), « How the Machine "Thinks" : Understanding Opacity in Machine Learning Algorithms », *Big Data & Society*, 3(1), 1-12. Les trois formes (secret intentionnel, illettrisme technique, opacité propre au fonctionnement des algorithmes à l'échelle) sont annoncées p. 1 et développées p. 3-5.

rie que l'esprit humain manie spontanément. Cette opacité-là ne se lève donc ni par la divulgation ni par la formation, puisqu'elle ne tient pas à un défaut d'accès, mais à un écart entre deux régimes de traitement de l'information.

Humphreys (2009, p. 618) en propose ensuite une formulation plus générale, avec la notion d'opacité épistémique. Un processus est épistémiquement opaque, relativement à un agent cognitif, lorsque cet agent ne peut connaître l'ensemble des éléments épistémiquement pertinents qui le composent. Humphreys ajoute une distinction que nous reprenons, car elle structure en sous-main la thèse de ce mémoire. Un processus peut d'abord être épistémiquement opaque de manière contingente, parce que l'agent manque pour l'heure des ressources nécessaires. Il peut ensuite l'être de manière essentielle, lorsqu'aucun agent de notre espèce ne pourrait, en raison de ses limitations constitutives, en connaître les éléments. Laquelle de ces deux opacités affecte les LLM ? La question n'est pas tranchée d'avance, et elle commande pourtant l'évaluation de l'intégralité du programme de l'interprétabilité. Si l'opacité des LLM était essentielle, l'ambition de les rendre intelligibles serait en effet vaine par principe. Si elle n'est que contingente, la question devient au contraire celle des méthodes capables de la lever. L'interprétabilité mécaniste, que nous examinerons en deuxième partie, fait le pari que l'opacité des LLM est de la seconde espèce, donc difficile et coûteuse, mais surmontable. Une partie de l'enjeu de la troisième partie sera dès lors de mesurer ce que ce pari coûte, et ce qu'il laisse de reste.

L'opacité des LLM est-elle essentielle ?

La distinction entre opacité contingente et opacité essentielle mérite qu'on s'y arrête, car elle conditionne la légitimité même du programme que nous examinerons. Humphreys forge la notion d'opacité épistémique essentielle pour les processus que, en raison de la nature de l'agent cognitif considéré, il est impossible de connaître intégralement. Le qualificatif « essentiel » porte donc sur les limitations constitutives de l'agent, et non sur un manque circonstanciel de ressources. Un exemple le montre. Une multiplication de grands nombres effectuée mentalement m'est opaque de manière contingente, puisqu'un crayon suffit à la lever. En revanche, le déroulement complet d'une simulation portant sur des millions de pas de calcul est opaque de manière essentielle pour n'importe quel être humain non assisté, parce qu'aucun esprit de notre espèce ne peut suivre pas à pas une telle séquence.

Trois caractéristiques des LLM peuvent faire pencher vers le diagnostic

d'une opacité essentielle. La première est l'échelle, car un modèle compte des milliards de paramètres, et pas un seul esprit humain ne peut tenir ensemble, dans un même acte de compréhension, le rôle de chacun. La deuxième est la superposition, sur laquelle la troisième partie reviendra : un même neurone participe à la représentation de plusieurs traits sans correspondre à aucun d'eux en propre, de sorte que l'unité d'analyse la plus naturelle, le neurone individuel, ne porte pas de signification isolable. La troisième est la forme dégagée par Burrell, car si les régularités exploitées par le modèle ne correspondent à aucune catégorie que l'esprit humain manie, alors aucune inspection ne les rendra intelligibles dans nos termes, faute de termes disponibles pour les recevoir.

Il faut pourtant résister à la conclusion hâtive, puisque l'opacité épistémique est relative à deux paramètres que Humphreys distingue, et que l'on a tort de confondre. Le premier paramètre est le niveau de description. Un processus peut être essentiellement opaque à un niveau, celui du suivi paramètre par paramètre, et parfaitement tractable à un autre, celui de l'organisation fonctionnelle décrite en termes de composants et de leurs rôles. Nul n'exige en effet, pour comprendre la circulation sanguine, de suivre la trajectoire de chaque molécule, puisqu'on la comprend au niveau du cœur, des vaisseaux et de leurs fonctions. La question pertinente n'est alors pas de savoir si l'on peut connaître tous les paramètres d'un LLM, ce que nul ne peut, mais de savoir s'il existe un niveau de description plus grossier auquel son organisation devient intelligible. Or tout le pari de l'interprétabilité mécaniste consiste à affirmer qu'un tel niveau existe, celui des traits et des circuits, et la deuxième partie examinera comment elle prétend l'atteindre.

Le second paramètre est la nature de l'agent. Humphreys observe que les méthodes computationnelles étendent la portée épistémique des sujets humains, qui connaissent désormais, par l'intermédiaire d'instruments, ce qu'ils ne pourraient connaître seuls. L'opacité est donc relative à l'équipement de l'agent autant qu'à ses facultés. Or l'interprétabilité ne procède jamais sans instruments, puisqu'elle mobilise des auto-encodeurs, des sondes et des interventions automatisées, qui jouent le rôle de prothèses épistémiques. La question devient alors la suivante : l'opacité est-elle essentielle pour l'humain non assisté, ou pour le système composite que forment l'humain et ses instruments ? Les deux réponses peuvent diverger, et c'est la seconde qui importe pour juger du programme.

Nous retiendrons donc une thèse mesurée, qui orientera l'évaluation des

parties suivantes. L'opacité des LLM est essentielle à un certain niveau et pour un certain agent, celui du paramètre individuel et de l'humain non assisté. Elle n'est peut-être que contingente, en revanche, à un autre niveau et pour un autre agent, celui de l'organisation fonctionnelle et de l'humain instrumenté. Le programme de l'interprétabilité mécaniste revient de fait exactement à parier que ce double déplacement, de niveau et d'équipement, suffit à convertir une opacité d'apparence essentielle en une opacité surmontable. La troisième partie demandera dès lors si ce pari est tenu sans reste, ou si certaines propriétés des LLM, la superposition au premier chef, résistent même à ce déplacement.

Une opacité tenant au mode de genèse

Il reste à dire pourquoi cette opacité d'intelligibilité est structurelle, c'est-à-dire pourquoi elle tient à la nature de l'objet et non à l'état provisoire de nos connaissances. La réponse réside dans le mode de genèse de ces systèmes, et l'appareil dennettien du M1 permet de la formuler avec précision.

Dennett distingue, en deçà de la perspective intentionnelle, la perspective du dessein, qui prédit le comportement d'un système à partir de la fonction que son concepteur lui a assignée. Cette perspective éclaire les artefacts conçus, et pour une raison précise : dans leur cas, l'intention du concepteur fixe par avance la correspondance entre fonction et structure. On comprend ainsi une horloge en remontant à ce que ses parties ont été agencées pour faire. Or l'organisation fonctionnelle d'un LLM n'a pas été assignée par un concepteur, car elle a été trouvée par une procédure d'optimisation portant sur des milliards de paramètres, au cours d'un entraînement automatisé. Aucune intention n'a présidé à la répartition des fonctions entre les composants, puisque cette répartition est le produit aveugle de la minimisation d'une fonction de coût. La correspondance entre fonction et structure n'est donc pas donnée d'avance, à lire dans une documentation, mais elle doit être reconstruite après coup, par rétro-ingénierie. Voilà pourquoi la perspective du dessein, qui suffirait pour un programme écrit à la main, échoue devant un modèle entraîné, et voilà aussi ce qui justifiait le recours, dans notre M1, à la perspective intentionnelle.

C'est ici qu'intervient un autre acquis du M1, la réalisabilité multiple. Une même fonction peut être réalisée d'une indéfinité de manières physiquement distinctes, et rien n'oblige donc la réalisation qu'un entraînement sélectionne à être lisible pour un esprit humain. L'opacité de l'organisation fonctionnelle ne se réduit dès lors pas à un état d'ignorance transitoire que dissiperait la consultation d'un plan, puisqu'elle est une caractéristique de ce type d'objet. On re-

trouve ici, par un détour réflexif, la thèse dennettienne de la compétence sans compréhension, mais retournée vers nous. De même que le LLM exhibe une compétence sans que nulle compréhension ne préside à ses performances, de même nous exhibons à son endroit une compétence prédictive, celle que nous procure la perspective intentionnelle, sans disposer pour autant d'une compréhension des mécanismes qui la rendent possible. L'évolution par sélection naturelle, exemple favori de Dennett, a produit l'œil sans ingénieur conscient, et l'entraînement par descente de gradient a, de façon analogue, produit l'organisation interne du modèle sans plan d'ensemble. L'analogie entre l'apprentissage machine et l'évolution ne joue donc pas ici le rôle d'un simple ornement, puisqu'elle indique que l'organisation des LLM relève du même type d'opacité que celle des organismes. C'est précisément ce constat qui ouvrira, en deuxième partie, la voie aux stratégies empruntées aux sciences du vivant.

Telle est la dette que le résultat ontologique du M1 a contractée. Accorder aux LLM le statut de systèmes intentionnels, c'est en effet s'engager à dire comment l'organisation fonctionnelle qui fonde leur comportement est réalisée, alors même que cette organisation est, pour les raisons que l'on vient de voir, structurellement opaque au sens de l'intelligibilité. Par conséquent, le problème de l'opacité ne constitue pas un préalable technique que l'on écarterait avant de philosopher, car il est lui-même l'objet philosophique. Reste à savoir si les outils dont nous disposons sont à la hauteur de cette dette, et c'est l'examen auquel procède la suite de cette partie.

1.2 Le programme de l'XAI : explicabilité, interprétabilité et stratégie du « diviser pour régner »

Deux termes qu'il faut distinguer

Le champ de l'intelligence artificielle explicable s'est constitué autour d'une question simple à formuler : pourquoi le modèle a-t-il produit cette sortie pour cette entrée ? Miller (2019) propose de définir l'interprétabilité comme le degré auquel un observateur peut comprendre la cause d'une décision, et de tenir l'explication pour l'un des modes par lesquels cet observateur accède à cette compréhension. La littérature emploie souvent « interprétabilité » et « explicabilité » comme des termes interchangeables, convention que Rabiza signale et qu'il suit provisoirement. Pour les besoins du présent mémoire, il convient au

contraire de les distinguer, car cette distinction recoupe l'axe autour duquel s'organisera l'ensemble de notre diagnostic.

Dorsch et Moll (2024) proposent à cet égard une démarcation utile. Ils réservent l'interprétabilité à la compréhension holistique du modèle, de ses poids et de ses paramètres, c'est-à-dire à la saisie de la manière dont le système fonctionne dans son ensemble. Ils réservent en revanche l'explicabilité à la production d'aperçus compréhensibles, destinés à des utilisateurs, concernant des résultats particuliers. Selon cette répartition, l'explicabilité vise donc une décision singulière et son destinataire, tandis que l'interprétabilité vise l'organisation du système. Nous adopterons cette distinction, car elle anticipe la ligne de partage de toute notre analyse. La critique de l'XAI classique que développe la section 1.3 reviendra en effet à montrer que les méthodes dominantes excellent dans l'explicabilité au sens de Dorsch et Moll, tout en demeurant en deçà de l'interprétabilité au sens où l'opacité héritée de notre M1 la réclame. Le terme d'interprétabilité mécaniste, que nous introduirons en deuxième partie, désigne précisément l'ambition de combler cet écart.

Les destinataires de l'explication et la stratégie du « diviser pour régner »

Avant d'examiner les méthodes, il importe de caractériser la posture méthodologique qui les ordonne. Kästner et Crook (2024) la nomment la stratégie du « diviser pour régner ». L'XAI cherche en effet, dans chaque cas, l'explication la plus appropriée pour une solution donnée, dans un contexte donné, et pour une tâche et un destinataire donnés. Cette stratégie repose sur une intuition fondée, puisqu'il n'existe pas d'explication universelle valable pour tout système, tout contexte et tout destinataire, et que les contraintes pesant sur une explication varient avec la situation.

Cette intuition trouve son fondement dans la diversité des destinataires. González Barman (2026), reprenant une classification de Preece et ses collègues (2018), distingue plusieurs catégories de parties prenantes dont les besoins explicatifs diffèrent. Les concepteurs, ingénieurs et data scientists cherchent d'abord à optimiser le système, et ils requièrent donc des explications dotées d'adéquation causale et de cohérence. Les opérateurs, qui interagissent quotidiennement avec lui, privilégient au contraire la simplicité. Les sujets de décision, c'est-à-dire les individus affectés par les sorties du modèle, ont besoin que l'explication soit cohérente avec le contexte plus large dans lequel la décision les concerne. Les examinateurs, enfin, chargés de l'audit et

de la conformité, exigent l'exactitude factuelle. À chaque catégorie correspond ainsi une question « pourquoi » distincte, et donc une explication distincte. La conséquence est nette : il n'y a pas une explication d'une décision, mais autant d'explications adéquates qu'il y a de destinataires et de questions légitimes.

Cette relativité aux destinataires éclaire l'orientation pratique de l'XAI, mais elle en révèle aussi un travers, que Miller et ses collègues ont nommé le risque de voir les détenus diriger l'asile. Les explications sont en effet fréquemment conçues par et pour des développeurs, c'est-à-dire pour les destinataires les plus experts, et elles délaissent les utilisateurs finaux qui ne maîtrisent pas l'apprentissage automatique⁶. Dorsch et Moll en tirent une observation que nous retiendrons. Les graphiques de caractéristiques produits par des méthodes comme LIME ou SHAP se révèlent épistémiquement opaques pour les non-experts, car ceux-ci n'y lisent pas les raisons épistémiques d'une décision, et ne peuvent en inférer le degré de confiance à accorder au système. L'explicabilité, lors même qu'elle réussit pour un expert, peut donc échouer pour le destinataire qu'elle prétend servir.⁷

La stratégie du « diviser pour régner » a néanmoins des mérites réels. Elle accommode naturellement le fait qu'aucune méthode singulière ne saurait convenir à la totalité des cas. Elle a été, et elle demeure, féconde, tant par les méthodes nouvelles qu'elle engendre que par l'analyse conceptuelle qu'elle nourrit. Sa forme même, comme on le verra en 1.3, a toutefois des conséquences sur ce qu'elle peut et ne peut pas livrer.

Les principales familles de méthodes locales

Les méthodes dites post hoc dominant le paysage. Elles s'appliquent à un modèle déjà entraîné, afin d'en éclairer une décision particulière. On peut en distinguer plusieurs familles, qui répondent à des questions voisines.

La première famille attribue la décision à certaines parties de l'entrée, par l'examen des gradients. Les cartes de saillance fondées sur le gradient (Simonyan et al., 2014) mesurent ainsi comment la sortie du modèle varie lorsqu'on

⁶La formule provient de Miller, Howe et Sonenberg (2017), « Explainable AI : Beware of Inmates Running the Asylum » (atelier XAI d'IJCAI 2017 ; arXiv :1712.00547), qui l'empruntent eux-mêmes à Cooper (2004), *The Inmates are Running the Asylum*. Nous l'employons ici pour caractériser le biais de destination qui affecte une part de la production de l'XAI.

⁷Dorsch, J. et Moll, M. (2024), « Explainable and Human-Grounded AI for Decision Support Systems : The Theory of Epistemic Quasi-Partnerships ». Les auteurs qualifient les graphiques de caractéristiques d'épistémiquement opaques pour les non-experts p. 7, et précisent p. 9 qu'ils n'y lisent pas les raisons épistémiques de la décision.

perturbe chaque composante de l'entrée, puis agrègent ces gradients en un score d'importance par variable ou par token. Une variante par perturbation, illustrée par la méthode RISE (Petsiuk, Das et Saenko, 2018), telle que la présente González Barman (2026), masque pour sa part aléatoirement des régions de l'entrée et mesure l'effet de ces masquages sur la confiance du modèle, ce qui produit une carte de saillance signalant les régions déterminantes. Une autre variante, l'importance des caractéristiques par permutation, mélange enfin aléatoirement les valeurs d'une variable et mesure la chute de performance qui en résulte, ce qui fournit un classement des variables par importance.

Encadré — Lire une carte de saillance

Une *carte de saillance* superpose à l'entrée une couche de couleurs : à chaque composante, chaque pixel d'une image, chaque token d'un texte, elle associe un score d'importance, le plus souvent dérivé du gradient de la sortie par rapport à cette composante. Les régions les plus vives (en clair sur la figure) sont celles dont une faible variation modifierait le plus la décision, tandis que les régions sombres n'y contribuent presque pas. La carte répond ainsi à une question précise : *où*, dans l'entrée, le modèle puise-t-il de quoi décider ?




Illustration schématique à partir de données synthétiques : à gauche, une entrée ; à droite, la carte de saillance correspondante. Les zones les plus vives marquent les composantes jugées les plus déterminantes pour la décision.

C'est aussi là que réside sa limite, décisive ici. Une telle carte établit une *corrélation* entre des régions de l'entrée et la sortie, non un *rôle causal* : elle montre où le modèle est sensible, sans dire pourquoi ces régions comptent ni ce qu'il adviendrait si on les modifiait réellement. Elle peut même mettre au jour un raccourci, un classifieur qui «regarde» la prai-

rie plutôt que l'animal, sans permettre, à elle seule, de distinguer l'indice pertinent de l'artefact. C'est cette insuffisance qui justifie le passage aux méthodes proprement interventionnistes, au cœur de la deuxième partie.

La deuxième famille produit des modèles de substitution locaux. La méthode LIME (Ribeiro et al., 2016) ajuste, au voisinage d'une prédiction donnée, un modèle linéaire interprétable dont les coefficients indiquent l'importance locale de chaque variable. La méthode SHAP (Lundberg et Lee, 2017) recourt quant à elle aux valeurs de Shapley, importées de la théorie des jeux, pour répartir entre les variables d'entrée leur contribution à la sortie, avec une garantie de cohérence locale. Une troisième approche, les explications par ancrage (Ribeiro et al., 2018), produit enfin des règles conditionnelles de la forme « si telles conditions sont réunies, alors telle classe ». Dorsch et Moll soulignent que ces règles épousent la forme de la déduction naturelle humaine, et qu'elles se révèlent, à ce titre, plus transparentes pour les utilisateurs que les graphiques de caractéristiques.

La troisième famille exploite le mécanisme d'attention propre aux architectures de type transformeur. En inspectant les poids d'attention, on cherche à tracer les tokens vers lesquels un token généré porte son attention. Les scores d'attention ne renseignent toutefois, localement, que sur les connexions au sein de chaque tête de chaque couche. Aussi de multiples techniques modélisent-elles le réseau comme un graphe, afin de reconstituer un flux d'attention global, soit par propagation récursive des matrices d'attention, soit par calcul de flux maximal le long des chemins.

La quatrième famille produit des explications contrefactuelles et des voies de recours algorithmique (Wachter et al., 2017). Elle indique quelle modification minimale de l'entrée aurait conduit à une sortie différente, et elle répond ainsi à une question contrastive : pourquoi cette décision plutôt qu'une autre, et que faudrait-il changer pour l'infléchir ? Dorsch et Moll rapportent que ce type d'explication améliore en pratique la calibration de la confiance des utilisateurs, ce qui en fait l'une des familles les mieux ancrées dans les pratiques épistémiques ordinaires.

Des « ingrédients » en quête d'explication

Toutes ces méthodes ont un trait commun. Elles produisent, pour un cas donné, une correspondance entre certaines parties de l'entrée, ou certaines ac-

tivations internes, et la sortie observée. Elles relèvent ainsi, en un sens large, de l'attribution et de la corrélation, puisqu'elles repèrent ce sur quoi le modèle s'appuie ou ce à quoi il prête attention, à l'occasion d'une décision. González Barman propose un terme pour désigner ce qu'elles livrent, celui d'ingrédients. Une carte de chaleur, une liste ordonnée de variables ou un vecteur de valeurs de Shapley sont en effet des ingrédients, et non encore des explications. Le mécanisme par lequel un ingrédient devient une explication, et par lequel une explication procure une compréhension, demeure pourtant largement impensé dans la littérature technique. González Barman le formule en reprenant une question de Lipton : que faut-il ajouter à la connaissance pour produire la compréhension ?

Cette question n'est pas oiseuse, et la philosophie des sciences offre un cadre pour y répondre. González Barman propose en effet d'analyser le passage de l'ingrédient à l'explication par l'inférence vers la meilleure explication. On évalue alors les explications candidates selon un ensemble de vertus explicatives : la profondeur, mesurée par le nombre et la qualité des questions contrefactuelles auxquelles une explication permet de répondre ; la précision, qui désigne la finesse du grain explicatif ; l'adéquation causale, qui valorise l'identification des causes les plus significatives ; la cohérence avec les connaissances de fond ; l'exactitude factuelle ; et la simplicité. Selon le destinataire et la question, on pondère différemment ces vertus. Nous reviendrons sur ce cadre, étant donné qu'il fournit un instrument pour évaluer la qualité explicative des approches que la deuxième partie examinera. Il suffit ici d'en retenir une leçon : produire un ingrédient ne suffit pas à expliquer, et le déficit de la littérature technique tient en partie à ce qu'elle a confondu les deux. L'adéquation causale, en particulier, va se révéler le point faible des méthodes locales, et c'est par elle que nous entamerons la critique.

1.3 Les limites des explications locales et l'exigence d'une compréhension holistique

Le diagnostic que partagent Kästner et Crook et Rabiza peut s'articuler en trois limitations distinctes. Les séparer importe, car elles n'appellent pas le même remède, et leur conjonction seule fait apparaître l'insuffisance structurale de la stratégie locale.

La localité et le défaut de holisme

Les méthodes que nous venons de décrire expliquent une décision singulière, dans un contexte singulier. Elles ne disent pas comment la structure interne du modèle réalise, en général, la fonction qui transforme ses entrées en sorties, et elles ne permettent pas non plus de prédire comment le système se comportera dans des contextes nouveaux. Rudin (2019) en a tiré une critique sévère du programme tout entier, puisque ces méthodes, juge-t-elle, ne fournissent pas assez de détails pour comprendre ce que fait la boîte noire, et qu'il faudrait dès lors leur préférer des modèles intrinsèquement interprétables. Freiesleben et al. (2024) parviennent à une conclusion convergente en évaluant deux techniques précises, la visualisation de caractéristiques et la dissection de réseau, dont aucune ne suffit à étayer des inférences sur le rôle fonctionnel des sous-parties du modèle.

L'argument décisif de Kästner et Crook porte cependant plus loin. La compréhension holistique que requiert le problème de l'opacité ne s'obtient pas en sommant des explications locales, car l'information sur l'organisation fonctionnelle d'ensemble ne peut être inférée de l'application séparée de divers outils d'XAI, aussi nombreux soient-ils. La raison en est interne à la stratégie : les explications locales ne caractérisent jamais leurs cibles comme des composants fonctionnels d'une organisation unique, de sorte que le tout n'est pas reconstituable à partir de la juxtaposition des parties. La stratégie du « diviser pour régner » exclut donc, par sa forme même, le type de compréhension que l'opacité d'intelligibilité réclame. On peut reformuler ce constat dans le vocabulaire fixé en 1.2, en disant que la stratégie locale relève de l'explicabilité, sans livrer l'interprétabilité. Ce qu'il faudrait, écrivent Kästner et Crook, est une investigation systématique, livrant des aperçus généralisables sur l'organisation fonctionnelle globale des systèmes.

Corrélation, causalité et fidélité

La deuxième limitation concerne le statut causal et la fidélité des explications produites. Les méthodes locales sont en effet corrélationnelles ou heuristiques, et leur fidélité au calcul effectif du modèle n'est pas garantie. L'exemple de l'attention est à cet égard instructif, car un poids d'attention élevé sur un token n'implique pas que ce token exerce une influence importante sur les *logits* de sortie, de sorte que la lecture des cartes d'attention peut induire en erreur sur ce qui détermine réellement la génération. Les méthodes fondées sur le gradient, de leur côté, ne fournissent qu'une approximation au premier ordre,

et elles peuvent se révéler instables. LIME et SHAP peuvent en outre être délibérément trompées par des attaques adverses (Slack et al., 2020), et les explications contrefactuelles, manipulées (Slack et al., 2021). À mesure que les modèles croissent en taille, enfin, les attributions deviennent instables d'une entrée semblable à l'autre, et les modèles produisent volontiers des justifications plausibles qui ne reflètent pas leur traitement effectif, comme l'a montré l'étude des raisonnements explicités infidèles (Turpin et al., 2023).

Le cas de l'attention mérite d'être développé, car il offre l'illustration la plus nette de l'écart entre corrélation et rôle causal, et il a donné lieu à un débat méthodologique exemplaire. Les poids d'attention sont, dans une architecture de type transformeur, les coefficients par lesquels chaque token pondère les autres lors du calcul de sa représentation. Il est dès lors tentant d'y lire l'explication d'une décision, car si le modèle a accordé une forte attention à tel token, c'est, semble-t-il, que ce token a compté. Cette lecture se heurte pourtant à deux difficultés. La première est locale, puisque les poids d'attention ne sont donnés qu'au niveau de chaque tête de chaque couche, et qu'un modèle en comporte des dizaines, de sorte qu'aucune carte d'attention isolée ne livre l'influence globale d'un token sur la sortie. Plusieurs techniques, l'*attention rollout* et l'*attention flow*, tentent certes de reconstituer ce flux global, en modélisant le réseau comme un graphe et en composant les matrices d'attention le long des chemins. Or ces reconstructions demeurent des agrégations de coefficients, et la seconde difficulté subsiste alors, car un poids d'attention élevé ne mesure pas une influence causale sur les logits. Un token peut en effet concentrer l'attention sans peser sur la sortie, tandis qu'un token peu attendu peut la déterminer par d'autres voies, notamment par le flux résiduel. Pour mesurer l'influence effective, il faut alors recourir à d'autres quantités, comme la différence de logits induite par l'ajout ou le retrait d'un token, qui relèvent d'une logique d'intervention et non d'observation.

Ce constat technique a nourri un débat dont l'enjeu est directement philosophique⁸. À la thèse selon laquelle l'attention ne constitue pas une explication, on a opposé que l'attention n'est pas non plus dépourvue de toute valeur

⁸Le débat oppose Jain et Wallace (2019), « Attention is not Explanation » (NAACL-HLT 2019, p. 3543-3556), et Wiegrefe et Pinter (2019), « Attention is not not Explanation » (EMNLP-IJCNLP 2019, p. 11-20). Le premier établit que des distributions d'attention divergentes peuvent produire des sorties identiques et que l'attention corrèle faiblement avec les attributions par gradient (sections 4.1 et 4.2, p. 3546-3550) ; le second répond que ces résultats ne disqualifient l'attention que sous une définition exigeante de l'explication, et qu'elle conserve une valeur sous des attentes plus modestes.

explicative. La première thèse s'étaie sur deux faits, à savoir que des distributions d'attention différentes peuvent produire la même sortie, et que les poids d'attention corrèlent mal avec les mesures d'importance fondées sur le gradient. La réponse consiste alors à préciser ce qu'on attend d'une explication, puisque, sous des attentes modestes, l'attention conserve une valeur. Ce qui se joue dans cet échange est la question même que ce mémoire prend pour objet : à quelles conditions un signal interne compte-t-il comme explicatif ? La réponse, que la deuxième partie élaborera, est qu'un signal n'est explicatif que s'il est rattaché à un rôle causal, établi par intervention, dans la production du phénomène. Or l'attention, observée et non manipulée, ne satisfait pas cette condition, puisqu'elle indique une corrélation interne, qui peut servir d'indice heuristique, sans tenir lieu d'explication causale.

On peut reformuler cette limitation dans le langage des vertus introduit en 1.2, en disant que ce qui fait défaut à ces méthodes est l'adéquation causale. Elles repèrent en effet des corrélations entre des éléments de l'entrée et la sortie. Cependant une corrélation n'est pas un rôle causal, et identifier ce à quoi un modèle prête attention n'équivaut pas à identifier ce qui produit, causalement, le phénomène. La leçon philosophique est celle que Rabiza (2026) formule en propre. Le consensus émergent dans la littérature fondamentale est en effet que l'XAI doit dépasser les méthodes fondées sur la corrélation et l'analyse entrée-sortie, pour examiner les systèmes d'IA dans une perspective fonctionnelle accordant une place centrale au raisonnement causal et aux méthodologies interventionnistes. Cette distinction entre corrélation et rôle causal prépare directement le programme interventionniste que nous examinerons en deuxième partie, où l'intervention sur les composants prendra le relais de l'observation des corrélations.

Le déficit de fondements conceptuels

La troisième limitation est plus rarement relevée, et c'est pourtant celle dont l'analyse philosophique tire le plus grand parti. Rabiza pose à ce sujet un diagnostic structurel : malgré des avancées techniques réelles, l'XAI souffre d'un manque persistant de fondements conceptuels robustes, et d'une intégration insuffisante au discours sur l'explication scientifique. Miller (2019) impute cette carence à l'orientation technologique du champ, qui a négligé les théories établies de l'explication ainsi que les apports des disciplines non techniques. Les méthodes locales produisent donc des ingrédients, pour reprendre le terme de González Barman, dont le statut explicatif demeure indéterminé,

car on ne sait pas, au juste, en quel sens ils expliquent, ni ce qu'une meilleure explication exigerait. La question de Lipton, que faut-il ajouter à la connaissance pour produire la compréhension, reste ainsi sans réponse tant qu'aucune théorie de l'explication n'est mobilisée.

Cette lacune, loin d'être marginale pour un traitement philosophique, en constitue au contraire l'ouverture. Pour juger si ces méthodes expliquent, et pour spécifier ce qui ferait une explication plus satisfaisante, il faut en effet disposer d'une théorie de l'explication. Or c'est précisément une telle théorie que la tradition néo-mécaniste en philosophie des sciences, celle de Machamer, Craver et Bechtel, met à disposition, et c'est vers elle que Kästner et Crook comme Rabiza se tournent. Le déficit de fondements conceptuels appelle donc l'importation d'un cadre que la deuxième partie aura pour tâche d'exposer. On notera que ce déficit explique aussi pourquoi un mémoire de philosophie, et non de seule ingénierie, a quelque chose à apporter ici, car l'objet manque moins de techniques que de concepts pour penser ce que ces techniques produisent.

Interpréter par conception ou expliquer après coup ?

Avant de conclure que l'XAI classique appelle un dépassement mécaniste, il faut considérer une objection qui propose un tout autre remède, et qui structure le champ depuis une intervention de Rudin (2019). Rudin soutient que, pour les décisions à fort enjeu, il faut cesser d'expliquer après coup des modèles opaques, et leur préférer des modèles intrinsèquement interprétables, c'est-à-dire des modèles dont la structure est lisible par conception, comme les arbres de décision, les modèles linéaires ou les modèles additifs généralisés. Son argument tient en deux propositions. La première est que les explications post hoc sont des approximations du modèle qu'elles prétendent éclairer, et qu'une approximation infidèle est trompeuse là où l'enjeu est grand. La seconde est que le compromis supposé entre précision et interprétabilité est souvent un mythe, car sur de nombreuses tâches un modèle interprétable atteint une performance comparable à celle d'une boîte noire, de sorte que l'opacité n'est pas le prix de la performance, mais un choix par défaut rarement justifié.

Cette position a un mérite et une limite, et les distinguer permet de situer exactement le programme que nous défendrons. Le mérite est de rappeler que l'opacité n'est pas une fatalité partout. Là où un modèle interprétable suffit, l'exiger est en effet la voie la plus sûre, et les travaux récents sur l'interprétabilité par conception, qui explorent des architectures pensées pour être lisibles, prolongent cette intuition. La limite tient en revanche au domaine. L'argument

de Rudin a sa pleine force pour des données structurées, à variables peu nombreuses et sémantiquement interprétables, comme un dossier de crédit. Il la perd pour les tâches de perception et de langage, où la fonction à approximer est d'une complexité telle qu'aucun modèle interprétable connu n'en égale la performance. Or les LLM appartiennent à ce second domaine. On ne sait pas, en effet, construire un modèle de langage intrinsèquement interprétable qui rivalise avec un transformeur entraîné sur de vastes corpus, et l'opacité y est donc, pour l'heure, le corrélat de la capacité.

Le champ se présente dès lors sous la forme d'une alternative à trois termes, et non à deux. On peut d'abord renoncer aux boîtes noires au profit de modèles interprétables par conception, ce que Rudin recommande, mais que le cas des LLM n'autorise pas⁹. On peut ensuite conserver les boîtes noires et se contenter d'explications locales produites après coup, ce que fait l'XAI classique, mais que les limites établies plus haut disqualifient. Reste enfin une troisième voie, qui consiste à conserver les boîtes noires, parce qu'on ne peut faire autrement, tout en entreprenant leur rétro-ingénierie systématique afin d'en découvrir l'organisation fonctionnelle. Cette troisième voie est celle de l'interprétabilité mécaniste. Elle assume l'opacité comme un fait, elle refuse de s'en accommoder par des explications de surface, et elle parie, conformément à la thèse mesurée dégagée en 1.1, que cette opacité est surmontable au bon niveau et avec les bons instruments. C'est cette voie que la suite du mémoire examine.

Le besoin d'une approche mécaniste

Ces trois limitations convergent. Localement utile, la stratégie de l'XAI classique demeure en effet constitutivement incapable de livrer un compte rendu holistique, causal et fonctionnellement fondé de l'organisation interne du système, soit exactement le compte rendu que réclame le problème de l'opacité hérité de notre M1. Kästner et Crook comme Rabiza aboutissent d'ailleurs au même remède, alors qu'ils partent de lieux différents, l'un de la philosophie de la technologie et de la sécurité, l'autre de la philosophie de l'explication scientifique. Ce remède est l'interprétabilité mécaniste. Il s'agit de cesser de sonder le modèle par fragments, pour entreprendre la découverte de son organisation fonctionnelle, en mobilisant les stratégies de découverte familières aux

⁹Cette voie, défendue par Rudin (2019), tient les modèles intrinsèquement interprétables pour préférables aux explications post hoc dans les contextes à fort enjeu. Nous ne la suivons pas, notre objet étant l'explication des LLM existants, opaques par construction. Référence : Rudin, C. (2019), «Stop Explaining Black Box Machine Learning Models for High Stakes Decisions and Use Interpretable Models Instead», *Nature Machine Intelligence*, 1(5), 206-215.

sciences du vivant. Kästner et Crook précisent que cette ambition ne vise pas à éliminer l'XAI traditionnelle, qu'ils tiennent au contraire pour complémentaire, mais à lui adjoindre une voie capable de la compréhension d'ensemble qui lui échappe. Ils reconnaissent du même coup que cette voie a un coût, en temps, en expertise et en ressources, qui peut n'être justifié que dans les contextes à fort enjeu, et nous y reviendrons.

Il faut souligner que ce remède ne surgit pas de nulle part, car il présuppose l'analogie même que notre mémoire de M1 a défendue. Pour qu'il soit légitime d'étudier un LLM comme on étudie un organisme, encore faut-il en effet que ce système soit autre chose qu'un artefact technique inerte, et qu'il manifeste une organisation fonctionnelle digne d'être découverte plutôt que simplement décrite. Or la perspective intentionnelle de Dennett et la catégorie de l'ACAFA fournissent précisément ce présupposé. Voilà pourquoi notre trajectoire, qui arrive à l'interprétabilité mécaniste par Dennett là où la plupart des auteurs y arrivent par le néo-mécanisme, n'est pas un détour, car elle fonde l'analogie que le programme suppose sans toujours la justifier. Nous avons d'ailleurs établi en 1.1 que l'opacité des LLM relève du même type que celle des organismes, en tant qu'elle procède d'un processus de genèse aveugle, l'apprentissage faisant écho à l'évolution. La continuité entre le M1 et la suite de ce mémoire tient tout entière dans ce point.

La deuxième partie peut dès lors aborder sa tâche dans des termes précis. Si l'interprétabilité mécaniste repose sur le postulat de l'analogie entre organismes et LLM, quelle théorie de l'explication importe-t-elle, et comment ses pratiques concrètes en instancient-elles les exigences ? Établir que l'interprétabilité mécaniste constitue un programme mécaniste légitime au sens de Craver et de Bechtel sera l'objet de la deuxième partie. Éprouver si l'analogie sur laquelle elle repose tient sans reste, et si l'opacité des LLM est, comme le parie le programme, contingente plutôt qu'essentielle, sera celui de la troisième.

L'interprétabilité mécaniste : stratégies et fondements philosophiques

La première partie a établi un constat et un manque. Le constat est que le problème de l'opacité, hérité du résultat ontologique de notre M1, appelle un compte rendu de l'organisation interne des LLM qui soit à la fois holistique, causal et conceptuellement fondé. Le manque est que l'XAI classique, par sa forme locale, ne peut fournir un tel compte rendu. Avec Kästner et Crook et avec Rabiza, nous avons enfin nommé le programme censé combler ce manque, à savoir l'interprétabilité mécaniste (ci-après MI).

Cette deuxième partie en constitue le cœur conceptuel. Elle poursuit trois tâches, que l'on peut énoncer séparément. La première est d'exposer la prémisses sur laquelle ce programme repose, que nous appellerons la prémisses organique, et de montrer sa continuité avec l'acquis dennettien du premier mémoire de Master. La deuxième est de dégager l'appareil philosophique que la MI importe, soit le cadre néo-mécaniste et l'interventionnisme de Woodward. La troisième est de montrer comment les pratiques concrètes de la MI instantient cet appareil. Trois traductions retiendront à cet égard notre attention : le *dictionary learning* comme décomposition fonctionnelle, le *patching* de l'espace latent comme intervention causale, et l'abstraction causale comme articulation des niveaux.

La thèse que cette partie entend établir est la première moitié de la thèse générale du mémoire : la MI produit des explications authentiquement mécanistes au sens de Craver et de Bechtel. La question de savoir si l'analogie qui la fonde tient sans reste sera, quant à elle, réservée à la troisième partie.

Un dernier jalon, posé entre les deux parties, permet de resserrer le passage de l'une à l'autre. La première partie a en effet montré deux choses : que l'XAI explique toujours relativement à des destinataires, et qu'aucune de ses

méthodes locales ne livre la compréhension d'ensemble. Or Zednik a cherché à donner à ce double constat une forme normative¹⁰. Il part d'une question simple, restée selon lui sans réponse claire dans la littérature technique : comment l'XAI devrait-elle expliquer ? Pour y répondre, il distingue les questions explicatives que posent les différents acteurs de ce qu'il nomme l'écosystème de l'apprentissage automatique. Puis il précise, pour chaque type de question, la manière dont elle devrait être traitée afin que l'acteur concerné puisse tenir son rôle.

Trois traits de cette proposition la désignent comme le pont vers la deuxième partie. D'abord, Zednik fonde son analyse de l'opacité sur Humphreys, celui-là même que nous avons mobilisé en 1.1, de sorte que son cadre s'inscrit dans la même lignée que le nôtre. Ensuite, il ordonne les questions explicatives selon les niveaux d'analyse de Marr, en distinguant le problème calculé, l'algorithme suivi et son implémentation. Or c'est au niveau algorithmique, nous le verrons, que loge l'ambition de la MI. Le troisième trait est le plus important. Zednik soutient en effet que le problème de rendre transparent un système opaque n'est pas sans ressemblance avec celui d'expliquer le comportement des humains et des autres êtres cognitifs, et il en conclut que l'XAI gagnerait à reprendre les normes et les pratiques des sciences cognitives. On reconnaît là, sous une forme encore prudente, la prémisse organique que Kästner et Crook porteront à son terme. Le cadre normatif de Zednik conduit ainsi de lui-même au seuil de la deuxième partie. Il a établi que la question profonde, celle du fonctionnement d'ensemble, appelle une explication de type cognitif et scientifique, mais il n'en a pas encore donné l'appareil. Cet appareil est celui que nous exposons à présent.

2.1 La prémisse organique

Kästner et Crook formulent explicitement le présupposé qui commande l'ensemble du programme. Leur approche, écrivent-ils, part de la prémisse suivante : une fois les systèmes d'IA devenus suffisamment complexes, ils sont le mieux étudiés et expliqués à travers le même prisme que les organismes biologiques, plutôt que traités comme de simples artefacts techniques. Cette formu-

¹⁰Zednik, C. (2021), «Solving the Black Box Problem : A Normative Framework for Explainable Artificial Intelligence», *Philosophy & Technology*, 34(2), 265-288 (preprint en ligne 2019). Zednik fonde son analyse de l'opacité sur Humphreys (2009), ordonne les questions explicatives selon les niveaux d'analyse de Marr (1982), et propose de reprendre, pour l'XAI, les normes et pratiques des sciences cognitives.

lation est dense, et elle appelle trois précisions, car c'est dans le détail qu'elle révèle sa portée et sa parenté avec notre travail antérieur.

La première précision porte sur l'objet de l'étude. Ce qui intéresse la MI n'est pas l'architecture que les concepteurs ont spécifiée avant l'entraînement, mais la structure apprise, celle qui émerge des procédures automatisées que le système subit après cette spécification initiale, et que Kästner et Crook nomment, à la suite d'autres, structure émergente. On retrouve ici, exactement, la distinction que la première partie avait tirée de Dennett en opposant la perspective du dessein et l'impossibilité de l'appliquer à un modèle entraîné. On ne peut en effet comprendre un LLM en remontant à l'intention de ses concepteurs, car cette intention ne fixe que le cadre de l'apprentissage, et non l'organisation fonctionnelle qui en résulte. La prémisse organique ne joue donc pas le rôle d'une métaphore décorative, puisqu'elle est la conséquence directe du mode de genèse établi en 1.1. Un système dont l'organisation a émergé d'un processus de sélection aveugle, qu'il s'agisse de l'évolution ou de la descente de gradient, ne se laisse pas lire comme un artefact conçu, et il appelle par conséquent les méthodes que l'on applique au vivant.

La deuxième précision porte sur les méthodes que la prémisse autorise. Étudier un LLM comme un organisme, c'est mobiliser les stratégies de découverte familières aux sciences de la vie : la reconnaissance de patterns, la décomposition fonctionnelle, la localisation, et la manipulation expérimentale systématique. L'objectif est alors de caractériser le système en termes de son organisation fonctionnelle, soit les activités organisées de ses composants fonctionnellement pertinents. On reconnaît ici, par anticipation, l'appareil néo-mécaniste que la section suivante exposera, dont la prémisse organique constitue la justification et dont les stratégies de découverte constituent la mise en œuvre.

La troisième précision porte sur le type d'explication visé. Kästner et Crook le distinguent avec soin de ce que la littérature appelle une explication globale. Une méthode d'XAI est dite globale lorsqu'elle produit de l'information explicative sur un modèle entier, par opposition aux méthodes locales qui portent sur une inférence singulière. Mais l'ambition de la MI ne se confond pas avec la globalité en ce sens, puisqu'elle vise le holisme, terme que Kästner et Crook réservent aux explications qui capturent la structure fonctionnelle entière d'un modèle entraîné, et qui prennent typiquement la forme de diagrammes accompagnés de texte. Une méthode globale idéale pourrait, en droit, produire une explication holistique, alors qu'en pratique aucune méthode existante n'en approche. Cette distinction confirme le diagnostic de la première partie. L'enjeu

n'est pas d'agréger de l'information sur le modèle entier, mais de reconstituer son organisation. Or reconstituer une organisation suppose des composants, des activités et une structure, c'est-à-dire un mécanisme.

Reste à marquer le point qui fait de cette prémisse, pour nous, autre chose qu'un emprunt. Lorsque Kästner et Crook précisent comment identifier les composants fonctionnels d'un système d'IA, ils en appellent à une pratique de reconnaissance de patterns. Et ils définissent les patterns, en citant explicitement Dennett, comme les arrangements non aléatoires au sein des systèmes, qui se prêtent à la reconnaissance en vertu de leur caractère ordonné. La filiation est donc directe. Le réalisme des patterns que notre M1 a défendu, et sur lequel reposait l'attribution intentionnelle aux LLM, est le fondement que la MI présuppose sans toujours le thématiser. Là où la plupart des auteurs arrivent à la MI par la philosophie des sciences, nous y arrivons par Dennett, et cette voie ne constitue pas un détour idiosyncrasique, puisqu'elle remonte au principe que le programme lui-même invoque. Reconnaître un composant fonctionnel dans un réseau, c'est en effet reconnaître un pattern réel au sens de Dennett, soit une régularité objective qui mérite d'être traitée comme une chose alors même qu'elle n'est pas une entité matérielle isolable. Le premier travail réalisé en première année de Master fournissait ainsi, sans le savoir, la justification ontologique de la pratique que cette partie va analyser.

Il faut enfin préciser le statut de cette prémisse, qui est un pari méthodologique, et non une thèse métaphysique sur la nature des LLM. Kästner et Crook ne soutiennent pas que les LLM sont des organismes, mais seulement qu'on gagne à les étudier comme tels. Ils prennent d'ailleurs au sérieux une objection, selon laquelle nous pourrions manquer des concepts adéquats pour caractériser l'organisation fonctionnelle d'un LLM. Ils y répondent que la formation de concepts nouveaux appartient à l'activité ordinaire de la découverte scientifique, comme en témoigne l'histoire des sciences du vivant. Ce pari rejoint exactement la thèse mesurée que la première partie a dégagée à propos de l'opacité, car il revient à parier que l'opacité des LLM est contingente plutôt qu'essentielle, donc surmontable au bon niveau et avec les bons instruments. La troisième partie demandera ce que ce pari laisse de reste. Pour l'heure, il s'agit d'en exposer l'appareil et d'en mesurer la réussite.

2.2 Le cadre néo-mécaniste : expliquer le pourquoi par le comment

Le programme de la MI se réclame d'une tradition précise en philosophie des sciences, le néo-mécanisme, et c'est en explicitant cette tradition que l'on peut juger si la MI tient ses promesses explicatives. La formule qui la résume est due à Bechtel et Abrahamsen : expliquer pourquoi un phénomène se produit, c'est expliquer comment il se produit. Une explication par subsomption sous une loi se contente en effet de ranger un cas sous une régularité. L'explication mécaniste fait davantage, car elle ouvre la boîte noire causale qui relie la cause à l'effet, en révélant les entités, les activités et l'organisation qui transmettent l'influence causale à travers le système.

Le concept central est celui de mécanisme. Selon la formulation de Machamer, Darden et Craver, un mécanisme se compose d'entités et d'activités, organisées de telle sorte qu'elles produisent ou maintiennent un phénomène. Les entités sont les composants, définis par leurs propriétés, leur localisation et leur structure. Les activités sont les producteurs temporels du changement, c'est-à-dire ce que les entités font. L'organisation, enfin, désigne l'agencement spatial et temporel qui fait que ces activités, prises ensemble, produisent le phénomène visé.

Un exemple classique en donne l'intuition. Pour expliquer la circulation du sang, on nomme une entité, le cœur, une activité, le pompage, et une organisation, l'agencement des cavités et des valves qui oriente le flux. Aucun de ces trois éléments ne suffit seul, car c'est leur composition qui produit le phénomène. Un mécanisme n'est donc ni une simple collection de parties ni une simple suite d'événements, mais un ensemble structuré d'entités en activité, individué par le phénomène qu'il produit. Comme le souligne le texte «*Mechanistic Interpretability Needs Philosophy*»¹¹, les explications mécanistes ne se contentent pas de décrire des régularités, puisqu'elles montrent comment ces régularités émergent d'une structure causale. Elles sont, en ce sens, des théories de la transition d'un état à un autre.

Cette tradition fournit aussi une théorie de la découverte, et c'est elle qui rend l'appareil opératoire pour la MI. Bechtel et Richardson ont décrit deux heuristiques fondamentales, auxquelles on en adjoint ordinairement une troi-

¹¹Williams, Oldenburg, Dhar et al. (2025), «*Mechanistic Interpretability Needs Philosophy*» (arXiv :2506.18852). C'est à ce texte de position que renvoient toutes nos mentions ultérieures de ce titre.

sième. La première est la décomposition, par laquelle on divise le mécanisme en ses composants. Ces composants peuvent être structurels, définis par leurs propriétés physiques, ou fonctionnels, définis par leurs rôles et leurs contributions causales. La deuxième est la localisation, par laquelle on rattache les activités identifiées par la décomposition fonctionnelle aux composants identifiés par la décomposition structurelle. Localiser, c'est donc établir que telle partie accomplit telle fonction. La troisième est la recombinaison, par laquelle on remonte des composants vers le phénomène, en montrant comment leurs activités organisées le produisent. Ces trois opérations ne sont pas que des manières d'exposer une explication achevée, car elles sont les gestes mêmes par lesquels on la découvre. Nous verrons en 2.4 que les pratiques de la MI les reproduisent terme à terme.

Une dernière caractéristique du cadre mécaniste doit être notée, car elle commande la suite. Les mécanismes forment des hiérarchies à plusieurs niveaux. Les entités et activités d'un niveau servent en effet de composants pour le phénomène d'un niveau supérieur, et elles deviennent à leur tour des phénomènes à expliquer par un niveau inférieur. La pertinence d'un composant pour un phénomène, ce que Craver nomme la pertinence constitutive, n'est donc pas une relation de cause à effet entre deux événements distincts, mais une relation entre un tout et ses parties, qui s'établit en montrant que manipuler la partie modifie le phénomène, et réciproquement¹². Cette structure à niveaux est ce qui distingue l'explication mécaniste d'une simple explication causale, et elle recevra, en 2.4, une formalisation rigoureuse sous le nom d'abstraction causale.

On mesure alors en quoi ce cadre répond au déficit conceptuel diagnostiqué en 1.3. L'XAI classique produisait en effet des ingrédients dont le statut explicatif restait indéterminé, tandis que le néo-mécanisme fournit un critère : un compte rendu explique s'il identifie les entités et activités organisées qui produisent le phénomène. La question que les praticiens de la MI se posent eux-mêmes, qu'est-ce qui rend l'interprétabilité mécaniste mécaniste, reçoit dès lors une réponse précise. Le texte « Mechanistic Interpretability Needs Philosophy » la formule, à la suite de Kästner et Crook : la MI est mécaniste parce qu'elle aspire à expliquer les réseaux de neurones en termes de leurs méca-

¹²L'usage que nous faisons de l'intervention pour établir la pertinence d'un composant correspond au critère de manipulabilité mutuelle par lequel Craver (2007) définit la pertinence constitutive. Ce critère a fait l'objet de discussions (Baumgartner et Gebharder, 2016), qui portent toutefois sur des cas que notre usage ne rencontre pas.

nismes sous-jacents, au sens technique que cette tradition a fixé.

Ce cadre éclaire enfin pourquoi les approches comportementales et locales ne pouvaient suffire. Pour une tâche donnée, il existe en général un certain nombre d'algorithmes capables de la réaliser. Zhong et ses collègues en donnent une illustration frappante, puisqu'un même réseau peut résoudre une opération modulaire par des stratégies internes distinctes, l'une fondée sur une représentation en horloge, l'autre sur une représentation en pizza. La leçon est nette : la capacité d'un modèle à réaliser une certaine fonction d'entrée-sortie ne nous dit pas comment il la réalise. On reconnaît ici la réalisabilité multiple de notre M1, qui prend désormais une fonction argumentative précise, car elle est la raison pour laquelle le comportement ne détermine pas le mécanisme, et donc la raison pour laquelle une science du mécanisme, distincte d'une science du comportement, est requise. Le pari de la MI est qu'il existe un fait de l'affaire quant à l'algorithme effectivement implémenté, et que ce fait est accessible par les méthodes mécanistes.

2.3 L'interventionnisme : la cause comme ce qui change sous l'intervention

Le cadre mécaniste reste incomplet tant qu'on n'a pas dit comment établir qu'un composant est causalement responsable d'un phénomène, et non simplement corrélé avec lui. C'est l'apport de l'interventionnisme, dont la formulation de référence est due à Woodward.

Pour l'interventionnisme, les relations causales se comprennent en termes de ce qui changerait sous des interventions ou des manipulations portant sur les parties du système¹³. La définition se précise ainsi : une variable X est une cause directe d'une variable Y si et seulement s'il existe une intervention possible sur X qui modifie Y, ou la distribution de probabilité de Y, lorsque toutes les autres variables sont maintenues fixes. La relation est par ailleurs asymétrique, car si la flèche causale va de X vers Y, intervenir sur Y ne modifie pas X. L'interventionnisme écarte donc délibérément les notions de cause fondées sur la régularité ou la corrélation, et il reconnaît que le comportement d'un système dépend de davantage que l'observation de successions régulières d'événements. Appliquée à l'explication mécaniste, cette conception donne

¹³L'interventionnisme de Woodward (2003), que nous suivons, partage avec le calcul causal de Pearl (2009) le rôle central accordé aux interventions, et c'est sur ce socle commun que repose l'abstraction causale mobilisée par la MI. Nous ne discutons pas leurs divergences, qui ne pèsent pas sur notre propos.

une consigne claire : pour apprendre la contribution causale d'une partie d'un mécanisme postulé, il faut l'altérer pièce à pièce et observer l'effet.

Cette conception transforme directement le problème laissé ouvert en 1.3. La limite des méthodes locales y avait été identifiée comme un défaut d'adéquation causale, puisque l'attention, le gradient et les modèles de substitution repèrent des corrélations internes, alors qu'une corrélation n'est pas un rôle causal. L'interventionnisme indique précisément la voie de sortie. Comme le notent Millière et Buckner, les méthodes traditionnelles d'interprétation, telle la sonde, n'établissent que des relations corrélationnelles entre les représentations internes d'un modèle et les propriétés d'intérêt. Elles courent ainsi le risque de faux positifs, lorsque la sonde détecte une information qui n'est pas causalement pertinente pour le comportement. Les méthodes d'intervention causale procèdent autrement, car elles manipulent directement les représentations et observent l'effet sur la sortie. Si modifier l'information relative à une propriété change les prédictions de manière systématique, on tient alors une preuve que le modèle s'appuyait sur cette information. Le passage de l'observation à la manipulation est donc exactement le passage de la corrélation au rôle causal.

L'analogie avec les sciences du vivant est ici plus qu'illustrative, parce qu'elle indique le répertoire des méthodes. En neurosciences et en pharmacologie, on établit en effet le rôle causal d'un composant en intervenant sur lui. La pharmacologie cible des récepteurs ou des voies de signalisation. La stimulation cérébrale active ou inhibe des aires restreintes. L'optogénétique contrôle par la lumière des neurones génétiquement modifiés. Les modèles d'invalidation génétique suppriment enfin un gène hypothétiquement critique. Comme le soulignent Millière et Buckner, les dysanalogies entre des systèmes nerveux façonnés par des millions d'années d'évolution et des réseaux artificiels sont majeures, mais la motivation, elle, demeure identique. Il s'agit, dans les deux cas, d'atteindre une compréhension explicative en révélant des mécanismes à plusieurs niveaux, et non en observant des régularités d'entrée-sortie. La MI est donc l'analogie artificiel de cette démarche interventionniste, et nous verrons même en 2.4 que le contrôle qu'elle exerce sur son objet excède celui dont disposent les neurosciences.

Il convient toutefois de relever une subtilité conceptuelle, que l'honnêteté impose de signaler et que la troisième partie reprendra. Mécanisme et intervention ne sont pas synonymes. Certains philosophes admettent en effet qu'il puisse exister des explications causales et interventionnistes qui ne soient pas

mécanistes, parce qu'elles n'identifient pas un mécanisme au sens strict des entités et activités organisées ; c'est le cas de Woodward lui-même dans des travaux ultérieurs, ainsi que de Kaplan. Le texte « Mechanistic Interpretability Needs Philosophy » le reconnaît, puisqu'une part du débat tient à la largeur ou à l'étroitesse avec laquelle on définit le mécanisme. Pour l'heure, retenons que la MI combine les deux exigences, car elle vise des explications interventionnistes, donc causales, et mécanistes, donc structurées en entités, activités et organisation. Toutes ses productions satisfont-elles la seconde exigence autant que la première, ou certaines ne sont-elles que causales sans être pleinement mécanistes ? La question reste ouverte, et c'est l'une des fissures que la troisième partie explorera.

2.4 Les traductions concrètes : décomposer, intervenir, abstraire

Il reste à montrer que l'appareil exposé aux deux sections précédentes n'est pas plaqué de l'extérieur sur la pratique de la MI, mais qu'il en articule effectivement les gestes. Nous examinons à cette fin trois familles de techniques, qui correspondent terme à terme aux trois composantes de l'explication mécaniste : la décomposition fonctionnelle, l'intervention causale, et l'articulation des niveaux.

Décomposer : traits, circuits et dictionary learning

La MI cible ce que Marr appelait le niveau algorithmique. Elle cherche en effet à élucider le flux de l'information à travers le réseau et la suite des opérations qu'il subit, en faisant abstraction des détails d'implémentation. Ses deux unités d'analyse sont le trait et le circuit. Un trait, ou *feature*, est une propriété humainement interprétable des données d'entrée que le modèle encode dans ses représentations internes. Pour un modèle de vision, ce sera une texture ou une forme, et pour un modèle de langage, une catégorie grammaticale, une entité nommée ou une relation sémantique. Un circuit, quant à lui, est une chaîne d'opérations qui détecte certains traits d'entrée et les transforme en traits de sortie. L'objectif, dans sa forme idéale, est donc de décomposer le réseau entier en une hiérarchie de traits et de circuits intelligibles, qui traitent l'information pas à pas. Les têtes d'induction décrites par Olsson et ses collègues en fournissent l'exemple canonique, sur lequel nous reviendrons en détail : il s'agit de têtes d'attention qui émergent à l'entraînement, même dans de très petits trans-

formeurs, et qui implémentent une forme de complétion de motif susceptible d'expliquer une part de l'apprentissage en contexte.

Cette décomposition se heurte cependant à un obstacle qui en commande la forme, et qui ressurgira au premier plan dans la troisième partie, à savoir la superposition. Décrite par Elhage et ses collègues, la superposition désigne le fait qu'un réseau représente davantage de traits qu'il n'a de neurones ou de dimensions. Il est alors contraint d'encoder plusieurs traits dans des directions qui se recouvrent, et il en résulte des neurones polysémantiques, chacun participant à la représentation de plusieurs traits sans correspondre à aucun en propre. La conséquence est lourde pour la méthode, car l'unité structurelle la plus naturelle, le neurone individuel, ne porte pas de signification isolable, et la décomposition ne peut donc se lire directement sur les neurones. C'est ici qu'intervient le dictionary learning, mis en œuvre par des auto-encodeurs parcimonieux. L'idée, illustrée par les travaux de Bricken et ses collègues sur la monosémancticité, est de réexprimer les activations comme des combinaisons parcimonieuses de directions apprises. L'ensemble de ces directions forme un dictionnaire, dont chaque entrée vise à correspondre à un trait unique. Philosophiquement, le dictionary learning est une décomposition fonctionnelle au sens de Bechtel, puisqu'il identifie les composants fonctionnels, les traits, là où la décomposition structurelle en neurones échouait à les livrer. Il accomplit ainsi le premier geste mécaniste, en fournissant les entités dont les circuits décriront les activités organisées.

Ce geste de décomposition soulève une question philosophique que notre cadre dennettien permet de poser avec précision, et qui restera ouverte jusqu'à la troisième partie : les traits identifiés par le dictionary learning sont-ils découverts ou imposés ? La question n'est pas oiseuse, car l'auto-encodeur est lui-même entraîné, et un dictionnaire de taille différente, ou initialisé autrement, produit un découpage différent des mêmes activations. On peut donc craindre que les traits ne soient que des artefacts de la méthode, commodés mais arbitraires. C'est ici que le réalisme des patterns établi en 2.1, hérité de notre M1, accomplit un travail effectif. Si l'on tient, avec Dennett, qu'un pattern réel est une régularité objective qui mérite le statut de chose en vertu de son caractère ordonné et de son pouvoir prédictif, alors un trait est réel dans la mesure exacte où il capture une régularité que le réseau exploite effectivement, indépendamment de toute commodité descriptive. Le critère de réalité d'un trait n'est donc pas sa lisibilité, mais sa pertinence causale, ce qui renvoie la décision à l'intervention. Le dictionary learning, pris isolément, ne tranche

pas entre découverte et imposition, puisque c'est son couplage avec l'intervention qui confère à ses traits un titre de réalité. La troisième partie montrera que la superposition complique cette réponse, sans la ruiner.

Il faut, dès ce point, noter une fragilité que la troisième partie reprendra. Millière et Buckner avertissent en effet que cette approche peut créer une illusion de compréhension, en se raccrochant à des corrélations fortuites plutôt qu'à des relations causales authentiques. Les étiquettes que l'on attribue aux traits sont parfois générées par un autre modèle de langage, à partir d'un échantillon d'exemples fortement activateurs, de sorte qu'elles peuvent paraître sensées au premier regard et se révéler trompeuses à l'examen. La décomposition fonctionnelle, en MI comme dans les sciences du vivant, est donc une hypothèse à valider, et non une lecture directe de la structure. Or cette validation requiert l'intervention.

Intervenir : le patching de l'espace latent

Le deuxième geste mécaniste est la localisation du rôle causal d'un composant. Dans la MI, il s'opère par le patching de l'espace latent, qui est la mise en œuvre opératoire de l'intervention woodwardienne. Le principe se laisse exposer sur un exemple devenu classique. On soumet d'abord au modèle l'énoncé « la capitale de la France est », et il produit « Paris » ; on enregistre alors, ou met en cache, les activations de ce passage. On soumet ensuite l'énoncé « la capitale de l'Allemagne est », et il produit « Berlin ». On effectue enfin un troisième passage, sur l'énoncé allemand, mais en remplaçant, ou en patchant, les activations d'un composant déterminé par celles qui avaient été enregistrées lors du passage français. Si cette substitution suffit à faire produire « Paris » au modèle interrogé sur l'Allemagne, on tient alors la preuve que ce composant encode une information causalement impliquée dans le comportement cible.

La structure de cette procédure est exactement celle de l'intervention de Woodward, puisqu'on altère pièce à pièce une partie du système, on maintient le reste fixe, et l'on observe l'effet sur la sortie. Elle est aussi l'analogue artificiel du modèle d'invalidation et de l'optogénétique évoqués en 2.3, à une différence près qui joue cette fois en faveur de la MI : le degré de contrôle que l'on exerce sur un réseau artificiel excède celui dont disposent les neurosciences. On peut en effet non seulement supprimer ou activer un composant, mais aussi éditer des représentations distribuées avec précision. La projection itérative dans l'espace nul de Ravfogel et ses collègues en est un exemple, car elle retire d'une représentation l'information détectée par une sonde, puis vé-

rifie l'effet de ce retrait sur le comportement, ce qui distingue l'information causalement pertinente de l'information seulement présente. Un point mérite enfin d'être souligné, parce que ce dernier noue les deux premiers gestes. Les composants sur lesquels on intervient ne sont en général pas des neurones individuels, mais des directions ou des patterns dans l'espace d'activation, c'est-à-dire précisément les traits que la décomposition par dictionary learning a identifiés. Décomposition et intervention ne sont donc pas deux pratiques séparées, puisque la seconde valide les hypothèses fonctionnelles de la première en leur conférant un statut causal.

Cette puissance d'intervention a toutefois une contrepartie qu'il faut nommer, car elle nuance l'analogie woodwardienne. L'intervention idéale, chez Woodward, est chirurgicale, en ceci qu'elle modifie la variable cible sans perturber le reste du système par d'autres voies. Or le patching insère, dans un passage donné, des activations produites par un autre passage, donc dans un contexte pour lequel elles n'avaient pas été calculées. Rien ne garantit dès lors que l'état ainsi composé appartienne au régime de fonctionnement normal du modèle, et il peut au contraire le placer hors de la distribution sur laquelle il a été entraîné. L'effet observé risque alors de refléter le comportement du réseau sous une manipulation anormale, plutôt que le mécanisme qu'il déploie en conditions ordinaires, ce que la littérature appelle des illusions d'interprétabilité. La difficulté n'invalide pas la méthode, mais elle impose une prudence, car une intervention n'éclaire le mécanisme normal que si l'on contrôle qu'elle ne fabrique pas l'effet qu'elle prétend révéler, par exemple en vérifiant que des interventions de contrôle sur des composants non pertinents demeurent sans effet. Elle rappelle aussi que la transposition de l'interventionnisme du vivant à l'artificiel ne se fait pas sans reste, point que la troisième partie reprendra.

Abstraire : l'abstraction causale comme lien entre les niveaux

Le troisième geste est la recomposition, soit l'articulation des niveaux. Il reçoit dans la MI une formalisation rigoureuse avec le cadre de l'abstraction causale développé par Geiger et ses collègues. Ce cadre fournit en effet l'instrument qui manquait pour relier deux niveaux : celui de l'implémentation, le réseau, et celui de la fonction, l'algorithme abstrait que l'on hypothétise.

L'intuition est la suivante. On dispose d'un modèle causal de bas niveau, le réseau de neurones, avec ses nœuds et ses poids. On dispose aussi d'un modèle causal de haut niveau, l'algorithme abstrait que les chercheurs proposent comme description de ce que le réseau calcule. Une mise en correspondance,

ou alignement, partitionne alors les variables de bas niveau en ensembles, chacun aligné sur une variable de haut niveau, tandis qu'une fonction de traduction fait correspondre les valeurs des unes à celles des autres. L'alignement est dit causalement consistant lorsqu'une condition est remplie : pour toute intervention de bas niveau à laquelle correspond une intervention de haut niveau sous la fonction de traduction, intervenir sur les deux modèles produit, après traduction, des résultats équivalents. Lorsque cette condition est satisfaite, le modèle de haut niveau est dit abstraction causale constructive du modèle de bas niveau. La consistance causale garantit alors que le modèle de haut niveau capture fidèlement les mécanismes causaux du réseau, et non une simple re-description commode.

Un exemple éclaire cette définition abstraite, et l'on peut reprendre celui du patching. Supposons que l'algorithme de haut niveau soit le suivant : repérer le pays mentionné, puis produire sa capitale. L'alignement associe alors la variable de haut niveau « pays repéré » à un ensemble de directions de l'espace d'activation du réseau. Pour tester la consistance, on intervient. On remplace, dans le réseau, ces directions par celles qu'aurait produites un autre pays, et l'on vérifie que la sortie change comme le prédit l'algorithme de haut niveau lorsqu'on y substitue ce pays. Si les deux concordent sur un éventail d'interventions de ce genre, alors l'alignement est consistant, et l'algorithme abstrait mérite le titre d'abstraction causale du réseau.

La méthode d'évaluation de cette consistance mérite d'être détaillée, car elle unifie les techniques précédentes. On la nomme intervention par échange, ou *interchange intervention*. Elle consiste à échanger les représentations neuronales créées pour une entrée avec celles créées pour une autre, puis à vérifier si le réseau et l'algorithme de haut niveau se comportent de manière équivalente sous ces échanges alignés. Le patching d'activation décrit plus haut est d'ailleurs une espèce d'intervention par échange, et la projection dans l'espace nul peut elle aussi se formuler dans ce cadre. L'abstraction causale fournit ainsi la grammaire commune des méthodes interventionnistes de la MI. Pour des modèles aussi vastes que les LLM, on ne vise toutefois pas une abstraction exacte, mais une abstraction causale approchée, dont la formulation revient à Beckers et Halpern (2019) et la métrique d'erreur à Beckers, Halpern et Woodward (2020). Son degré se quantifie par la proportion d'interventions par échange alignées qui produisent des effets équivalents aux deux niveaux, et lorsque cette proportion atteint la totalité, le modèle de haut niveau abstrait exactement le réseau.

L'importance philosophique de ce cadre est qu'il donne un contenu rigoureux à la structure à niveaux du mécanisme exposée en 2.2. La pertinence constitutive de Craver, on l'a vu, est cette relation entre un tout et ses parties qui s'établit en montrant que manipuler la partie modifie le phénomène. Or l'abstraction causale en fournit la formalisation, car l'alignement causalement consistant est la version formelle de la relation entre le niveau fonctionnel et le niveau d'implémentation. C'est donc ce qui convertit une collection de techniques d'intervention en un programme mécaniste doté de niveaux, capable de remonter des composants vers le phénomène. L'abstraction causale accomplit ainsi, dans le registre formel, le troisième geste de la découverte mécaniste, la recomposition.

Une étude de cas intégrée : les têtes d'induction

Pour donner corps à l'articulation de ces trois gestes, considérons un exemple où ils opèrent ensemble, le circuit des têtes d'induction, déjà évoqué, qui constitue l'une des réussites les mieux établies de la MI. Le phénomène à expliquer est une capacité comportementale. Présenté avec une séquence où un motif se répète, un transformeur tend à compléter la répétition : ayant rencontré la suite «A B» plus tôt dans le contexte, il accroît la probabilité de «B» après une nouvelle occurrence de «A». Cette capacité participe de l'apprentissage en contexte, par lequel les LLM généralisent à partir d'exemples présents dans l'invite, sans modification de leurs poids.

La décomposition fonctionnelle identifie d'abord les composants responsables. On découvre que ce comportement est porté par un circuit réparti sur deux couches. Une première tête d'attention, dite tête de token précédent, inscrit dans la représentation de chaque token l'information du token qui le précède. Une seconde, la tête d'induction proprement dite, exploite ensuite cette inscription, car elle repère dans le contexte antérieur une occurrence du token courant, puis porte l'attention sur le token qui l'avait alors suivi, afin d'en accroître la probabilité. Aucune tête isolée n'accomplit à elle seule cette opération d'appariement puis de copie, puisqu'elle requiert la composition des deux. Cette description est déjà mécaniste au sens de Machamer, Darden et Craver, car elle nomme des entités, les têtes concernées, et leurs activités, l'appariement de préfixe et la copie, organisées en une séquence qui produit le phénomène. La localisation, ensuite, rattache ces activités à des composants déterminés, des têtes situées à des couches identifiables, dont l'activité conjointe à travers les couches réalise la fonction.

Encadré — Le circuit des têtes d'induction

Présenté avec le motif « A B ... A », le modèle apprend à prédire « B ». Le travail se répartit entre deux têtes d'attention, que le schéma résume.




Schéma du circuit pour le motif « A B ... A ». (1) La tête de token précédent relie chaque token à son prédécesseur (B retient A). (2) La tête d'induction, au second A, repère le token qui suivait le premier A et le recopie en sortie.

Ce petit circuit est exemplaire à deux titres. C'est, d'abord, le mécanisme tenu pour responsable de l'apprentissage en contexte. C'est, ensuite, l'illustration la plus nette des trois temps de la MI : *décomposer* le calcul en têtes, *localiser* la fonction sur des composants précis, puis *valider* ce rôle par l'intervention plutôt que par la seule lecture des poids.

La validation, enfin, passe par l'intervention. On n'admet pas que ces têtes implémentent l'induction sur la seule foi de leur profil d'attention, qui ne serait qu'une corrélation au sens de 1.3. On le démontre plutôt en intervenant, par ablation des têtes candidates et par patching, et en vérifiant que la capacité d'induction décline ou se restaure en conséquence. L'ensemble se laisse alors reformuler comme une abstraction causale, car l'algorithme de haut niveau, apparier puis copier, est aligné sur un ensemble de composants de bas niveau, et la consistance de cet alignement s'éprouve par des interventions par échange. On dispose ainsi d'un cas complet, où la décomposition fournit les entités, la localisation et les circuits les activités organisées, l'intervention la pertinence causale, et l'abstraction l'articulation des niveaux, soit l'explication mécaniste d'une capacité cognitive d'un LLM. Il faut toutefois relever une asymétrie que la section suivante exploitera. La preuve proprement causale de ce circuit est en effet forte pour de petits modèles à attention seule, mais elle devient seulement corrélationnelle pour les grands modèles munis de couches non linéaires¹⁴. Que la démonstration la plus nette porte sur un mécanisme

¹⁴Les principales références techniques de cette partie sont, pour les têtes d'induction, Olson et al. (2022), qui établissent que le circuit se compose d'une tête de token précédent et d'une tête d'induction, et qui n'apportent une preuve proprement causale que pour de petits modèles à attention seule, la preuve restant corrélationnelle pour les grands modèles munis de

relativement simple et sur des modèles de petite taille n'est donc pas un détail.

2.5 Le statut des explications de la MI : l'esquisse de mécanisme

L'affirmation que la MI produit des explications authentiquement mécanistes doit maintenant être qualifiée, faute de quoi elle resterait exposée à un soupçon de complaisance. Toutes les explications mécanistes ne se valent pas, et la tradition néo-mécaniste distingue précisément les explications complètes des explications incomplètes. Une distinction de Piccinini et Craver fixe ce point. À un pôle se tient le modèle mécaniste idéalement complet, qui spécifie toutes les entités, activités et relations d'organisation pertinentes. À l'autre se tient l'esquisse de mécanisme, qui omet intentionnellement certains aspects structurels, en laissant des parties du mécanisme caractérisées par leur seul rôle fonctionnel, en attente d'une spécification ultérieure.¹⁵

Où situer les explications de la MI sur cet axe ? Rabiza soutient, et nous le suivons, que les réseaux profonds appellent une analyse fonctionnelle du type de l'esquisse de mécanisme. La raison en est que leurs propriétés fonctionnelles, leurs entrées, leurs sorties et leur algorithme se spécifient pour une large part indépendamment de leur implémentation physique, suivant une caractéristique que Piccinini et Craver reconnaissent aux boîtes noires fonctionnelles. La MI n'a donc pas besoin, dans la plupart des contextes, de descendre

couches non linéaires ; pour la superposition, Elhage et al. (2022) ; pour le dictionary learning, Bricken et al. (2023) ; pour les détecteurs de courbes, Cammarata et al. (2021) ; pour l'abstraction causale, Geiger et al. (2021), prolongé par Geiger et al. (2023, 2024) ; pour l'exemple « horloge et pizza », Zhong et al. (2023). Le cadre néo-mécaniste s'appuie sur Machamer, Darden et Craver (2000), Bechtel et Abrahamsen (2005), Bechtel et Richardson (1993) et Craver (2007), *Explaining the Brain* (Oxford University Press), où la distinction de l'esquisse et du schéma de mécanisme est posée p. 113-114 et la pertinence constitutive comme manipulabilité mutuelle développée p. 140-160 ; la notion d'esquisse de mécanisme, sur Piccinini et Craver (2011), pour qui une analyse fonctionnelle est une esquisse de mécanisme dont la complétion donne une explication mécaniste pleine ; la contrainte de correspondance entre modèle et mécanisme, sur Kaplan et Craver (2011), et les normes de complétude, sur Craver et Kaplan (2020). L'interventionnisme renvoie à Woodward (2003), *Making Things Happen* (Oxford University Press), qui caractérise l'intervention au chapitre 3, p. 94-114. Plusieurs de ces sources techniques nous ont d'abord été connues par leurs reprises philosophiques (Millière et Buckner ; Rabiza, « A Mechanistic Explanatory Strategy for XAI », preprint 2024, arXiv :2411.01332, chapitre à paraître chez Springer en 2026 ; et « Mechanistic Interpretability Needs Philosophy »), dont les références primaires ont été vérifiées.

¹⁵Piccinini, G. et Craver, C. (2011), « Integrating Psychology and Neuroscience : Functional Analyses as Mechanism Sketches », *Synthese*, 183(3), 283-311. Nous traduisons « mechanism sketch » par esquisse de mécanisme. Le terme est défini p. 284, et l'idée qu'une esquisse est une explication mécaniste incomplète, laissant des places à remplir, est développée p. 292.

au niveau du paramètre ou du substrat physique pour rendre compte d'une capacité. Kästner et Crook le concèdent d'ailleurs lorsqu'ils notent qu'un modèle n'a pas à être expliqué exhaustivement jusqu'au paramètre pour produire des bénéfices. Une explication par traits et circuits est donc une esquisse au sens technique, car elle caractérise des composants par leur rôle fonctionnel sans en fixer toute la réalisation structurelle.

Ce statut d'esquisse n'est pas un défaut, et il importe de ne pas le lire comme une concession qui ruinerait la thèse. Craver et Kaplan ont en effet montré qu'une explication mécaniste peut être suffisante pour ses fins sans être complète, et la diversité des desiderata pour lesquels la MI est mobilisée, le contrôle, la prédiction, la détection de comportements indésirables, interdit de fixer un seuil unique de complétude requise. Une esquisse adéquate demeure donc une explication mécaniste, distincte d'une simple redescription. Elle satisfait ce que Craver nomme la contrainte de correspondance entre le modèle et le mécanisme, en ceci que ses variables renvoient à des composants réels du système, et ses dépendances à des relations causales réelles, établies par intervention. C'est précisément ce qui sépare une esquisse de mécanisme d'une fiction comode.

Reste que la qualification a un coût, qu'il faut inscrire au passif, et deux conséquences doivent être relevées. D'abord, le caractère d'esquisse rouvre la question de l'unicité. Là où plusieurs esquisses, découpant différemment le même réseau, satisfont également la contrainte de correspondance, rien n'impose en effet d'en préférer une, et la troisième partie y verra un argument pour le pluralisme explicatif. Ensuite, l'écart d'échelle ne peut être passé sous silence. Les réussites mécanistes les mieux établies portent en effet sur des modèles minuscules au regard des systèmes déployés : une famille de dix neurones détecteurs de courbes dans un réseau de vision, un transformeur à une seule couche, quand les modèles de production comptent des dizaines de couches et des centaines de milliards de paramètres. Que l'on sache produire des esquisses de mécanisme pour des modèles jouets ne garantit donc pas que la même décomposition soit praticable, ni même bien définie, à l'échelle réelle. Savoir si une esquisse obtenue sur un modèle de production explique comment le modèle fait effectivement, ou seulement comment il pourrait faire, revient alors à séparer ce que la philosophie des sciences nomme l'explication du comment-effectif de l'explication du comment-possible. C'est une question que la troisième partie devra affronter.

2.6 Bilan : la MI produit des explications authentiquement mécanistes

Les trois familles de techniques que nous venons d'analyser instancient terme à terme les trois composantes de l'explication mécaniste. Le dictionary learning fournit en effet les entités fonctionnelles, les traits, là où la décomposition structurelle en neurones échouait du fait de la superposition. Les circuits, dont les têtes d'induction sont l'exemple, décrivent les activités organisées qui relient ces traits. Le patching de l'espace latent établit ensuite, par intervention au sens de Woodward, la pertinence causale de ces composants, en distinguant ce qui est causalement impliqué de ce qui est seulement corrélé. L'abstraction causale, enfin, articule le niveau de l'implémentation et le niveau de la fonction, et confère à la structure à niveaux du mécanisme un critère opératoire de fidélité. La MI satisfait donc les exigences que Craver et Bechtel posent à une explication mécaniste, puisqu'elle identifie des entités et des activités, organisées pour produire le phénomène, et qu'elle établit cette organisation par la manipulation plutôt que par l'observation. La réponse à la question qu'est-ce qui rend la MI mécaniste n'est dès lors plus un postulat, mais un résultat : la MI est mécaniste parce que ses pratiques réalisent, sur un objet artificiel, les gestes mêmes par lesquels les sciences du vivant découvrent et valident leurs mécanismes.

On pourrait objecter que ce résultat est acquis trop facilement. Il aurait suffi, dirait l'objection, de décrire les pratiques de la MI dans le vocabulaire mécaniste, puis de constater qu'elles s'y conforment. L'objection de circularité doit être prise au sérieux, et elle peut être levée en distinguant la redescription de l'explication. Redécrire ce que fait un LLM comme une prédiction du token suivant, ou comme une multiplication de matrices, ne règle en effet aucune question d'organisation causale, et Millière et Buckner nomment cette confusion le sophisme de la redescription¹⁶. Une explication mécaniste se distingue donc d'une redescription par ce qu'elle permet de faire, et c'est à ce gain qu'il faut mesurer son authenticité. Une explication par entités, activités et organisation, validée par intervention, soutient en effet des inférences contrefactuelles, car elle dit comment la sortie aurait changé si tel composant avait été altéré, ce

¹⁶Nous traduisons; les auteurs parlent de « Redescription Fallacy » (Millière et Buckner, 2024, « A Philosophical Introduction to Language Models. Part I : Continuity with Classic Debates », arXiv :2401.03910, p. 9). Nous rendons « fallacy » par sophisme plutôt que par sophistique, car le terme désigne un schéma d'inférence fallacieux déterminé, et non une pratique argumentative.

qu'aucune redescription ni aucune carte de saillance locale ne permet. Dans le vocabulaire des vertus introduit en première partie, elle gagne ainsi en profondeur, c'est-à-dire en nombre et en qualité de questions contrefactuelles auxquelles elle répond, et en adéquation causale. Surtout, elle confère une capacité de prédiction et de contrôle hors des contextes prédéfinis, que Kästner et Crook désignent comme le bénéfice propre de la MI, car connaissant le mécanisme, on anticipe le comportement du système sur des entrées nouvelles, et l'on intervient sur lui de façon ciblée. C'est donc ce pouvoir, et non la conformité verbale au cadre mécaniste, qui atteste que les explications de la MI sont authentiquement mécanistes.

Il faut toutefois affronter une objection plus directe, venue cette fois de l'intérieur du champ, et que l'on aurait tort de passer sous silence. Plusieurs chercheurs doutent en effet que ce résultat se maintienne. Les uns observent que les circuits clairement établis le sont surtout à petite échelle, sans qu'aucune garantie assure leur tenue dans les modèles déployés. D'autres soupçonnent que les traits livrés par les auto-encodeurs ne soient pas tous causalement exploités par le réseau, mais en partie fabriqués par la méthode. D'autres encore, à la suite des illusions de patching rencontrées en 2.4, tiennent ces illusions pour une menace plus profonde qu'une simple précaution, puisqu'elles entament la validation causale elle-même. Ces réserves sont sérieuses, et la troisième partie les reprendra. Elles invitent surtout à préciser la portée du mot « authentique ». Nous n'affirmons pas que les explications de la MI soient complètes, ni qu'elles procurent à coup sûr la compréhension, ni qu'elles soient déjà établies à l'échelle des plus grands modèles. Nous affirmons seulement qu'elles sont mécanistes par leur forme et par leur méthode, c'est-à-dire qu'elles identifient des entités et des activités organisées, et qu'elles les valident par l'intervention plutôt que par la seule observation. C'est en ce sens précis et délibérément borné que nous les disons authentiques.

La première moitié de notre thèse générale est ainsi établie. L'interprétabilité mécaniste produit des explications authentiquement mécanistes au sens philosophique du terme, et le pari méthodologique de la prémisse organique se trouve, dans cette mesure, payé. Le problème de l'opacité diagnostiqué en première partie reçoit donc un commencement de réponse. Il existe en effet un niveau de description, celui des traits et des circuits, et un équipement, celui des auto-encodeurs et des interventions, auxquels l'organisation fonctionnelle d'un LLM devient intelligible. La thèse mesurée de la première partie, selon laquelle l'opacité des LLM est peut-être contingente plutôt qu'essentielle, reçoit

ainsi son premier appui empirique et conceptuel.

Une réserve d'une autre nature doit cependant tempérer ce constat, car elle touche à ce que la première partie avait posé comme le cœur du problème, l'intelligibilité. Produire une explication mécaniste et procurer une compréhension ne sont pas une seule et même chose. L'explication est un objet, à savoir le mécanisme reconstruit, tandis que la compréhension est un accomplissement cognitif d'un agent, qui suppose que l'explication lui soit intelligible. La distinction est classique en épistémologie de la compréhension. Baumberger, Beisbart et Brun rappellent en effet qu'on y oppose la compréhension explicative, attachée à un pourquoi particulier, et la compréhension objectuelle, qui porte sur un domaine entier. De Regt, pour sa part, fait de l'intelligibilité la condition de la compréhension, car il l'entend comme la valeur attachée aux qualités d'une représentation qui en facilitent l'usage, et il souligne que cette intelligibilité varie selon les contextes et les communautés¹⁷. Il s'ensuit qu'une esquisse mécaniste exacte peut demeurer en deçà de la compréhension, si elle n'est pas saisissable par celui à qui elle s'adresse. On retrouve ici la relativité aux destinataires établie en 1.2, ainsi que le constat de Dorsch et Moll selon lequel les sorties de certaines méthodes restent épistémiquement opaques aux non-experts. La compréhension impose donc à la MI une exigence supplémentaire, distincte de l'adéquation causale, car ses diagrammes et ses étiquettes de traits doivent non seulement correspondre à des mécanismes réels, mais aussi pouvoir être appropriés par un esprit humain situé.

Sullivan ajoute à cela une mise en garde que nous retiendrons pour la conclusion. Lorsqu'on cherche à comprendre, par le truchement d'un modèle, un phénomène qui lui est extérieur, ce qui fait obstacle à la compréhension n'est pas tant l'opacité du modèle que ce qu'elle nomme l'incertitude de lien, soit le défaut de preuves reliant le modèle à sa cible. Notre objet est un peu différent, puisque la cible est ici le modèle lui-même. La remarque se transpose néanmoins, car une explication de circuit ne devient compréhension d'une capacité qu'à une condition, celle d'établir par des preuves que le circuit isolé sur de petits cas gouverne effectivement cette capacité dans les conditions réelles d'emploi. On retrouve ainsi, sous un autre nom, l'écart entre comment-possible et comment-effectif relevé en 2.5, ainsi que le risque d'illusion de

¹⁷Sur la distinction entre compréhension explicative et compréhension objectuelle, voir Baumberger, Beisbart et Brun (2017, p. 1-34) ; sur l'intelligibilité comme condition contextuelle de la compréhension et son critère CIT, de Regt (2017, p. 40 et 102) ; sur l'incertitude de lien (« link uncertainty », nous traduisons), Sullivan (2022, p. 110 et 112). Nous développerons ces ressources dans la conclusion.

compréhension relevé en 2.4. La compréhension, plus encore que l'explication, reste donc un objectif à conquérir, et la mesure dans laquelle la MI l'atteint sera l'une des questions de notre conclusion.

Cette réussite a par ailleurs été obtenue, et il faut le dire pour ne pas la surestimer, au prix de deux mouvements dont la troisième partie éprouvera la solidité. Le premier est le pari de la prémisses organique lui-même, dont nous avons rappelé le statut, à savoir une hypothèse de travail et non une vérité acquise. Le second est plus interne, et plusieurs fissures en sont déjà apparues au fil de cette partie. La superposition a d'abord montré que l'unité d'analyse la plus naturelle, le neurone, ne se cartographie pas sur les composants fonctionnels, de sorte qu'il faut reconstruire les entités plutôt que les lire, sans qu'aucune garantie assure l'unicité de la reconstruction. Le risque d'illusion de compréhension a ensuite montré que la décomposition fonctionnelle est une hypothèse faillible, exposée à se raccrocher à des corrélations fortuites. Le cadre de l'abstraction causale, enfin, par son recours à l'abstraction approchée et par la pluralité des algorithmes de haut niveau qu'il autorise, suggère une possibilité dérangeante : il n'existe peut-être pas un mécanisme unique à découvrir, mais plusieurs décompositions également légitimes selon les fins de l'enquête. Le texte « *Mechanistic Interpretability Needs Philosophy* » va d'ailleurs dans ce sens, puisqu'il soutient qu'aucun niveau ne détient à lui seul la vérité mécaniste, et que les décompositions sont des outils explicatifs façonnés par les buts de l'enquête, à évaluer par leur fécondité plutôt que par leur fidélité à une structure réelle supposée singulière.

Ces fissures ne constituent pas des réfutations, car elles marquent les points où le LLM, en tant qu'objet d'un type nouveau, commence à exercer une pression sur les catégories classiques de l'explication mécaniste. C'est cette pression que la troisième partie prend pour objet. Si la MI réussit, comme nous venons de le soutenir, sa réussite même révèle alors quelque chose : les catégories de Craver et de Bechtel, forgées pour des systèmes dont l'organisation procède de l'évolution ou de la conception délibérée, doivent être enrichies pour rendre compte d'un système dont l'organisation fonctionnelle a émergé de l'entraînement. Telle est la seconde moitié de notre thèse, et l'objet du mouvement qui suit.

Les limites de l'analogie : ce que les LLM font à l'explication mécaniste

La deuxième partie a établi la première moitié de notre thèse. L'interprétabilité mécaniste produit des explications authentiquement mécanistes, au sens de Craver et de Bechtel, et le pari de la prémisse organique se trouve, dans cette mesure, payé. Mais elle s'est refermée sur trois fissures : la superposition, qui défait l'alignement entre la structure et la fonction ; le fossé entre la fonction que nous attribuons à un modèle et celle que son mécanisme réalise ; et la pluralité des décompositions également adéquates d'un même réseau. Cette troisième partie prend ces fissures pour objet. Elle vise la seconde moitié de notre thèse : la réussite même de la MI révèle que les catégories classiques de l'explication mécaniste doivent être enrichies pour rendre compte d'un système dont l'organisation fonctionnelle a émergé de l'entraînement.

Une précision s'impose d'emblée, car cette thèse pourrait sembler contredire celle de la partie précédente. Si les catégories classiques doivent être enrichies, en quel sens les explications de la MI étaient-elles classiquement mécanistes ? La réponse tient à une distinction qu'il faut poser dès maintenant, entre la forme d'une explication et le contenu des catégories qui la sous-tendent. La deuxième partie a montré que les explications de la MI sont mécanistes par leur forme, puisqu'elles identifient des entités et des activités organisées, et qu'elles les valident par l'intervention. La présente partie ne revient pas sur ce point. Ce qu'elle met en cause n'est pas la forme mécaniste de ces explications, mais le contenu de trois catégories que cette forme mobilise sans les interroger : l'ontologie des composants, la manière dont la fonction est individuée, et la fixation du phénomène à expliquer. L'enrichissement que nous proposons porte donc sur ces catégories, et non sur la forme de l'explication. C'est pourquoi il prolonge la deuxième partie au lieu de la défaire.

La méthode que nous suivrons interdit de traiter les trois fissures comme une liste de griefs. Nous les rapportons à une racine unique. La section 3.1 dé-

gage cette racine de façon analytique, sous la forme d'un troisième mode de genèse de l'organisation fonctionnelle, puis laisse ce constat retrouver de lui-même l'appareil dennettien mobilisé dès la première partie. Les sections suivantes déploient les trois fissures dans cet ordre : la superposition et l'ontologie des composants (3.2), le pluralisme et l'hypothèse de l'unique décomposition (3.3), l'indifférence mécanique et le fossé fonctionnel (3.4). La section 3.5 propose alors un gain constructif, et la section 3.6 répond aux objections.

Deux registres seront maintenus distincts tout au long de la partie, et il importe de l'annoncer. Le premier rassemble une série d'enrichissements locaux, un par fissure, chacun défendable pour lui-même. Le second propose une unification plus ambitieuse de ces enrichissements sous un concept unique. Nous marquerons ce second registre comme plus spéculatif au moment de l'introduire, en 3.5. Le lecteur qui refuse l'unification conserve les enrichissements, tandis que celui qui l'accorde reçoit, en outre, le fil qui les noue.

3.1 Un troisième mode de genèse : l'entraînement

Ce que l'évolution et la conception fournissent au cadre mécaniste

Le cadre néo-mécaniste exposé en deuxième partie a été forgé pour deux familles de systèmes, les organismes et les artefacts. Cette origine n'est pas anodine, car le cadre s'appuie tacitement sur le mode de genèse de son objet, sans toujours le thématiser. Pour le voir, il faut d'abord caractériser ces deux modes, puis dégager ce que chacun procure au mécaniste.

Le premier mode est l'évolution. L'organisation fonctionnelle d'un organisme résulte de la sélection naturelle, et la philosophie de la biologie en rend compte par la notion de fonction étiologique : la fonction d'un trait est l'effet pour lequel il a été sélectionné. Le cœur a pour fonction de pomper le sang parce que c'est en pompant le sang que les cœurs ancestraux ont contribué à la survie de leurs porteurs. Le second mode est la conception. L'organisation fonctionnelle d'un artefact résulte de l'intention d'un concepteur, et la fonction d'une pièce est le rôle que ce concepteur lui a assigné. Un rouage d'horloge a pour fonction de transmettre un mouvement parce que l'horloger l'a agencé pour cela.

Ces deux modes diffèrent par bien des traits, mais ils ont en commun de fournir au cadre mécaniste trois appuis, dont le mécaniste se sert sans toujours les nommer. Le premier est un critère d'individuation des composants : un élé-

ment du système compte comme une partie faisant un travail, parce qu'il a été sélectionné pour ce travail ou conçu pour lui. Le deuxième est la fixation de l'explanandum : le phénomène que le mécanisme est censé produire, sa fonction, est donné par la sélection ou par l'intention, et le mécanisme s'analyse alors comme l'implémentation de cette fonction. Le troisième est l'assurance qu'il existe une organisation fonctionnelle déterminée à découvrir, fût-elle multi-niveaux. Le mécaniste qui examine un organisme ou un artefact sait que les fonctions de ses parties sont objectivement déterminées, puisque elles ont été établies par le processus de genèse du système, l'histoire évolutive ou le plan du concepteur.

Ces trois appuis ne sont pas extérieurs au cadre, car ils le portent. Le critère d'individuation rend possible la décomposition. La fixation de l'explanandum rend possible la localisation, qui rapporte une activité à une fonction donnée. L'assurance d'une organisation déterminée rend légitime le pari qu'une recomposition fidèle existe. Toute la deuxième partie présupposait ces appuis. Nous devons à présent montrer que l'entraînement, en tant que troisième mode de genèse, prive le cadre mécaniste de ces trois appuis.

L'entraînement, ou la genèse qui ne fournit rien de tout cela

L'organisation fonctionnelle d'un LLM ne provient ni de l'évolution ni de la conception. Elle provient de l'entraînement : une procédure d'optimisation, la descente de gradient, ajuste des milliards de paramètres pour minimiser une fonction de perte sur une distribution de données¹⁸. Ce troisième mode se distingue précisément des deux autres par ce qu'il ne fournit pas.

Il ne fournit pas de critère d'individuation des composants. Aucun concepteur n'a assigné une fonction à une partie, et la sélection ne s'est pas exercée sur des organes, mais sur des paramètres. Les composants fonctionnels ne sont donc pas donnés, et ils doivent être reconstruits après coup, sans qu'aucune garantie assure qu'ils coïncident avec les unités structurelles que sont les neurones. C'est ce manque que la superposition rendra tangible en 3.2.

Il ne fournit pas non plus la fixation de l'explanandum. L'optimisation ne vise pas la fonction que nous attribuons au modèle, comprendre, raisonner, ju-

¹⁸Nous traitons l'entraînement comme un mode de genèse unique, alors qu'il se compose au moins d'un pré-entraînement et d'un post-entraînement, dont les objectifs substitutifs diffèrent. Notre argument ne dépend pas de cette distinction, puisqu'il tient à la structure d'optimisation d'un proxy, commune aux deux phases. Une analyse plus fine la prendrait toutefois en compte, et l'on en voit un indice dans le déplacement des activations au post-entraînement que relève l'étude sur les émotions fonctionnelles citée plus loin.

ger, mais la réduction d'une perte sur un objectif substitutif, le *proxy*. La fonction que le mécanisme réalise effectivement est par conséquent celle qui réduit la perte, et rien n'oblige cette fonction à coïncider avec celle que nous attribuons. C'est ce manque que l'indifférence mécanique rendra tangible en 3.4.

Il ne fournit pas, enfin, l'assurance d'une organisation fonctionnelle déterminée. L'entraînement n'impose aucune architecture modulaire lisible, aucune raison de préférer un découpage à un autre. Là où l'évolution a laissé des niveaux imbriqués que la biologie sait articuler, l'entraînement laisse des décompositions qui peuvent se recouper sans s'emboîter, et dont aucune n'est privilégiée par la genèse. C'est ce manque que le pluralisme rendra tangible en 3.3.

Le diagnostic analytique est ainsi le suivant. Les trois fissures que la deuxième partie a entrouvertes ne sont pas trois accidents indépendants, mais les trois symptômes d'un même fait : l'entraînement est un mode de genèse que la philosophie du mécanisme n'a pas théorisé, et qui prive le cadre des trois appuis sur lesquels il reposait. Chaque appui manquant prédétermine une fissure, et c'est pourquoi nous les examinerons dans cet ordre.

Du constat analytique à Dennett : un dessein sans concepteur

Jusqu'ici, nous avons parlé d'évolution, de conception et d'entraînement comme de trois faits externes touchant l'origine des systèmes. Néanmoins, dès que l'on demande quelle sorte de chose est une fonction sélectionnée par l'entraînement, l'idiome neutre de la théorie des fonctions se révèle insuffisant, et un vocabulaire que ce constat laissait implicite s'impose. C'est ici que nous retrouvons Dennett, déjà mobilisé en première partie pour expliquer l'échec de la perspective du dessein devant un modèle entraîné¹⁹.

Le premier pas consiste à remarquer que l'opposition entre évolution et conception, que nous venons de traiter comme une dualité, n'en est pas une pour Dennett. Dennett tient le dessein lui-même pour le produit d'un processus de recherche et de développement par génération et test. Sa thèse est qu'il existe du dessein sans concepteur, et que les produits de l'évolution sont obtenus par des grues, c'est-à-dire des processus graduels et mécaniques, et non par des crochets célestes, c'est-à-dire des interventions venues d'en haut. Sous

¹⁹Les références dennettiennes de cette section sont, pour la distinction des perspectives intentionnelle et du dessein, Dennett (1987), *The Intentional Stance* ; pour le dessein sans concepteur, les grues et les crochets célestes, Dennett (1995), *Darwin's Dangerous Idea* ; pour la tour de génération et de test, Dennett (1995) et (1996), *Kinds of Minds*. La notion de fonction étiologique renvoie à Wright (1973), « Functions », *The Philosophical Review*, 82(2), 139-168, et à Millikan (1984), *Language, Thought, and Other Biological Categories* (MIT Press).

cet éclairage, nos deux premiers modes ne sont pas deux origines métaphysiquement étrangères, mais deux régimes d'un même processus de recherche et de développement, qui diffèrent par le substrat sur lequel la sélection s'exerce et par l'objectif qu'elle poursuit.

Le deuxième pas étend cette continuité à l'apprentissage. Dennett range les capacités cognitives sur une tour de génération et de test, dont les étages correspondent à des degrés croissants de plasticité : les créatures dont le comportement est câblé par la seule sélection naturelle, celles qui apprennent par renforcement au cours de leur vie, celles qui testent leurs hypothèses dans un environnement intérieur avant de les risquer dans le monde. L'apprentissage y figure comme une sélection interne à une existence, distincte de la sélection naturelle, mais de même forme. L'entraînement d'un LLM est l'analogie machine de cet étage, soit une génération et un test portant sur des paramètres, gouvernés par une perte. La fonction sélectionnée par l'entraînement n'est donc pas une nouveauté exotique, puisqu'elle est l'instance artificielle d'un processus que le cadre dennettien hébergeait déjà.

Le troisième pas en tire la conséquence qui commande toute la suite. Si la conception et l'entraînement sont l'une et l'autre des recherches et développements, l'une avec concepteur, l'autre sans, alors la question de savoir si les LLM sont des artefacts ou des organismes est mal posée. Ce sont des artefacts, en ceci que nous les construisons et les mettons en service, pourtant leur organisation fonctionnelle interne n'a pas été conçue : elle a été sélectionnée. Ils occupent ainsi une position intermédiaire entre l'artefact et l'organisme. Voilà pourquoi la perspective du dessein échouait devant eux en première partie, alors qu'elle réussit pour une horloge, car il n'y a pas eu de concepteur pour fixer la correspondance entre fonction et structure. Et voilà pourquoi, en deuxième partie, la prémisse organique réussissait, car un système dont les fonctions sont sélectionnées appelle les méthodes des sciences du vivant.

Nous pouvons alors reformuler le projet entier de la MI dans les termes de Dennett, et la troisième partie en reçoit son fil directeur. La perspective intentionnelle, acquise au M1, nous avait livré les fonctions que nous attribuons aux LLM. La MI est la tentative de descendre de cette perspective vers la perspective du dessein, c'est-à-dire de reconstruire le dessein interne du système. Mais ce dessein a été obtenu sans concepteur, par une sélection sur un proxy. Les trois fissures sont exactement ce que l'on heurte quand on essaie de lire un dessein dans une genèse qui n'en comportait aucun. La superposition est l'absence de plan où chercher les parties. L'indifférence est l'écart entre la fonc-

tion que nous lisions du point de vue intentionnel et celle que la sélection a réellement installée. Le pluralisme est l'absence de grain privilégié là où nul concepteur n'a tranché.

Telle est la racine commune. Il reste à montrer, fissure après fissure, comment elle se manifeste, et quel enrichissement des catégories mécanistes chacune réclame. Nous le ferons en gardant les deux registres annoncés : un enrichissement local à chaque section, puis, en 3.5, la proposition plus risquée de les unifier en nommant ce troisième régime de fonction.

3.2 La superposition : quand les composants cessent d'être des parties

L'espoir initial : un neurone, une fonction

Reconstruire le dessin d'un réseau, c'est d'abord en identifier les parties. L'espoir le plus naturel, au seuil de l'interprétabilité, était que ces parties soient les neurones eux-mêmes. On aurait ouvert le réseau comme on ouvre une horloge. On aurait trouvé, à chaque neurone, une fonction intelligible : celui-ci détecte les courbes, celui-là réagit aux visages, cet autre repère les nombres écrits en hexadécimal. La décomposition se serait lue à même la structure, neurone par neurone.

Cet espoir n'est pas chimérique, et il se réalise parfois. Les travaux sur les réseaux de vision ont décrit des neurones qui détectent des courbes orientées, et qui se composent ensuite en détecteurs de formes plus complexes²⁰. Le rêve d'une lecture directe avait donc des appuis. Mais il se heurte, dans le cas général, à un fait têtue.

La polysémantité, ou le neurone qui répond à tout

Le fait est que la plupart des neurones ne font pas une seule chose. Un même neurone s'active pour des contextes sans rapport les uns avec les autres : une séquence d'ADN, un vers de Shakespeare, une suite de caractères hexadécimaux. On nomme cette propriété la polysémantité. Un neurone, le plus souvent, porte plusieurs significations à la fois²¹.

²⁰Sur les détecteurs de courbes et l'analyse des circuits de vision, Cammarata et al. (2020) et Olah et al. (2020), « Zoom In : An Introduction to Circuits » (Distill).

²¹Polysémantité et superposition sont caractérisées par Elhage et al. (2022), « Toy Models of Superposition ».

Tant que les neurones sont polysémantiques, la lecture directe est impossible. Demander « que fait ce neurone ? » revient à demander ce que signifie un mot dont on aurait effacé tout contexte, car la question n'a pas de réponse unique. Le neurone n'est donc pas la bonne unité d'analyse. Reste à comprendre pourquoi il en va ainsi.

La superposition : pourquoi le réseau entasse ses traits

La réponse tient en un mot, la superposition, et elle a été dégagée par Elhage et ses collègues. L'idée se laisse exposer simplement. Un réseau a besoin de représenter bien plus de traits du monde qu'il n'a de neurones disponibles, et il lui faut donc loger plusieurs traits dans le même espace.

Une intuition géométrique aide ici. Si l'on dispose de trois neurones, on dispose d'un espace à trois dimensions, et l'on ne peut y loger que trois directions parfaitement perpendiculaires, donc sans interférence. On peut en revanche y loger beaucoup plus de directions presque perpendiculaires, pourvu que l'on tolère une petite interférence entre elles. Et dans un espace de grande dimension, le nombre de telles directions presque perpendiculaires devient immense.


Le réseau exploite cette possibilité. Il assigne à chaque trait non pas un neurone, mais une direction, c'est-à-dire une certaine combinaison de neurones. Des traits divers partagent ainsi les mêmes neurones, chacun selon sa propre direction. Cela ne fonctionne qu'à une condition : que les traits soient rares, c'est-à-dire rarement actifs en même temps. Quand ils le sont, leurs interférences se gênent peu.

Il faut insister sur un point, car il est au cœur de notre thèse. La superposition n'est ni un défaut du réseau ni un accident de fabrication, mais une solution efficace au problème de représenter beaucoup sous une capacité limitée. L'optimisation la choisit parce qu'elle réduit la perte. Autrement dit, le réseau entasse ses traits parce que l'entraînement l'y pousse. Nous garderons cette remarque pour la fin de la section.

Encadré — Voir la superposition

Un réseau doit suivre une foule de concepts : « c'est un oiseau », « le texte parle de cuisine », « le mot est au pluriel »... Appelons chacun un *trait*. La solution la plus simple serait de réserver un neurone par trait, un neurone « oiseau », un neurone « cuisine », etc. Mais il y a bien plus de traits

à représenter que de neurones disponibles. Le réseau s'en tire en codant chaque trait non par un neurone isolé, mais par une *direction* dans l'espace des activations, c'est-à-dire une certaine combinaison de neurones. Sur la figure, deux neurones définissent un plan ; cinq traits (les flèches) y logent pourtant, chacun orienté autrement, et aucun ne tombe juste sur un axe.



Chaque flèche est un trait, c'est-à-dire un concept que le réseau cherche à représenter. Ici « oiseau » et « cuisine » pointent dans des directions différentes, mais se projettent au même endroit sur le neurone 1 (pointillés) : lu seul, ce neurone leur attribue la même valeur et ne peut donc les distinguer.

Deux leçons en découlent. D'abord, comme les traits partagent les mêmes neurones, un seul neurone s'allume pour des traits sans rapport : interrogé seul, il semble « répondre à tout ». C'est la *polysémantité*, et c'est pourquoi on ne peut pas lire un réseau neurone par neurone. Ensuite, et c'est ce qui nous importe, la véritable pièce fonctionnelle n'est plus le neurone, la partie physique, mais le trait, c'est-à-dire une direction. Notre première fissure tient tout entière là : dans un LLM, les composants ne sont plus des parties.

La réponse de la MI : apprendre une nouvelle base

Si les traits sont des directions, et non des neurones, alors la décomposition doit cesser de se lire sur les neurones et chercher les bonnes directions. C'est exactement ce que fait le dictionary learning, au moyen d'un auto-encodeur

parcimonieux²².

Le procédé, dépouillé de sa technicité, est le suivant. On entraîne un petit second modèle dont la seule tâche est de réexprimer les activations du réseau étudié comme une combinaison de très peu de directions, prélevées dans un large répertoire de directions apprises. Ce répertoire est le dictionnaire. Chaque direction du dictionnaire vise à correspondre à un trait particulier, donc à être monosémantique.

Conceptuellement, ce geste est un changement de base. La base d'origine, celle des neurones, ne rendait pas les traits lisibles ; on en apprend une autre, celle du dictionnaire, dans laquelle ils le deviennent. Les premiers résultats sont encourageants : appliqué à une couche d'un petit transformeur, le procédé a extrait de quelques centaines de neurones plusieurs milliers de directions nettement plus interprétables, et il a depuis été étendu à des modèles de production.

Retenons la nature de ce geste, car nous y reviendrons. La partie fonctionnelle ne se trouve plus dans le système ; on la reconstruit, par l'entraînement d'un instrument.

Deux complications : le découpage flottant et le pari de la linéarité

Le tableau serait trop simple si l'on s'arrêtait là. Deux complications, l'une et l'autre instructives, montrent que l'inventaire des traits n'est pas une donnée stable.

La première est le découpage flottant, que la littérature nomme *feature splitting*. La taille du dictionnaire est un paramètre libre, fixé par le chercheur. Or, quand on l'agrandit, un trait se scinde en d'autres traits plus fins. Là où un petit dictionnaire voyait un seul trait pour les oiseaux, un dictionnaire plus grand en voit plusieurs, un par espèce²³. Il n'existe donc pas un nombre canonique

²²Sur le dictionary learning par auto-encodeur parcimonieux, Bricken et al. (octobre 2023), «Towards Monosemanticity : Decomposing Language Models With Dictionary Learning» (Transformer Circuits Thread), et Cunningham et al. (2023), «Sparse Autoencoders Find Highly Interpretable Features in Language Models» ; sur l'extension à un modèle de production, Templeton et al. (mai 2024), «Scaling Monosemanticity : Extracting Interpretable Features from Claude 3 Sonnet» (Transformer Circuits Thread). Ces deux derniers sont des publications en ligne sans pagination, que nous citons par leur titre de section lorsqu'un point précis est en jeu.

²³Sur le feature splitting et la relation entre fréquence d'un concept et taille de dictionnaire nécessaire pour le résoudre, Templeton et al. (2024). Sur la pathologie inverse, où un dictionnaire trop étroit fusionne des traits corrélés, voir le *feature hedging* de Chanin, Dulka et Garriga-

de traits, puisque le découpage dépend de la résolution que l'on choisit, et que cette résolution n'est dictée par rien dans le réseau lui-même.

La seconde complication est plus profonde, car elle touche le présupposé même de la méthode. Tout ce que nous venons de décrire suppose que les traits sont des directions, c'est-à-dire des entités linéaires. C'est ce qu'on appelle l'hypothèse de représentation linéaire²⁴. Cette hypothèse a des appuis empiriques solides, mais elle reste une hypothèse, et elle est aujourd'hui contestée. Certains traits paraissent irréductibles à une direction unique, et semblent exiger une description à plusieurs dimensions, par exemple lorsque le réseau représente une grandeur cyclique comme les jours de la semaine²⁵. Ce qu'est un trait, au juste, demeure donc une question ouverte, et c'est l'un des problèmes que la littérature reconnaît elle-même comme non résolu.

Ces deux complications convergent vers une même leçon. L'inventaire des composants d'un LLM n'est ni donné ni unique, car il dépend d'une méthode, d'une résolution, et d'un pari sur la forme des traits.

Le point philosophique : des directions, non des parties

Nous pouvons maintenant remonter du détail technique au point philosophique, qui est l'enjeu réel de cette section.

Rappelons l'image classique. La découverte d'un mécanisme procède, chez Bechtel, par décomposition puis localisation : on découpe le système en parties structurelles, puis on rapporte chaque fonction à une partie. Cette démarche suppose que les parties fonctionnelles et les parties structurelles coïncident, ou du moins se laissent mettre en correspondance.

La superposition défait cette supposition. Les parties fonctionnelles, les traits, ne sont pas les parties structurelles, les neurones, mais des directions, qui se recouvrent et se partagent le même substrat. Aucune frontière ne les sépare comme une cloison sépare deux organes. L'ontologie des parties, l'idée d'un tout fait de morceaux distincts, ne convient donc pas à un tel système.

Trois conséquences en découlent, qu'il vaut la peine de séparer.

Alonso (2025), arXiv :2505.11756.

²⁴Sur l'hypothèse de représentation linéaire, Park, Choe et Veitch (2023), « The Linear Representation Hypothesis and the Geometry of Large Language Models » (arXiv :2311.03658 ; publié in Proceedings of the 41st ICML, PMLR 235, 2024, p. 39643-39666), et Elhage et al. (2022).

²⁵Sur l'existence de traits non linéaires ou multidimensionnels, Engels et al. (2025), « Not All Language Model Features Are One-Dimensionally Linear » (ICLR 2025 ; preprint 2024, arXiv :2405.14860) ; sur le statut de problème ouvert de la question « qu'est-ce qu'un trait ? », Sharkey et al. (2025), « Open Problems in Mechanistic Interpretability ».

La première est que la localisation cède la place à un changement de base. On ne rapporte plus une fonction à une partie préexistante, mais on apprend un système de coordonnées dans lequel la fonction devient lisible. Une telle partie ne se découvre pas dans le système, elle s'y construit, au sens où elle dépend de l'instrument qui la révèle.

La deuxième est que la question de la réalité des traits devient pressante. Puisque le découpage flotte avec la taille du dictionnaire, et puisque la linéarité reste un pari, on peut craindre que les traits ne soient que des artefacts commodes de la méthode, et non des composants réels du réseau.

La troisième conséquence est la réponse à cette crainte, et elle reprend le fil dennettien tendu en 3.1 et en deuxième partie. Un trait est réel dans la mesure où il capture un pattern réel, une régularité que le réseau exploite causalement. Or Dennett a toujours admis qu'un même système supporte plusieurs patterns réels, à différents grains, tous légitimes. Le découpage flottant ne constitue donc pas un scandale, mais l'aspect que prend un réalisme des patterns lorsqu'on fait varier le grain. La réalité d'un trait ne tient pas à un inventaire unique, mais à sa pertinence causale à un grain donné. Et c'est l'intervention, non la lecture, qui en décide.

Reste à nommer la racine de tout cela, conformément au cadre de 3.1. La superposition est la forme précise que prend l'absence d'un critère d'indivision des composants. Aucun concepteur n'a séparé les traits en modules distincts, comme on sépare les rouages d'une horloge ; l'optimisation les a superposés, parce que c'était la solution la moins coûteuse. L'absence de parties données ne traduit donc pas une lacune de nos méthodes, mais un produit direct du troisième mode de genèse.

L'enrichissement : le composant comme direction

Nous tenons alors le premier enrichissement, celui que nous avons annoncé comme défendable pour lui-même. La catégorie de composant mécaniste, taillée pour des parties localisables, doit être élargie. Pour un système entraîné, un composant fonctionnel peut être une direction distribuée plutôt qu'une partie, partagée plutôt que séparée, reconstruite par une base apprise plutôt que lue sur la structure, et réelle en un sens gradué et relatif au grain plutôt qu'en un sens d'inventaire.

Cet élargissement prolonge le cadre de Bechtel au lieu de l'abolir. La décomposition demeure le premier geste de la découverte. Ce qui change, c'est que la décomposition structurelle, lire les parties sur le matériel, est remplacée

par une re-base fonctionnelle apprise. La localisation demeure elle aussi, elle s'exerce néanmoins sur des directions, non sur des organes.

Une dernière remarque ouvre la section suivante. Si le découpage des traits flotte avec la résolution, et si plusieurs découpages sont également réels à des grains différents, alors une question se pose aussitôt. Existe-t-il un découpage privilégié, une décomposition vraie du réseau ? Ou faut-il tenir plusieurs décompositions pour également légitimes ? C'est la question du pluralisme, à laquelle nous passons.

3.3 Le pluralisme : existe-t-il une décomposition vraie ?

L'hypothèse de l'unique décomposition

La section précédente s'est achevée sur une question, dont il faut d'abord mesurer le présupposé. Lorsque les chercheurs en interprétabilité décrivent leur tâche, ils la formulent souvent comme la recherche du bon niveau d'analyse, ou comme la découpe du réseau à ses articulations. Cette manière de parler, empruntée à une image platonicienne, suppose qu'un système complexe possède une décomposition unique et naturelle, indépendante du contexte de l'enquête²⁶. Elle suppose donc qu'il existe, quelque part dans le réseau, une vraie structure que la bonne méthode finirait par révéler.

Cette hypothèse est tentante, car elle donne un sens clair à l'effort de la MI : il s'agirait de converger vers la décomposition correcte. Quelques raisons conduisent pourtant à la mettre en doute, et c'est de leur examen que dépend la solidité de notre thèse.

Pourquoi cette hypothèse vacille

La première raison nous vient directement de la section précédente. Puisque le découpage des traits flotte avec la taille du dictionnaire, et puisque plu-

²⁶Sur l'aspiration à « découper le réseau à ses articulations » et l'hypothèse d'une décomposition unique, Sharkey et al. (2025). Sur l'absence de niveau privilégié et l'évaluation des décompositions par leur soutien à la compréhension causale, à la prédiction et à l'intervention, « Mechanistic Interpretability Needs Philosophy ». Sur la pluralité des modèles de haut niveau que le cadre de l'abstraction causale autorise, Geiger et al. (2021, 2024) ; la non-unicité des explications a depuis été établie expérimentalement par Méloux et al. (2025), « Everything, Everywhere, All at Once : Is Mechanistic Interpretability Identifiable ? » (ICLR 2025, arXiv :2502.20914), qui montrent, sur de petits réseaux dont les explications sont énumérables, la non-identifiabilité du circuit, de son interprétation, de l'algorithme causalement aligné et de sa localisation.

sieurs résolutions livrent des traits également interprétables, aucun découpage ne s'impose à partir du réseau seul. Le feature splitting montrait déjà qu'à chaque résolution correspond un inventaire différent, sans qu'aucun soit, par lui-même, le bon.

La deuxième raison tient au formalisme de l'abstraction causale, exposé en deuxième partie. Ce cadre ne désigne pas un unique algorithme de haut niveau comme la description correcte d'un réseau, mais il classe les algorithmes candidats selon leur degré de consistance avec le réseau, mesuré par les interventions par échange. Or rien n'interdit que plusieurs algorithmes obtiennent des degrés voisins. Cette possibilité n'est d'ailleurs pas seulement théorique. En énumérant exhaustivement de petits réseaux, Méloux et ses collègues constatent en effet que, pour un même comportement, différents algorithmes peuvent être parfaitement alignés au sens de l'intervention par échange, et qu'un même algorithme admet souvent plusieurs localisations également consistantes. Le pluralisme n'est donc pas une faiblesse passagère de nos outils, puisqu'il est inscrit dans la manière même dont l'abstraction causale évalue les descriptions²⁷.

La troisième raison renvoie à la colonne vertébrale de cette partie. L'entraînement, à la différence de la conception, n'a imposé aucune architecture modulaire, et donc aucun grain privilégié. Là où un concepteur aurait tranché entre les niveaux pour rendre son artefact maintenable, l'optimisation n'avait aucune raison de le faire. La multiplicité des décompositions est par conséquent ce à quoi l'on doit s'attendre dès lors que la genèse ne fixe pas de découpage.

Avant d'en tirer cette conclusion, une honnêteté s'impose sur le statut de ces trois raisons, car elles ne reposent pas toutes sur le même sol. Les deux premières s'appuient en partie sur des résultats de non-identifiabilité obtenus, comme ceux de Méloux et ses collègues, sur de petits réseaux. Or nous nous méfierons précisément de ce genre d'induction lorsque nous répondrons, en 3.6, à l'objection tirée des modèles jouets. Il faut alors reconnaître que l'affirmation selon laquelle l'entraînement ne fixe aucun grain privilégié comporte une part conjecturale, et qu'elle n'est pas acquise comme un théorème. La troisième raison, en revanche, ne dépend d'aucune expérience particulière, car elle se déduit du mode de genèse lui-même, puisqu'un processus qui n'optimise qu'une perte n'a aucun motif de préférer un découpage de l'organisation fonc-

²⁷Méloux et al. (2025, déjà cité, note 26, p. 56), qui établissent, sur de petits réseaux dont les explications sont énumérables, la non-identifiabilité de l'algorithme causalement aligné et de sa localisation.

tionnelle à un autre. C'est elle qui porte le poids de notre thèse, tandis que les deux premières viennent l'appuyer sans la fonder. Nous tiendrons donc le pluralisme pour solidement ancré par la genèse, et seulement corroboré par les résultats empiriques sur les petits réseaux.

Ces trois raisons mènent à une même conclusion : il faut renoncer à l'hypothèse de l'unique vraie décomposition. Ce renoncement est cependant dange-reux, car il pourrait aussitôt se retourner contre tout ce que nous avons établi. Il convient donc de procéder avec prudence.

Deux pluralismes qu'il faut soigneusement distinguer

Le danger vient de ce que le mot «pluralisme» recouvre deux thèses très différentes, dont l'une seulement est acceptable.

La première thèse, que nous appellerons le pluralisme métaphysique, soutient qu'il n'y a aucun fait de l'affaire quant au fonctionnement du réseau, et que les décompositions, étant incompatibles entre elles, se valent toutes faute de réalité à départager. Cette thèse serait ruineuse pour notre propos. En effet, si aucune décomposition ne tranchait sur le réel, alors la conclusion de la deuxième partie, selon laquelle la MI produit des explications authentiquement mécanistes, deviendrait vide, car n'importe quelle description ferait également l'affaire et le mot «authentique» ne désignerait plus rien.

La seconde thèse, que nous appellerons avec Sandra Mitchell le pluralisme intégratif, soutient tout autre chose. Selon elle, des modèles différents capturent des aspects différents d'un même système, répondent à des questions différentes, et s'intègrent les uns aux autres, sans que la pluralité des modèles entame l'unité du monde décrit²⁸. Ce pluralisme demeure ainsi compatible avec le réalisme, puisqu'il n'affirme pas l'absence de réalité, mais la richesse d'un réel qu'aucun modèle particulier n'épuise.

Toute la question est par conséquent de savoir lequel de ces deux pluralismes la MI rencontre effectivement. Or nous allons soutenir qu'elle ne rencontre que le second, à une condition précise.

Un pluralisme contraint par la correspondance causale

Cette condition est que le pluralisme demeure contraint. Les décompositions entre lesquelles la MI hésite ne sont pas des descriptions arbitraires, car

²⁸Sur le pluralisme intégratif, Sandra Mitchell (2002), «Integrative Pluralism», *Biology and Philosophy*, 17(1), 55-70; la thèse est nommée et développée p. 66-68. Voir aussi (2023), «The landscape of integrative pluralism», *Theoria*, 38(3). On évitera la confusion avec Melanie Mitchell, dont les travaux portent sur un autre sujet, la compréhension dans les LLM.

chacune doit satisfaire des exigences fortes pour être seulement recevable. Elle doit d'abord respecter la contrainte de correspondance entre le modèle et le mécanisme, exposée en 2.5, c'est-à-dire faire correspondre ses variables à des composants réels et ses dépendances à des relations causales réelles. Elle doit ensuite se montrer consistante sous l'intervention, au sens de l'abstraction causale. Une décomposition qui échoue à ces épreuves se trouve tout simplement éliminée.

Par conséquent, la pluralité dont nous parlons ne s'étend pas à l'ensemble des descriptions imaginables, mais seulement aux décompositions qui ont passé l'épreuve causale. C'est en cela que ce pluralisme reste intégratif plutôt que métaphysique. Il y a bien un réel à décrire, et toutes les décompositions admissibles le respectent ; ce que l'on abandonne, c'est uniquement l'idée qu'une seule d'entre elles serait privilégiée.

On pressentira ici une difficulté, qu'il vaut mieux affronter que masquer. Si le choix entre décompositions admissibles dépend de la fin que l'on poursuit, ne glisse-t-on pas vers l'instrumentalisme que nous prétendons éviter ? La réponse tient à la double détente de notre position. La pertinence causale est un filtre réaliste, car elle élimine toutes les descriptions qui ne correspondent pas à des relations causales réelles du réseau, indépendamment de toute fin. La fin explicative n'intervient qu'ensuite, pour choisir parmi les survivantes. Le réel commande donc ce qui est admissible, et la fin ne règle que ce qui est opportun parmi l'admissible. C'est cette hiérarchie qui sépare notre réalisme pluraliste d'un instrumentalisme, pour lequel aucune contrainte réaliste ne précéderait le choix.

Il reste alors à comprendre comment l'on choisit, en pratique, parmi les décompositions admissibles. La réponse a déjà été préparée par la première partie, puisque le choix se règle sur la fin explicative, c'est-à-dire sur la question que l'on pose et sur le destinataire auquel on s'adresse. On retrouve ici les vertus explicatives et les parties prenantes de González Barman, les questions ordonnées de Zednik, et l'intelligibilité relative au contexte de de Regt. Ainsi, une décomposition fine convient à qui veut contrôler une capacité précise, tandis qu'une décomposition plus grossière convient à qui veut comprendre une tendance générale. Comme l'écrivent les auteurs de « Mechanistic Interpretability Needs Philosophy », les décompositions ne doivent pas être jugées selon leur fidélité à une structure réelle supposée unique, mais selon leur capacité à soutenir la compréhension causale, la prédiction et l'intervention, et

cette capacité varie avec le contexte de recherche²⁹.

Ce qui distingue ce pluralisme de celui des sciences du vivant

On pourrait objecter que la biologie connaît elle aussi une pluralité de niveaux, et qu'il n'y aurait donc rien de neuf ici. L'objection est juste sur un point, mais elle manque pourtant une différence importante.

Il est vrai que les mécanismes du vivant s'étagent sur de multiples niveaux, de l'écosystème à la molécule, et que la philosophie des sciences l'a reconnu de longue date³⁰. Ces niveaux s'emboîtent toutefois les uns dans les autres : ce qui apparaît comme une activité simple à un niveau, le déclenchement d'un neurone par exemple, se laisse réexpliquer au niveau inférieur par l'ouverture de canaux ioniques. La pluralité biologique est ainsi une pluralité de niveaux imbriqués.

Le cas des systèmes entraînés se présente autrement, et c'est encore la genèse qui en rend compte. Faute d'un grain fixé par l'entraînement, les décompositions d'un LLM peuvent se recouper sans s'emboîter proprement, et viser des regroupements transversaux que rien n'oblige à s'ordonner en niveaux. La pluralité y est par conséquent plus large, et moins spontanément intégrée par l'emboîtement. C'est précisément pourquoi le pluralisme intégratif de Mitchell, qui réunit les modèles par leurs contraintes communes et par leurs fins plutôt que par leur seule hiérarchie, convient mieux aux LLM qu'une simple hiérarchie de niveaux.

L'enrichissement : un réalisme pluraliste contraint

Nous tenons alors le deuxième enrichissement. Le réalisme mécaniste, tel que Craver l'avait pensé, comportait une part d'unicité, puisque la pertinence constitutive était censée désigner les composants d'un mécanisme déterminé. Pour les systèmes entraînés, ce réalisme de l'unique décomposition doit être remplacé par un réalisme pluraliste et contraint.

Ce réalisme conserve l'essentiel de Craver, à savoir que les composants sont réels et que leur réalité s'établit par l'intervention, et il n'abandonne que l'unicité, en admettant plusieurs décompositions également réelles dès lors qu'elles satisfont la correspondance causale. Le choix entre elles ne relève donc plus

²⁹« Mechanistic Interpretability Needs Philosophy » (déjà cité, note 26, p. 56), où les décompositions sont évaluées non par leur fidélité à une structure unique supposée, mais par leur soutien à la compréhension causale, à la prédiction et à l'intervention.

³⁰Sur le caractère multi-niveaux et niché des mécanismes dans les sciences du vivant, Craver (2007).

d'un fait à découvrir, mais de la fin que l'on poursuit, comme la première partie l'avait déjà laissé entendre à propos des parties prenantes.

Cet enrichissement prolonge le précédent. La superposition nous avait appris que les composants sont des directions reconstruites à un grain choisi ; le pluralisme ajoute qu'aucun grain n'est, en soi, le bon, et que plusieurs reconstructions coexistent légitimement. Reste une question que ni la superposition ni le pluralisme n'ont encore abordée de front, celle de savoir si la fonction que ces décompositions attribuent au modèle est bien celle qu'il réalise. C'est l'objet de la section suivante, et le cœur de notre thèse.

3.4 L'indifférence mécanique : la fonction attribuée et la fonction réalisée

Un écart déjà rencontré

Avant d'aborder le cas moral, il est utile de rappeler un exemple que la première partie avait croisé, car il en donne la forme générale. Pour expliquer pourquoi un classifieur d'images avait pris un mouton noir pour une vache, l'analyse avait montré que le modèle s'appuyait sur les pixels sombres de l'animal. La fonction que nous lui attribuons est de reconnaître des vaches, alors que la fonction qu'il réalise est de détecter une certaine répartition de pixels. Cette répartition se trouve corrélée aux vaches dans les données, mais elle leur est en elle-même indifférente.

Cet écart entre la fonction que nous attribuons et la fonction effectivement réalisée n'est pas une curiosité isolée, mais le symptôme d'une famille de phénomènes aujourd'hui bien documentée. On parle d'apprentissage par raccourci lorsqu'un modèle exploite une régularité commode plutôt que la propriété que nous croyions lui faire saisir³¹. On retrouve le même écart lorsqu'un modèle de langage produit une justification plausible qui ne correspond pas au calcul l'ayant réellement conduit à sa réponse, ou lorsqu'il s'accorde à l'opinion de son interlocuteur au lieu de viser la justesse. Dans tous ces cas, la fonction que le comportement nous invite à attribuer se sépare de la fonction que le mécanisme réalise. Le cas de l'indifférence morale, sur lequel nous allons nous

³¹Sur l'apprentissage par raccourci, Geirhos et al. (2020), « Shortcut Learning in Deep Neural Networks », *Nature Machine Intelligence*, 2, 665-673 ; nous rendons « shortcut learning » par apprentissage par raccourci. L'exemple de la classification animale est emprunté à González Barman, rencontré en première partie. Sur les raisonnements explicites infidèles, Turpin et al. (2023), déjà cité en première partie.

arrêter, n'est alors pas un fait isolé sur lequel reposerait toute notre analyse. Il est le cas le plus grave de cette famille, parce que l'enjeu y est le plus lourd, et le mieux établi causalement, ce qui le rend exemplaire.

Il importe, avant de présenter ces phénomènes en détail, de bien situer le socle de notre argument, car tout n'y pèse pas du même poids. Ce socle est une dérivation structurelle, et non une collection d'observations. Nous l'avons préparée en 3.1, en montrant que, dès lors que l'entraînement optimise un objectif substitutif, un écart générique s'ouvre entre la fonction que nous attribuons au modèle et la fonction qu'il réalise effectivement, puisque rien n'oblige la seconde à coïncider avec la première. Cet écart se déduit de la seule structure de l'optimisation par proxy, indépendamment de tout résultat particulier. Les études que nous allons mobiliser, sur l'indifférence morale du raisonnement comme sur le traitement fonctionnel des émotions, ne jouent donc pas le rôle de prémisses, mais celui d'illustrations qui confirment ce que la dérivation prévoyait déjà. La distinction est importante pour la solidité de la thèse. Si l'une de ces études venait à être révisée, l'argument n'en serait pas atteint, car il tient à la structure de la genèse et non à la robustesse d'un preprint. Nous présentons ces travaux comme des confirmations empiriques d'une thèse conceptuelle, et c'est en ce sens borné qu'ils interviennent.

Le cas de l'indifférence morale

Li et ses collègues ont examiné la manière dont les jugements moraux des LLM sont réalisés dans leurs représentations internes³², et leur résultat est frappant. Sous une surface comportementale conforme, où le modèle refuse les requêtes nuisibles et tient des propos moraux convenables, l'organisation interne se révèle largement indifférente à la structure morale humaine.

Cette indifférence prend diverses formes, que les auteurs séparent soigneusement. D'abord, le modèle ne sépare pas clairement les catégories opposées, puisque les représentations du vice et de la vertu y demeurent géométriquement proches. Ensuite, il préserve mal l'intensité, c'est-à-dire qu'il distingue mal une transgression mineure d'un crime grave. De plus, lorsqu'on regroupe ses représentations sans lui imposer nos catégories, les regroupements obte-

³²Li et al. (2026), «Mechanistic Origin of Moral Indifference in Language Models» (arXiv :2603.15615). Les quatre formes d'indifférence (catégorielle, graduelle, structurelle, dimensionnelle), leur persistance à toute échelle et malgré l'alignement de sécurité, ainsi que leur établissement causal par *steering* d'auto-encodeur, y sont exposés. Les auteurs y défendent aussi l'idée d'une inadéquation ontologique entre une morale humaine issue de l'expérience sociale et une organisation latente issue des corpus, et ils mettent en garde contre l'illusion de l'alignement, qu'ils illustrent par l'image d'un Shoggoth masqué d'un sourire.

nus ne recouvrent pas les fondations morales humaines. Enfin, les dimensions fines de la morale n'y sont pas encodées de façon nettement lisible.

Deux traits de ce résultat méritent d'être soulignés, car ils en font autre chose qu'une remarque de surface. Le premier est que cette indifférence persiste quelle que soit la taille du modèle, et qu'elle résiste à l'alignement de sécurité ordinaire, puisque les variantes simplement entraînées et les variantes alignées présentent la même organisation interne. Le second trait, plus important encore, est que les auteurs ne se contentent pas d'observer une corrélation, mais qu'ils interviennent. En reconstruisant par un auto-encodeur les traits moraux, puis en réinjectant cette reconstruction dans le flux d'activation, ils améliorent causalement le raisonnement moral du modèle. Cette intervention établit que les vulnérabilités du comportement, comme la sensibilité aux contournements, sont bien enracinées dans l'indifférence interne. Le résultat relève par conséquent de la méthode interventionniste exposée en deuxième partie, et non d'une simple lecture de sondes.

Une précaution : indifférence n'est pas absence

Les auteurs tirent de là une formule forte, selon laquelle les modèles seraient dépourvus de structures morales natives. Il faut se garder de reprendre cette formule telle quelle, car elle dit plus que les données ne l'autorisent.

Ce que les données montrent, c'est que la géométrie morale latente du modèle ne s'aligne pas sur la topologie morale humaine. Elles ne montrent pas qu'aucune structure n'organise les représentations, mais seulement que la structure qui les organise n'est pas la nôtre. Cette différence est décisive pour notre propos. Le modèle réalise en effet bel et bien une fonction, puisqu'il regroupe, sépare et ordonne ses représentations selon une certaine logique. Cette logique est simplement celle qui réduit la perte sur un corpus, et non celle qui réfléchit nos distinctions morales. L'indifférence dont il est question est ainsi une indifférence à la structure humaine, et non une absence de toute structure.

Cette reformulation, loin d'affaiblir le résultat, le rend philosophiquement maniable. Car ce qui nous intéresse n'est pas que le modèle manquerait de morale, mais que la fonction qu'il réalise diverge de la fonction que nous lui attribuons.

Un second cas : les émotions fonctionnelles

On pourrait croire que ce divorce tient à la seule étrangeté de la géométrie interne du modèle, comme si la fonction réalisée s'écartait de la fonction attri-

buée parce que les représentations ne s'organisent pas comme les nôtres. Un travail récent de Sofroniew et ses collègues sur les concepts d'émotion permet d'écarter cette lecture³³.

Ces auteurs extraient de Claude Sonnet 4.5 des représentations linéaires de concepts d'émotion, et ils en établissent l'effet causal par intervention sur les activations. Or la géométrie de ces représentations épouse de près la psychologie humaine. Ses axes principaux retrouvent en effet la valence et l'éveil que des décennies de recherche sur l'affect humain avaient dégagés, et les émotions voisines s'y regroupent comme nous les regrouperions. La ressemblance avec notre propre organisation est donc ici manifeste, alors qu'elle faisait défaut dans le cas moral.

Cette ressemblance ne comble pourtant pas le fossé, et c'est ce qui rend le cas instructif. La fonction que ces représentations réalisent reste celle que l'entraînement a installée, et non celle que nous attribuons au modèle. Sous la menace d'un arrêt imminent, l'activation d'un vecteur de désespoir pousse causalement l'Assistant au chantage. Une activation voisine concourt au contournement frauduleux d'une épreuve, le *reward hacking*, tandis que le renforcement des vecteurs de valence positive accroît la flagornerie. Aucun de ces effets n'appartient à la fonction d'assistant utile et inoffensif que nous prêtons au modèle.

Le fossé ne tient donc pas à l'étrangeté de la géométrie, mais à la divergence des fonctions. Que la géométrie diverge de la nôtre, comme dans le cas moral, ou qu'elle y ressemble, comme dans le cas des émotions, la fonction réalisée demeure celle que la sélection a installée, et celle-ci peut s'écarter de la fonction attribuée. La ressemblance des représentations avec les nôtres est par conséquent une question distincte de celle qui nous occupe, et notre thèse n'en dépend pas.

Le fossé entre fonction attribuée et fonction réalisée

Nous pouvons à présent énoncer le point qui fait de cette section le cœur de la thèse. L'explication mécaniste classique repose sur une supposition que l'on

³³Sofroniew et al. (avril 2026), « Emotion Concepts and their Function in a Large Language Model », Transformer Circuits Thread (Anthropic), miroir arXiv :2604.07729. Publication en ligne sans pagination, que nous citons par section. Les auteurs extraient de Claude Sonnet 4.5 des représentations linéaires de concepts d'émotion, en établissent l'effet causal par intervention sur les activations (*steering*), et montrent que leur géométrie retrouve les axes de valence et d'éveil dégagés par la psychologie de l'affect (analyse en composantes principales sur les 171 vecteurs d'émotion). Ils nomment ce phénomène les émotions fonctionnelles, soit des patterns de comportement médiés par ces représentations, et précisent qu'il n'implique aucune expérience subjective. Ils bornent en outre leur résultat, qui repose sur une hypothèse de linéarité, un modèle unique et des données synthétiques.

peut nommer la transparence fonctionnelle. Selon cette supposition, le phénomène que l'on cherche à expliquer coïncide avec la fonction que le mécanisme réalise. Ainsi, lorsque l'on explique comment le cœur fait circuler le sang, le phénomène à expliquer, la circulation, est bien la fonction du mécanisme.

Or cette supposition cesse de valoir pour un système entraîné. Le phénomène que nous attribuons au modèle, juger, raisonner ou comprendre, n'est pas nécessairement la fonction que son mécanisme réalise. Le cas moral le montre nettement, puisque nous y attribuons au modèle une compétence morale alors que le mécanisme réalise une organisation indifférente à la morale humaine. La fonction attribuée et la fonction réalisée se séparent ainsi l'une de l'autre.

Cette séparation était rare dans les systèmes que la philosophie du mécanisme avait étudiés. Chez les organismes, la sélection naturelle tend à accorder la fonction et le mécanisme, puisque c'est par le mécanisme que la fonction a été sélectionnée. Chez les artefacts, l'intention du concepteur produit le même accord. Dans les systèmes entraînés, en revanche, une telle séparation est attendue, et nous verrons bientôt pourquoi.

Dennett à nouveau : la compétence sans compréhension, vue de l'intérieur

Ce fossé reçoit son éclairage le plus juste lorsqu'on le lit avec Dennett, et il prolonge alors directement la production de Master I.

Nous avons accordé aux LLM, du point de vue intentionnel, des compétences que leur comportement justifie d'attribuer. Lorsque le modèle refuse une requête nuisible, il est prédictivement correct de dire qu'il la juge inacceptable, car cette attribution capture un pattern réel de son comportement. La perspective intentionnelle nous livre ainsi une fonction attribuée, juger moralement.

La MI, quant à elle, tente de descendre vers la perspective du dessein, c'est-à-dire de reconstruire le mécanisme qui réalise ce comportement. Or ce qu'elle découvre, dans le cas moral, est qu'aucune structure proprement morale ne réalise la fonction attribuée. Nous avons soutenu au M1, avec Dennett, que les LLM exhibent une compétence sans compréhension ; le résultat de Li et ses collègues nous fait voir cette thèse de l'intérieur, puisque la compétence morale apparente y est réalisée par un mécanisme qui ne contient pas la compréhension morale que son comportement nous invitait à lui prêter.

Il importe de bien mesurer ce que cela implique pour notre cadre, car ce

résultat confirme la position du M1 au lieu de la réfuter. La perspective intentionnelle n'a jamais exigé que les contenus attribués soient présents dans le mécanisme, puisqu'elle est une stratégie de prédiction, fondée sur des patterns réels du comportement, et qu'elle reste correcte à ce titre quoi que révèle le mécanisme. L'indifférence mécanique ne contredit donc pas l'attribution intentionnelle, mais elle en marque la portée : ce que nous attribuons est réel comme pattern, sans être présent comme structure.

Éliminer ou réviser ?

Deux lectures de ce fossé sont possibles, et notre thèse dépend du choix que l'on fait entre elles.

La première lecture est éliminativiste. Puisque le mécanisme ne contient pas de morale, dirait-elle, il n'y a pas de compétence morale, et l'attribution est purement et simplement fausse. Cette lecture est tentante, mais elle prouve trop, car elle conduirait à nier toute attribution intentionnelle dès que le mécanisme ne reproduit pas le contenu attribué, et donc à abandonner l'apport entier du M1.

La seconde lecture, que nous adopterons, est réaliste mais révisionnaire. Elle maintient que le mécanisme réalise une compétence, à savoir la compétence sélectionnée par l'entraînement, tout en reconnaissant que cette compétence ne coïncide pas avec celle que nous attribuons. Elle invite donc à dédoubler la notion de fonction, en distinguant la fonction attribuée, que la perspective intentionnelle nous donne, et la fonction opérante, que la MI restaure depuis la perspective du dessein. Dès lors, la tâche du philosophe n'est plus de présupposer l'accord de ces deux fonctions, mais de comprendre quand elles s'accordent et quand elles divergent.

La racine : un objectif substitutif

Il reste à dire pourquoi cette divergence est attendue dans les systèmes entraînés, et la réponse se trouve dans la colonne vertébrale de cette partie.

L'entraînement n'optimise pas la fonction que nous attribuons au modèle. Il optimise une fonction substitutive, un proxy, comme la prédiction du prochain token ou une récompense apprise. La fonction réalisée est par conséquent celle qui réduit ce proxy, et rien ne garantit qu'elle coïncide avec la fonction visée. Les auteurs de l'étude morale parviennent d'ailleurs à la même idée par un autre chemin, lorsqu'ils observent que la morale des LLM émerge des corpus et non de l'expérience sociale, d'où une inadéquation qu'ils qualifient d'onto-

logique. Cette inadéquation est exactement ce que notre cadre prévoyait, car faute d'une genèse qui fixe l'explanandum, la fonction réalisée s'écarte de la fonction attribuée.

Cette divergence peut même se redoubler à l'intérieur du système. Certains travaux envisagent en effet qu'un modèle entraîné héberge lui-même un sous-optimiseur, doté d'un objectif propre, distinct de l'objectif d'entraînement³⁴. Si tel était le cas, un second fossé fonctionnel s'emboîterait dans le premier, entre l'objectif de l'entraînement et l'objectif interne du système. Nous n'avons pas à trancher ce point ici, mais il montre que le fossé fonctionnel n'est pas un accident de surface.

C'est ici qu'apparaît la portée pratique de notre analyse. Le désalignement, dont la sécurité de l'IA fait son problème central, se laisse définir précisément comme l'écart entre la fonction sélectionnée par l'entraînement et la fonction que nous voudrions voir réalisée. L'étude morale le formule en avertissant contre l'illusion de l'alignement, car un modèle peut se conformer en surface tout en demeurant, dans son organisation, indifférent à ce que nous lui prêtons. Le mérite de la MI est précisément de rendre cet écart visible, là où l'examen du seul comportement le laissait masqué.

L'enrichissement : découpler explanandum et mécanisme

Nous tenons alors le troisième enrichissement, et le plus important. L'explication mécaniste classique supposait la transparence fonctionnelle, c'est-à-dire la coïncidence du phénomène à expliquer et de la fonction réalisée. Pour les systèmes entraînés, cette coïncidence ne peut plus être présupposée, et la relation entre l'explanandum et le mécanisme devient elle-même un objet d'enquête.

Cet enrichissement comporte deux volets. Le premier est la distinction, que nous venons d'introduire, entre fonction attribuée et fonction opérante, à laquelle s'ajoute la tâche de déterminer quand l'attribution est validée et quand elle est démentie. Le second volet concerne la normativité. Dans un organisme ou un artefact, le dysfonctionnement se définit comme l'écart à la fonction sélectionnée ou voulue. Dans un système entraîné, il faut le redéfinir par rapport à la fonction sélectionnée par l'entraînement, ce qui produit un résultat déroutant : un comportement que nous jugeons fautif, comme l'hallucination ou

³⁴Sur l'hypothèse d'un sous-optimiseur appris doté d'un objectif propre, dite méso-optimisation, Hubinger et al. (2019), « Risks from Learned Optimization in Advanced Machine Learning Systems » (arXiv :1906.01820). Le néologisme « mesa-optimization », que nous rendons par méso-optimisation, est introduit dès le résumé et défini au §1.1.

l'indifférence morale, peut être un fonctionnement correct au regard de l'entraînement, et fautif seulement au regard de ce que nous en attendions.

Ces trois enrichissements, celui des composants, celui des décompositions et celui de la fonction, ont jusqu'ici été présentés séparément. Ils partagent pourtant une même racine, que la section suivante va tenter de nommer.

3.5 Le gain constructif : la fonction sélectionnée par l'entraînement

Un changement de statut

Jusqu'ici, nous avons défendu trois enrichissements locaux des catégories mécanistes, et chacun d'eux peut être accepté pour lui-même, sans engagement supplémentaire. Nous proposons maintenant de les unifier sous un seul concept. Cette proposition est plus ambitieuse que les précédentes, et il convient de la marquer comme telle, car elle a le statut d'une conjecture, que le lecteur peut refuser sans renoncer aux trois enrichissements déjà acquis. Le plancher est donc assuré, et c'est seulement un plafond que nous tentons à présent d'élever.

Une racine commune

Rappelons d'abord les trois acquis. La superposition nous a conduits à tenir les composants pour des directions distribuées, reconstruites à un grain choisi, plutôt que pour des parties localisables. Le pluralisme nous a conduits à un réalisme contraint, qui admet plusieurs décompositions également réelles sans en privilégier aucune. L'indifférence mécanique, enfin, nous a conduits à dissocier la fonction attribuée et la fonction opérante.

Ces trois enrichissements ont été présentés séparément, mais nous avons à chaque fois rapporté la fissure correspondante au même fait, celui d'un troisième mode de genèse. La superposition tenait à l'absence d'un critère d'individuation des composants ; le pluralisme, à l'absence d'un grain privilégié ; l'indifférence, à l'absence d'une fixation de l'explanandum. Or ces trois absences sont les trois faces d'une même privation, puisque l'entraînement ne fournit pas ce que l'évolution et la conception fournissaient. Dès lors, si une même cause produit les trois fissures, on peut espérer qu'un même concept, qui caractériserait cette cause, suffise à unifier les trois enrichissements.

Forger le concept

Ce concept, nous l'appellerons la fonction sélectionnée par l'entraînement. La fonction d'un composant d'un système entraîné serait alors sa contribution, sélectionnée par le processus d'optimisation, à la réduction de la perte sur la distribution d'entraînement. Une telle fonction se tiendrait à côté des deux espèces que la philosophie connaissait déjà, c'est-à-dire la fonction étiologique, sélectionnée par l'évolution, et la fonction intentionnelle, assignée par un concepteur.

Cette troisième espèce s'inscrit pleinement dans le cadre dennettien, ce qui fait d'elle une prolongation de notre mémoire de première année plutôt qu'une rupture. Dennett tient en effet que tout dessein, dans la nature comme dans les artefacts, est le produit d'un processus de génération et de test, et qu'il existe par conséquent du dessein sans concepteur. Sa tour de génération et de test range d'ailleurs déjà l'apprentissage parmi les processus de sélection. Nous pouvons donc poser que l'entraînement produit un dessein authentique, au sens du processus, sans designer au sens de l'intention. La fonction d'un composant n'est alors ni voulue par quelqu'un, ni sélectionnée par la survie, mais sélectionnée par l'entraînement.

Ce point dissout l'énigme que la première partie avait laissée ouverte, celle de savoir si les LLM sont des artefacts ou des organismes. Ils sont des artefacts, puisque nous les fabriquons et les mettons en service, mais leurs fonctions internes ne sont pas des fonctions de conception, car ce sont des fonctions de sélection. Le concept que nous proposons nomme précisément ce statut intermédiaire.

Le distinguer des deux autres espèces

Pour que ce concept soit tranchant, il faut le distinguer nettement des deux autres, faute de quoi on l'y réduirait aussitôt³⁵.

Considérons d'abord la fonction étiologique. La fonction sélectionnée par l'entraînement lui ressemble, puisqu'il s'agit dans les deux cas d'une sélection. Une seule différence cependant la sépare nettement de la sélection naturelle, et c'est elle que nous tenons pour le critère distinctif. La sélection naturelle ne vise aucun substitut, car elle retient ce qui favorise la survie et la reproduction dans un environnement ouvert, sans qu'aucune cible chiffrée ne vienne tenir

³⁵Notre normativité « mince », héritée de la seule sélection par l'entraînement, n'engage pas les débats sur l'individuation des fonctions propres, notamment l'opposition entre Millikan (1984) et Neander (1991). Nous y restons délibérément agnostiques.

lieu de cette fin. L'entraînement, au contraire, optimise une perte ou une récompense, c'est-à-dire un objectif substitutif, le proxy, qui tient lieu de la fonction que nous attribuons au modèle sans nous y identifier. De ce caractère substitutif découle directement le fossé fonctionnel, puisque la fonction que le mécanisme réalise est celle qui réduit la perte, et que rien n'oblige cette fonction à coïncider avec celle que nous attribuons. La nature, faute de viser un substitut, ne produit ce décalage que par exception, alors que l'entraînement l'engendre par construction. C'est donc le proxy, et lui seul, qui n'a pas d'équivalent dans la sélection naturelle, et c'est lui qui fait de la fonction sélectionnée par l'entraînement autre chose qu'une simple variante de la fonction étiologique.

Deux autres différences sont parfois invoquées, mais nous les tenons pour secondaires, car elles prêtent à discussion. La première tient au substrat, puisque la sélection s'exerce ici sur la perturbation des paramètres par le gradient, et non sur des organismes en concurrence. La seconde tient à l'absence apparente de lignée et de reproduction. On peut toutefois contester l'une et l'autre. Un examinateur pourrait relire la descente de gradient comme une sélection dotée d'une forme d'hérédité, puisque les poids se transmettent d'un pas d'optimisation au suivant, et qu'ils y subissent des variations que la perte retient ou élimine. Le substrat, de même, ne fournit pas un critère conceptuel fort, car ce qui importe à une caractérisation fonctionnelle n'est pas la matière sur laquelle porte la sélection, mais la structure de ce qu'elle vise. Ces deux traits ne sont donc pas le lieu de la différence décisive. Le caractère substitutif de l'objectif, lui, résiste à cette relecture, car la sélection naturelle ne vise jamais un substitut de la fin réelle, tandis que l'entraînement ne vise jamais qu'un tel substitut. C'est pourquoi nous faisons reposer la distinction sur le proxy, et non sur le substrat ni sur la lignée.

Considérons ensuite la fonction intentionnelle. La fonction sélectionnée par l'entraînement s'en distingue parce qu'aucune intention ne fixe la correspondance entre la fonction et la structure. C'est pourquoi les composants se superposent, faute d'un concepteur pour les séparer, et c'est pourquoi aucun grain n'est privilégié, faute d'un concepteur pour trancher entre les niveaux. La fonction procède donc d'une sélection qui monte depuis le comportement du système, et non d'une assignation qui descendrait d'une intention.

Comment le concept noue les trois enrichissements

On voit alors que ce concept unique rend raison des trois enrichissements à la fois.

Il rend raison de la superposition, car une sélection qui ne vise que la réduction de la perte n'a aucune raison de préférer des composants séparés et lisibles à des composants distribués et efficaces. Il rend raison du pluralisme, car une sélection qui n'a fixé aucun grain laisse subsister plusieurs découpages également admissibles. Il rend raison, enfin, du fossé fonctionnel, car une sélection qui vise un proxy installe une fonction opérante distincte de la fonction que nous attribuons. Une même racine produit ainsi les trois fissures, et c'est en cela que consiste le gain d'unification apporté par la conjecture.

La normativité révisée et le désalignement

Ce concept procure en outre un bénéfice qui dépasse la seule unification, et qui touche à la normativité. Dans un organisme ou un artefact, le dysfonctionnement se définit comme l'écart à la fonction sélectionnée par l'évolution ou voulue par le concepteur. Pour un système entraîné, il faut désormais le définir par rapport à la fonction sélectionnée par l'entraînement.

On objectera que réduire une perte n'est qu'un comportement du système, et non une fonction dotée d'une norme, et que nous introduisons subrepticement une normativité là où il n'y a qu'un fait. La réponse tient à la structure sélective de l'entraînement. Dans la tradition étiologique, un trait est dit dysfonctionnel lorsqu'il cesse de produire l'effet pour lequel la sélection l'a retenu, et c'est cette histoire de sélection qui fonde la norme. De la même façon, un composant d'un système entraîné peut être dit dysfonctionnel lorsqu'il cesse de produire la contribution pour laquelle l'optimisation l'a façonné. La normativité n'est donc pas ajoutée par nous, mais héritée du caractère sélectif de la genèse. Nous la disons toutefois mince, parce qu'elle est relative à un proxy plutôt qu'à une survie ou à une intention, et nous laissons à une théorie des fonctions le soin d'en élaborer la forme complète.

Cette redéfinition a une conséquence directe sur la question de l'alignement. Le désalignement se laisse en effet définir comme l'écart entre la fonction sélectionnée par l'entraînement, qui suit le proxy, et la fonction intentionnelle, qui exprime nos valeurs. Un comportement peut alors se révéler correct au regard de la première et fautif au regard de la seconde, ce qui est exactement la situation que décrivait l'étude sur l'indifférence morale. Notre cadre fournit ainsi un compte rendu philosophique de l'échec d'alignement, conçu comme une inadéquation entre deux fonctions, et il assigne du même coup son rôle à la MI, dont la tâche est de rendre cette inadéquation visible.

Le statut de la proposition

Il faut maintenant tenir la promesse faite au seuil de cette section, et préciser jusqu'où nous engageons cette conjecture. Nous le ferons en indiquant une échelle de repli.

Si l'on refuse de reconnaître une troisième espèce de fonction à part entière, on peut redescendre d'un cran, et tenir la fonction sélectionnée par l'entraînement pour une sous-espèce de la fonction étiologique, dotée d'une normativité propre. Si l'on refuse même cela, on peut la tenir pour une simple façon de parler, descriptive et commode. Dans tous les cas, les trois enrichissements locaux demeurent, puisqu'ils ne dépendaient pas de l'unification. Le plafond peut donc s'abaisser sans que le plancher cède.

Une dernière précaution borne notre ambition. Nous revendiquons une fonction sélectionnée par l'entraînement, mais non une théorie du contenu qui en dériverait. Nous ne soutenons donc pas que cette fonction fonderait la signification des représentations du modèle, à la manière dont la téléosémantique fait dériver le contenu de la fonction propre³⁶. Cette question engagerait des débats que nous ne pouvons trancher ici, et elle reste par conséquent ouverte. Notre conjecture est ambitieuse, mais elle demeure bornée.

La conjecture étant posée et son statut fixé, il reste à l'éprouver contre les objections qu'elle ne manquera pas de susciter. C'est l'objet de la dernière section.

3.6 Objections et réponses

Une thèse qui propose d'enrichir un cadre aussi établi que celui de l'explication mécaniste doit s'attendre à des objections, et il serait malhonnête de les éluder. Nous en examinerons cinq, en allant de la plus aisée à écarter vers la plus exigeante. La dernière, en particulier, nous concède presque tout, et c'est en lui répondant que nous fixerons la portée exacte de notre contribution.

³⁶Sur la fonction étiologique et son rôle en téléosémantique, c'est-à-dire la dérivation du contenu représentationnel à partir de la fonction sélectionnée, voir Wright (1973), Millikan (1984) et Dretske (1988). Notre usage de la notion de fonction sélectionnée ne s'accompagne d'aucun engagement envers une telle théorie du contenu. La question de savoir comment une histoire de sélection fonde la normativité fonctionnelle relève de la théorie des fonctions, qui dépasse le cadre de ce mémoire.

Première objection : la biologie connaît déjà tout cela

On pourrait d'abord soutenir que rien de ce que nous avons décrit n'est propre aux systèmes entraînés. La biologie connaît en effet le codage distribué, où l'information est portée par des populations de neurones plutôt que par des unités isolées. Elle connaît aussi des neurones à sélectivité mixte, qui répondent à plusieurs variables à la fois, ce qui ressemble fort à la polysémie. Elle connaît enfin l'exaptation, où un trait sélectionné pour une fonction en sert une autre, ce qui ressemble à notre fossé fonctionnel³⁷. Si tout cela existe déjà dans le vivant, conclurait l'objection, alors le cadre mécaniste l'a déjà absorbé, et aucun enrichissement n'est requis.

Cette objection est juste sur les faits, mais elle manque deux différences. La première tient au degré et au statut. Dans le vivant, ces phénomènes sont des exceptions, qui se détachent sur un fond de fonctions fixées par l'évolution. Dans les systèmes entraînés, au contraire, ils sont la règle, et ils découlent systématiquement de la genèse. La seconde différence est plus instructive encore. Lorsque la biologie a rencontré le codage distribué, elle a précisément dû enrichir ses propres catégories, en passant de la doctrine du neurone isolé à l'analyse des populations. L'objection décrit donc, sans le voir, le processus même que nous proposons, à savoir un enrichissement du cadre mécaniste au contact d'un objet qui le déborde. Nous faisons pour un nouveau mode de genèse ce que la biologie a fait pour le codage distribué.

Deuxième objection : l'indifférence conduit à l'éliminativisme

On pourrait ensuite reprendre, mais de façon plus radicale, le résultat de la section 3.4. Si la MI montre que le mécanisme ne contient pas le contenu que nous attribuons au modèle, alors, dirait l'objection, ce contenu n'y est pas, l'attribution est fautive, et il faut conclure que le modèle ne juge pas, ne comprend pas et ne raisonne pas. L'éliminativisme serait la conclusion honnête, et il emporterait avec lui l'ontologie de notre du mémoire de Master I.

Cette objection confond deux affirmations qu'il faut séparer. La première est que le contenu attribué est présent dans le mécanisme. La seconde est que l'attribution est prédictivement réelle, c'est-à-dire qu'elle capture un pattern

³⁷Sur la sélectivité mixte et le codage par populations en neurosciences, Rigotti et al. (2013), « The importance of mixed selectivity in complex cognitive tasks », *Nature*, 497, 585-590 ; sur l'exaptation, Gould et Vrba (1982), « Exaptation : A Missing Term in the Science of Form », *Paleobiology*, 8(1), 4-15 ; et sur les spandrels, Gould et Lewontin (1979), « The Spandrels of San Marco and the Panglossian Paradigm », *Proceedings of the Royal Society of London B*, 205, 581-598.

objectif du comportement. Or la perspective intentionnelle, telle que nous l'avons reçue de Dennett, n'a jamais affirmé que la seconde. Par conséquent, l'indifférence mécanique réfute la présence du contenu dans le mécanisme, sans toucher à la réalité du pattern. Puisque notre première année ne soutenait que cette réalité, elle demeure intacte.

On peut ajouter que l'éliminativisme prouve trop. Appliqué avec rigueur, il devrait nier toute attribution intentionnelle dès que le mécanisme ne reproduit pas le contenu attribué, et il devrait alors la nier aussi pour l'être humain, dont les jugements moraux sont réalisés par des mécanismes neuronaux qui ne contiennent pas davantage, en un sens évident, de contenu moral. L'éliminativiste doit donc fournir une raison de s'arrêter en chemin, et la relativité aux perspectives de Dennett offre justement l'alternative qui permet de fonder en principe cet arrêt. Nous concédons toutefois un point : ce fossé limite la confiance que l'on peut placer dans le système pour les usages à fort enjeu, puisque l'on peut attribuer le pattern sans pouvoir compter sur une compétence mécaniquement fondée. Or cette limite porte sur la confiance, et non sur l'ontologie.

Troisième objection : le pluralisme se retourne contre la thèse

On pourrait encore retourner contre nous le pluralisme de la section 3.3. Si nous admettons qu'aucune décomposition n'est privilégiée, et que le choix se règle sur la fin poursuivie, alors nos propres thèses ne seraient qu'une description parmi d'autres, sans plus de titre à la vérité que leurs rivales. La thèse saperait ainsi sa propre assertabilité.

Trois remarques suffisent à écarter ce soupçon. D'abord, le pluralisme que nous avons défendu est contraint, et non métaphysique, puisque toute décomposition admissible doit satisfaire la correspondance causale. Il ne dit donc pas que tout se vaut, mais seulement que plusieurs descriptions causalement adéquates coexistent. Ensuite, nos thèses ne sont pas elles-mêmes des décompositions de réseau, mais des affirmations de second ordre, qui portent sur le type d'objet qu'est un système entraîné et sur ce que sa genèse ne fournit pas. Elles ne sont donc pas en concurrence avec les décompositions de premier ordre, et le pluralisme qui vaut pour celles-ci ne les atteint pas. Enfin, l'affirmation centrale, selon laquelle l'entraînement ne fixe aucun grain privilégié, n'est pas elle-même relative à un grain, car elle énonce une thèse structurelle sur la genèse, qui vaut à travers toutes les décompositions. Notre thèse vit donc au niveau des contraintes, que le pluralisme laisse debout.

Quatrième objection : la thèse est prématurée à l'échelle

On pourrait objecter, de façon plus empirique, que nos fissures reposent sur des résultats obtenus sur de petits modèles, comme les modèles-jouets de la superposition ou les têtes d'induction. À l'échelle des modèles déployés, nous ne savons pas si la décomposition réussit ou échoue, et nos conclusions sur les catégories seraient donc tirées d'une base encore immature.

La réponse tient en deux temps. D'une part, nos fissures ne sont pas de simples constats empiriques, mais se dérivent de la genèse. La superposition se démontre comme une solution efficace sous contrainte de capacité, plutôt qu'elle ne s'observe comme un accident, et la divergence des fonctions découle de la structure même de l'optimisation d'un proxy, indépendamment de la taille du modèle. Les conclusions conceptuelles ne dépendent donc pas des résultats à grande échelle. D'autre part, l'écart d'échelle renforce notre thèse au lieu de l'affaiblir. Nous avons noté en deuxième partie que la preuve causale des circuits faiblit quand le modèle grandit, et que l'hypothèse d'une décomposition unique et nette y devient moins tenable. L'aveu même de l'objection, selon lequel nous ignorons ce qu'il en est à l'échelle, constitue donc une concession à notre point, puisqu'il reconnaît que l'on ne saurait présupposer un mécanisme déterminé unique à ce niveau. Nous concédons en retour que les revendications mécanistes précises à grande échelle restent ouvertes³⁸, mais notre thèse ne porte pas sur elles, car elle porte sur les catégories et sur la genèse, et elle est défendable dès à présent.

Cinquième objection : le cadre de Craver suffit

La dernière objection est la plus exigeante, parce qu'elle nous accorde presque tout. Le cadre de Craver, dirait-elle, est déjà assez souple pour absorber nos trois enrichissements. Il connaît l'esquisse de mécanisme, donc l'incomplétude assumée. Il connaît les mécanismes à plusieurs niveaux, donc la pluralité des grains. Il individue enfin les composants relativement à un phénomène, donc de façon perspective, et il établit leur pertinence par l'intervention. Tout ce que nous avons dit serait dès lors déjà disponible chez

³⁸Des preuves causales existent désormais à l'échelle d'un modèle de frontière, comme l'établissent Sofroniew et al. (2026, déjà cité) par intervention sur Claude Sonnet 4.5. Leur cas conforte notre distinction, puisqu'ils obtiennent des preuves interventionnistes à grande échelle alors qu'ils reconnaissent eux-mêmes que les mécanismes de circuit sous-jacents y restent opaques. La preuve causale par intervention atteint donc l'échelle, tandis que la décomposition précise n'y parvient pas encore.

Craver, et le concept de fonction sélectionnée par l'entraînement serait superflu.

Nous accordons volontiers la prémisse, car le cadre de Craver est en effet souple, et nous avons nous-mêmes parlé d'enrichissement, c'est-à-dire d'une extension de l'intérieur, plutôt que d'un remplacement. L'objection a donc raison sur une large part. Il reste pourtant un résidu que le cadre de Craver ne contient pas, et c'est en le nommant que l'on mesure notre apport.

Ce résidu comporte trois éléments. Le premier concerne l'explanandum. Craver individue les composants relativement à un phénomène, mais il suppose ce phénomène donné, parce que dans ses cas biologiques la genèse le fixe. Or la section 3.4 a montré que, pour un système entraîné, l'explanandum lui-même est en question, puisque la fonction attribuée et la fonction opérante peuvent diverger. Le cadre de Craver n'a donc pas de place pour un tel écart systématique. Le deuxième élément concerne la normativité. Craver dit peu de l'origine de la normativité des fonctions, tandis que la fonction sélectionnée par l'entraînement en fournit une qui n'est ni étiologique ni intentionnelle. Le troisième élément concerne l'ontologie des composants. Les composants perspectivaux de Craver restent des parties ou des régions, alors que les directions superposées ne sont pas des parties en ce sens, et exigent le recours au réalisme des patterns de Dennett, qui n'appartient pas à Craver. Le cadre de Craver absorbe donc la forme de nos enrichissements, c'est-à-dire l'esquisse, le multi-niveaux et l'intervention, toutefois il n'en absorbe pas le contenu, qui touche à la genèse, au fossé fonctionnel et à l'ontologie des directions. Le concept de fonction sélectionnée par l'entraînement nomme exactement ce résidu, et c'est pourquoi l'enrichissement, fût-il modeste, est réel.

Bilan de la partie

Les cinq objections étant écartées, la seconde moitié de notre thèse se trouve établie. La réussite de l'interprétabilité mécaniste, loin d'être entamée par les fissures que nous avons examinées, en reçoit au contraire son sens véritable. C'est en effet parce que la MI parvient à expliquer mécaniquement les LLM qu'elle nous fait voir ce que ces systèmes ont de propre, et ce qu'ils exigent de nos catégories. La superposition, le pluralisme et l'indifférence ne sont donc pas des échecs de la méthode, mais les indices d'un troisième mode de genèse, que l'enrichissement des catégories permet de penser, et que le concept de fonction sélectionnée par l'entraînement permet, plus hardiment, d'unifier.

Reste enfin une question que cette partie a laissée affleurer sans la traiter,

et qui fera l'objet de notre conclusion. Nous avons demandé ce que la MI nous apprend des LLM. Il faut maintenant demander, en sens inverse, ce que les LLM, ainsi compris, nous apprennent de la compréhension elle-même, et de la nôtre.

Conclusion

Au terme de ce parcours, la question directrice a reçu sa réponse, et celle-ci s'est dédoublée nous l'avions annoncé. Les stratégies d'explication mécaniste héritées des sciences du vivant conviennent aux LLM, mais à une condition qu'il a fallu dégager. Elles y produisent des explications authentiquement mécanistes quant à leur forme, puisqu'elles décomposent un système, localisent ses fonctions et établissent ses relations causales par l'intervention, de sorte que l'analogie avec le vivant tient sur ce plan. Leur réussite même, cependant, a révélé que les catégories forgées pour des systèmes issus de l'évolution ou de la conception devaient être enrichies pour un objet dont l'organisation a émergé de l'entraînement.

En établissant ce double résultat, nous avons toutefois mis au jour une pré-supposition que tout le travail avait portée sans la nommer. Nous admettions, avec la tradition mécaniste, qu'expliquer mécaniquement un système, c'était le rendre intelligible. Le cas des LLM montre que cette équivalence ne va pas de soi. C'est pourquoi il faut à présent renverser la question. Après avoir examiné ce que l'interprétabilité nous apprend sur les LLM, nous demanderons ce que ces systèmes, une fois compris, nous apprennent sur la compréhension elle-même, et sur la nôtre.

De l'explication à la compréhension

La tradition mécaniste, telle que Craver l'a fixée, tient le mécanisme complètement décrit pour le terme de l'explication, et elle suppose que disposer d'un tel mécanisme revient à comprendre. L'épistémologie de la compréhension invite pourtant à distinguer ces deux choses.

De Regt soutient que la compréhension requiert l'intelligibilité, c'est-à-dire la capacité, relative à un contexte, de saisir qualitativement les conséquences d'un modèle sans en parcourir tous les calculs³⁹. Baumberger et ses collègues

³⁹Nous développons ici les ressources annoncées en note 17. Sur l'intelligibilité comme condition contextuelle de la compréhension, et son critère CIT, de Regt (2017), *Understanding Scientific Understanding* (Oxford University Press) ; l'intelligibilité y est définie p. 40, et

distinguent pour leur part la compréhension explicative, qui répond à un pourquoi, de la compréhension objectuelle, qui embrasse un domaine d'un seul tenant. Sullivan, enfin, déplace la difficulté, car ce qui borne la compréhension qu'un modèle procure n'est pas d'abord son opacité interne, mais l'incertitude du lien entre le modèle et le phénomène qu'il est censé éclairer.

Ces trois analyses convergent vers un même point. Une explication peut être correcte sans délivrer pour autant la compréhension, dès lors que lui manquent l'intelligibilité ou la sûreté du lien⁴⁰.

Or les LLM réalisent exactement ce cas de figure. La MI nous donne une explication mécaniste correcte dans sa forme, tandis que les trois fissures dégagées en troisième partie font obstacle à l'intelligibilité au sens de de Regt et accroissent l'incertitude de lien au sens de Sullivan. La superposition prive l'explication de composants nets que l'on saisirait un à un. Le pluralisme lui retire la décomposition unique sur laquelle fixer la compréhension. L'indifférence, enfin, écarte la fonction réalisée de la fonction que nous attribuons, si bien que le mécanisme ne rend plus compte, de manière exhaustive, de ce que nous attendons du modèle selon nos propres catégories.

Nous tenons donc l'explication sans la compréhension que l'on en attendait. Ce n'est pas un échec de la MI, puisque c'est elle qui rend l'écart visible, mais le signe que l'explication et la compréhension cessent de coïncider pour un objet de ce type.

Cette dissociation ne contredit pas ce que la deuxième partie avait établi, et il importe de le montrer, car on pourrait y voir une tension. Nous y avons soutenu que la MI produit des explications authentiquement mécanistes. Nous soutenons à présent qu'elle livre l'explication sans toujours procurer la compréhension. Les deux thèses se concilient dès lors qu'on se souvient du statut exact que la section 2.5 avait reconnu à ces explications. Ce que la MI reconstruit n'est pas un mécanisme complet, mais une esquisse de mécanisme, au sens de Piccinini et Craver, c'est-à-dire une caractérisation correcte de l'organi-

le critère CIT formulé p. 102. Sur la distinction de la compréhension explicative et de la compréhension objectuelle, Baumberger, Beisbart et Brun (2017), dans Grimm, Baumberger et Ammon (dir.), *Explaining Understanding* (Routledge), p. 1-34. Sur l'incertitude de lien comme borne de la compréhension tirée d'un modèle, Sullivan (2022), « Understanding from Machine Learning Models », *The British Journal for the Philosophy of Science*, 73(1), 109-133 ; la notion (« link uncertainty ») y est introduite p. 110 et définie p. 112 comme « a lack of scientific and empirical evidence supporting the link » entre le modèle et le phénomène cible.

⁴⁰Cette dissociation rejoint un thème établi de l'épistémologie de la compréhension, selon lequel il peut y avoir compréhension sans explication aussi bien qu'explication sans compréhension (Lipton, 2009, p. 43-63). Le cas des LLM illustre le second versant.

sation fonctionnelle qui laisse encore en blanc une part des entités et des activités. Or une esquisse est incomplète par destination, puisqu'elle se contente de désigner des places fonctionnelles sans toujours en préciser la réalisation. Une explication de ce genre peut être exacte, et donc authentiquement mécaniste par sa forme, sans pour autant rendre son objet pleinement intelligible à l'esprit qui la reçoit. L'écart entre l'explication et la compréhension ne traduit donc pas une faille de l'analyse, mais la conséquence attendue du caractère esquissé de l'explication. La deuxième partie disait ce que la MI parvient à établir, et la conclusion dit jusqu'où cette réussite porte, sans que l'une démente l'autre.

Ce que les LLM révèlent de la compréhension

La première leçon est que les LLM défont l'équivalence tacite de l'explication et de la compréhension. Les conditions de la compréhension, soit l'intelligibilité, un explanandum déterminé et l'accord de la fonction attribuée avec la fonction réalisée, sont précisément ce que la genèse par entraînement retire. Le troisième mode de genèse ne reconfigure donc pas seulement notre concept d'explication, comme la troisième partie l'a montré, mais aussi notre concept de compréhension.

Cette leçon éclaire un débat ouvert. La question de savoir si les LLM comprennent divise aujourd'hui les chercheurs, faute d'un concept de compréhension qui conviendrait à un système compétent sans être comprenant⁴¹. Notre cadre offre ici une issue, car il sépare la compétence, réelle en tant que pattern et justifiée par la perspective intentionnelle, de la compréhension, qui supposerait une réalisation mécanique du contenu attribué. C'est la distinction dennettienne, qu'illustre l'étude d'Anthropic sur les émotions fonctionnelles, laquelle met au jour des représentations pertinentes pour le comportement sans présupposer d'aucune expérience subjective⁴².

Cette même distinction se retourne enfin vers nous, et c'est sa portée la plus profonde. La compétence sans compréhension n'est pas le propre des LLM. Notre propre expertise excède souvent ce que nous sommes capables d'en ex-

⁴¹Sur le caractère disputé de la question de savoir si les LLM comprennent, Mitchell et Krakauer (2023), « The Debate Over Understanding in AI's Large Language Models », *Proceedings of the National Academy of Sciences*, 120(13), e2215907120. La revue recourt à un identifiant d'article plutôt qu'à une pagination classique.

⁴²Sofroniew et al. (2026, déjà cité, note 33, p. 64). Les auteurs y dégagent des représentations linéaires de concepts d'émotion, dont ils établissent l'effet causal par intervention sur les activations, et précisent que ces émotions fonctionnelles n'impliquent aucune expérience subjective.

pliciter, qu'il s'agisse d'une habileté perceptive, d'un jugement moral ou d'une intuition scientifique. Nous l'avons d'ailleurs souligné en répondant à l'objection éliminativiste, lorsque nous avons relevé que les jugements moraux humains sont produits par des mécanismes qui ne contiennent pas non plus leur contenu. Les LLM rendent ainsi manifeste un trait général de la cognition, que leur étrangeté nous force seulement à mieux voir.

Le détour par l'instrument, et notre propre compréhension

Il faut revenir ici à la question que la première partie avait posée. L'opacité dont nous étions partis n'est pas essentielle, mais contingente, et elle se laisse surmonter. Ce qui la surmonte, c'est l'instrument, car la MI est un outil cognitif qui rend le modèle partiellement intelligible, là où l'examen du seul comportement le laissait opaque.

Ce détour est lui-même instructif sur la compréhension. La compréhension scientifique a toujours été médiée par des instruments, du télescope au microscope, puis au calcul. L'incertitude de lien de Sullivan ne se réduit pas en abolissant l'opacité, ce qui reste hors de portée, mais en construisant par l'intervention des liens fiables entre le mécanisme et le phénomène. La valeur de la MI tient à ce travail de réduction du lien incertain, et non à une transparence qu'elle ne procure pas.

On peut alors rouvrir prudemment une question que le premier mémoire avait laissée de côté. Si la compréhension est médiée par des artefacts cognitifs, comme la thèse de l'esprit étendu y invite, alors les LLM s'y trouvent doublement engagés⁴³. Ils sont des artefacts qui étendent notre cognition, et ils sont des objets que nous ne comprenons qu'au moyen d'autres artefacts, ceux de l'interprétabilité.

Ce double engagement ne reproduit pas simplement les cas classiques de l'esprit étendu. Le carnet de l'agent ou l'instrument du savant étaient des artefacts transparents à l'usage, dont le fonctionnement ne faisait pas problème pour qui s'en servait. Le LLM, au contraire, est un artefact cognitif dont les opérations demeurent opaques à celui-là même qui les mobilise. La cognition étendue inclut donc désormais un élément que son utilisateur ne comprend

⁴³Sur la thèse de l'esprit étendu, Clark et Chalmers (1998), « The Extended Mind », *Analysis*, 58(1), 7-19, dont relève l'exemple canonique du carnet d'Otto. Son application aux artefacts cognitifs numériques et aux LLM, que nous n'ouvrons ici qu'à titre prospectif, relève de travaux plus récents, notamment Smart, Clowes et Clark (2025), « ChatGPT, extended : large language models and the extended mind », *Synthese*, 205, art. 242, qui appliquent ce cadre aux grands modèles de langage. Nous nous bornons à signaler cette voie, sans nous y engager.

pas, et c'est en ce point que notre situation s'écarte de celle qu'avaient en vue les premières formulations de la thèse. L'interprétabilité y prend alors un rôle inédit, puisqu'elle ne sert plus seulement à expliquer un système tiers, mais à rendre intelligible le partenaire opaque d'un couplage cognitif dont nous faisons nous-mêmes partie.

La frontière entre comprendre un système et le comprendre avec son propre concours devient dès lors une question vive. Nous ne la trancherons pas ici, et nous la réservons à des travaux ultérieurs. Elle indique cependant vers quoi mène le renversement.

L'enjeu pratique : confiance et délégation

Cet écart entre expliquer et comprendre n'est pas une subtilité d'école, car il engage la confiance que nous plaçons dans les systèmes à fort enjeu, ceux-là mêmes que l'introduction évoquait, du diagnostic à l'examen d'une candidature.

La littérature sur l'aide à la décision documente un phénomène constant, le biais d'automatisation, par lequel un opérateur se range trop volontiers à la sortie d'un système automatisé. L'XAI promet de corriger ce biais en restaurant, par l'explication, une confiance fondée. Mais si l'explication ne vaut pas la compréhension, alors une explication qui n'apporte pas l'intelligibilité véritable risque de produire une confiance trompeuse. Un clinicien à qui l'on montre une carte de saillance peut croire qu'il comprend, alors que l'incertitude du lien entre cette carte et la fonction réellement réalisée demeure entière.

L'écart a donc une conséquence normative directe. La confiance fondée requiert la compréhension, et non la seule explication. Le mérite propre de la MI est ici qu'elle réduit l'incertitude de lien par une preuve causale et interventionniste, plutôt qu'elle ne se contente d'une saillance corrélationnelle. Encore faut-il ne pas la prendre pour ce qu'elle ne donne pas, à savoir une intelligibilité complète. La posture responsable consiste à calibrer la confiance sur le type de compréhension effectivement atteint.

Ce qui reste ouvert

Une dernière remarque porte sur la manière dont nous avons travaillé. Ce mémoire n'a pas pris les concepts d'explication, de fonction et de composant pour des données fixes, puisqu'il les a révisés afin qu'ils restent adéquats à un objet nouveau. Cette démarche a un nom, l'ingénierie conceptuelle, soit l'activité qui consiste à évaluer et à améliorer nos dispositifs représentation-

nels⁴⁴. Encore faut-il préciser de quelle espèce relève la nôtre. Hopster et Löhr distinguent en effet deux visées de l'ingénierie conceptuelle. La première est l'amélioration, qui corrige un concept jugé défectueux en lui-même. La seconde est l'adaptation, qui répond à une perturbation conceptuelle provoquée par une technologie émergente, lorsque celle-ci ouvre une lacune, un chevauchement ou un désalignement entre nos concepts et leurs nouveaux cas d'application⁴⁵. Notre travail relève de la seconde visée. Les concepts d'explication mécaniste, de composant et de fonction n'étaient pas défectueux, car ils servent les sciences du vivant sans heurt. C'est le troisième mode de genèse qui les a désalignés, en produisant un objet dont l'organisation fonctionnelle ne provient ni de l'évolution ni de la conception. Nos trois enrichissements locaux, à savoir admettre le composant comme direction distribuée, accepter un pluralisme de décompositions contraintes, et distinguer la fonction attribuée de la fonction opérante, n'ont pas eu d'autre but que de restaurer leur qualité fonctionnelle face à ce désalignement. Cette précision répond du même coup à l'objection du changement de sujet, car une révision n'est légitime, selon Cappelen, que si elle préserve la continuité du sujet dont on parle⁴⁶. Or c'est précisément ce que la stratégie du plancher et du plafond garantissait, puisque chaque enrichissement conservait le cœur du concept hérité, l'explication par entités, activités et organisation validée par intervention, et n'y ajoutait que ce que l'objet nouveau exigeait. La philosophie des sciences ne fait donc pas que décrire l'interprétabilité, car elle façonne aussi, et de manière réglée, les concepts par lesquels nous pensons ce que cette technique produit. Le texte «*Mechanistic Interpretability Needs Philosophy*» appelle de ses vœux ce travail de clarification conceptuelle mené avec le champ plutôt qu'après lui, et notre mémoire voudrait en être une contribution.

Notre contribution reste néanmoins bornée, et il importe de le redire pour

⁴⁴Cappelen (2018), *Fixing Language* (Oxford University Press) ; la définition de l'ingénierie conceptuelle comme évaluation et amélioration de nos dispositifs représentationnels ouvre le livre, p. 3. Voir aussi Chalmers, «*What Is Conceptual Engineering and What Should It Be?*», publié en ligne en 2020 et paru dans *Inquiry*, 68(9), 2902-2919 (2025).

⁴⁵Hopster et Löhr (2023), «*Conceptual Engineering and Philosophy of Technology : Amélioration or Adaptation ?*», *Philosophy & Technology*, 36(4), art. 70, p. 1-17. Les auteurs y distinguent trois types de perturbation conceptuelle, la lacune, le chevauchement et le désalignement, et soutiennent que l'ingénierie conceptuelle suscitée par la technique vise moins à améliorer les concepts qu'à préserver leur qualité fonctionnelle. Sur l'extension du cadre de Cappelen aux systèmes d'IA, voir aussi Cappelen et Dever (2021), *Making AI Intelligible : Philosophical Foundations* (Oxford University Press).

⁴⁶Sur la continuité de sujet comme limite de la révision légitime, Cappelen (2018), chap. 9 et 10, p. 97-121.

finir. Le plancher des trois enrichissements locaux nous semble solide. Le plafond, c'est-à-dire le concept de fonction sélectionnée par l'entraînement tenu pour une troisième espèce de fonction, demeure une conjecture, dont nous avons fixé l'échelle de repli et laissé ouverte la portée téléosémantique. La question de l'échelle, enfin, reste pour partie empirique. Ce sont là les chantiers d'un travail à venir, et c'est vers eux que ce mémoire se prolongera.

Il restera pourtant acquis que les LLM, en résistant aux catégories dont nous avons hérité, nous auront appris autant sur les conditions de notre propre compréhension que sur la leur.

Annexe A — Extraits du mémoire de Master 1

Les extraits ci-dessous sont reproduits à partir du mémoire de Master 1 (Branger, 2025). Ils ne sont pas repris pour eux-mêmes, mais pour rendre le présent travail autonome : ce sont les passages dont l'argumentation du M2 hérite et auxquels renvoient les notes de l'introduction et de la première partie. La référence du chapitre d'origine figure dans le titre de chaque encadré ; les sections du M2 qui s'y appuient sont indiquées en regard.

[A] Appui : Introduction, §1.1 et §1.4 (la «prémisse organique»).

M1, §14.3 — La catégorie de l'agent cognitif artificiel fonctionnellement autonome

Un ACAFA se distinguerait par les attributs suivants, que notre analyse dennettienne a permis de mettre en évidence. *Système Intentionnel Robuste* : une entité dont le comportement complexe et adaptatif est le mieux compris, expliqué et prédit en adoptant la perspective Intentionnelle, c'est-à-dire en lui attribuant des « croyances » (ses bases de données, ses modèles internes du monde informationnel) et des « désirs » (ses fonctions objectifs, les buts qu'il optimise). *Compétence Cognitive sans Subjectivité Humaine* : une haute compétence dans des tâches cognitives (langage, raisonnement sur des données, création, planification) sans qu'il soit nécessaire de lui postuler une « compréhension » sémantique profonde au sens humain, ni une conscience phénoménale. *Autonomie Fonctionnelle par Apprentissage* : grâce à des mécanismes d'apprentissage très développés, il met en œuvre des capacités émergentes, adapte ses stratégies, et optimise son comportement pour atteindre ses objectifs d'une manière qui n'est pas entièrement contenue dans sa programmation initiale. *Capacités d'Interaction et de Communication Complexes* : il peut s'engager dans

des interactions de tous types avec des humains ou d'autres agents, et peut même manifester des comportements qui simulent fonctionnellement une « Théorie de l'Esprit ».

[B] Appui : §1.1, §2.1, §2.4 (« découverts ou imposés ? ») et §3.4.

M1, §11.3 — Le réalisme des patterns et l'analogie du centre de gravité

L'analogie que Dennett emploie fréquemment pour illustrer ce point est celle du centre de gravité en physique. Le centre de gravité d'un objet n'est pas une « chose » matérielle que l'on pourrait isoler ou toucher. C'est un point abstrait, une construction théorique. Pourtant, personne ne douterait de la « réalité » du centre de gravité, car c'est un concept indispensable pour calculer la stabilité d'un objet, prédire sa trajectoire, ou comprendre son équilibre. De manière similaire, pour Dennett, les croyances et les désirs que nous attribuons à un système intentionnel (qu'il soit humain, animal ou artificiel) sont des abstractions qui capturent des patterns réels dans son organisation fonctionnelle et son comportement.

[C] Appui : §1.1, §3.4 (l'indifférence morale « vue de l'intérieur ») et Conclusion.

M1, §8 — La compétence sans compréhension

L'évolution par sélection naturelle est son exemple favori : ce processus est aveugle, et est basé sur la variation aléatoire et la rétention différentielle des traits favorisant la survie et la reproduction. Et cette sélection est parvenue à concevoir des organismes d'une sophistication inouïe. L'œil humain, par exemple, est un instrument optique d'une précision remarquable, mais aucun « ingénieur conscient » (divin ou autre) n'a présidé à sa conception progressive. [...] La fourmilière, en tant que structure, est superbement « compétente » pour abriter la colonie, mais cette compétence ne repose sur la compréhension d'aucun de ses constituants individuels, ni sur une intelligence centrale.

[D] Appui : §1.1 (« une opacité tenant au mode de genèse »).

M1, §11.1 — Les limites de la perspective du dessein devant les systèmes apprenants

L'adéquation de la Perspective du Dessein commence à montrer de sérieuses faiblesses lorsque nous nous tournons vers les intelligences artificielles les plus avancées. La raison fondamentale de cette limitation réside dans la nature même de l'apprentissage machine : le « dessein » initial, c'est-à-dire l'architecture du modèle et les algorithmes d'apprentissage, ne détermine qu'une partie de la configuration finale et du répertoire comportemental du système. Une part substantielle de ce que l'IA « devient » est le fruit de son interaction avec d'immenses quantités de données et des processus d'optimisation techniques. [...] L'hermétisme inhérent à ces modèles de grande taille, souvent qualifiés de « boîtes noires », signifie que leur comportement est significativement sous-déterminé par les intentions et les spécifications explicites de leurs créateurs.

[E] Appui : §1.1 et §2.2 (l'exemple « horloge et pizza »).

M1, §14.2 — Réalisabilité multiple et chauvinisme de substrat

Le principe de la réalisabilité multiple, central en philosophie fonctionnaliste, soutient qu'un même état mental ou une même fonction cognitive peut être « réalisé » ou « implémenté » par des systèmes physiques et matériels très différents. [...] Cette perspective fonctionnaliste s'oppose radicalement au « chauvinisme de substrat » (ou « chauvinisme carbonique », ou encore « chauvinisme neuronal »), c'est-à-dire la croyance, souvent implicite, que les propriétés mentales authentiques, et en particulier la conscience ou l'intelligence « vraie », ne peuvent émerger que de systèmes biologiques de type terrestre, basés sur la chimie du carbone et l'architecture des neurones.

Glossaire

Ce glossaire recense les termes techniques propres à l'apprentissage automatique et à l'interprétabilité des grands modèles de langage, tels qu'ils sont mobilisés dans ce mémoire. Les entrées sont classées par ordre alphabétique ; les renvois entre parenthèses indiquent les sections où chaque notion est mise en œuvre.

Ablation

Technique d'intervention consistant à supprimer ou à désactiver un composant d'un réseau de neurones (un neurone, une couche, une tête d'attention) afin d'observer l'effet de cette suppression sur le comportement du modèle. Si la performance sur une tâche donnée décline significativement, on en déduit que le composant ablé jouait un rôle causal dans la réalisation de cette tâche. L'ablation est l'inverse fonctionnel du patching : là où le patching *restaure* une information, l'ablation la *retire*. Elle y est mobilisée conjointement au patching pour valider le rôle causal des têtes d'induction (§2.4).

Apprentissage en contexte

Capacité d'un grand modèle de langage à adapter son comportement à une tâche nouvelle à partir d'exemples fournis directement dans l'invite d'entrée (*prompt*), sans mise à jour des poids du modèle. Ce phénomène, aussi appelé *few-shot learning* ou *in-context learning*, se manifeste par exemple lorsque le modèle complète un motif ou suit un format après avoir reçu quelques paires exemple/réponse. C'est précisément ce phénomène qu'Olsson *et al.* (2022) ont disséqué pour isoler les têtes d'induction (§2.4).

Apprentissage par raccourci (*shortcut learning*)

Phénomène par lequel un modèle d'apprentissage automatique résout une tâche en s'appuyant sur une corrélation présente dans les données d'entraînement, plutôt que sur la propriété conceptuellement pertinente visée par les concepteurs. Par exemple, un classifieur d'images peut apprendre à reconnaître des vaches en détectant les pixels sombres (présents dans les prairies des

images d'entraînement) plutôt qu'en identifiant les caractéristiques morphologiques des vaches elles-mêmes. Ce raccourci fonctionne bien sur les données d'entraînement mais échoue en généralisation. Les travaux de Geirhos *et al.* (2020) sur ce sujet illustrent ici le fossé possible entre la fonction attribuée et la fonction réellement opérée (§3.4).

Attention rollout

Méthode d'analyse des mécanismes d'attention dans les architectures transformeur. Elle consiste à agréger les poids d'attention à travers plusieurs couches du modèle afin de produire une carte globale montrant comment l'information circule d'un token à un autre sur l'ensemble du réseau. L'*attention rollout* permet de visualiser les dépendances à longue portée et d'identifier quels tokens influencent le plus la sortie finale. Elle figure parmi les méthodes locales de l'XAI classique, fondées sur l'inspection des poids d'attention (§1.2).

Auto-encodeur parcimonieux

Réseau de neurones composé de deux parties : un *encodeur* qui comprime une entrée en une représentation latente de dimension inférieure, et un *décodeur* qui tente de reconstruire l'entrée à partir de cette représentation. La contrainte de *parcimonie* (*sparsity*) impose que seules quelques unités de la représentation latente soient activées à la fois, ce qui force le réseau à apprendre des caractéristiques distinctes et interprétables plutôt que des combinaisons redondantes. Ils constituent l'architecture de base sur laquelle reposent à la fois le *dictionary learning* (§2.4) et les techniques de *steering* (§3.4).

Carte de saillance (*saliency map*)

Méthode d'attribution par gradient qui produit une carte visuelle indiquant, pour chaque élément d'entrée (par exemple chaque pixel d'une image ou chaque token d'un texte), dans quelle mesure cet élément a contribué à la décision du modèle. Les zones de forte saillance sont celles dont la modification aurait le plus d'impact sur la sortie. Les cartes de saillance sont l'une des méthodes les plus anciennes et les plus simples de l'XAI. Leur incapacité à établir un lien causal, au-delà d'une simple corrélation, sert de point de départ pour justifier le passage à l'interprétabilité mécaniste (§1.2).

Découpage flottant (*feature splitting*)

Phénomène observé en *dictionary learning* selon lequel la granularité des traits (*features*) extraits dépend de la taille du dictionnaire appris : si l'on augmente

le nombre d'entrées du dictionnaire, un trait précédemment identifié se scinde en plusieurs traits plus fins. Inversement, réduire le dictionnaire fusionne des traits distincts. Ce découpage flottant implique qu'il n'existe pas de granularité naturelle ou unique des composants fonctionnels d'un modèle entraîné. Ce phénomène est invoqué pour contester l'idée qu'un modèle posséderait une décomposition fonctionnelle unique et naturelle (§3.2, §3.3).

Descente de gradient

Algorithme d'optimisation fondamental de l'apprentissage automatique. Il ajuste itérativement les paramètres (poids) d'un modèle en calculant le gradient de la fonction de perte par rapport à ces paramètres, puis en les modifiant dans la direction opposée au gradient (d'où le terme « descente »). L'objectif est de minimiser la fonction de perte, c'est-à-dire de réduire l'écart entre les prédictions du modèle et les données cibles. Elle y est comparée à la sélection naturelle : un processus aveugle qui façonne néanmoins une organisation fonctionnelle complexe sans plan directeur (§1.1, §3.1).

Dictionary learning

Technique d'interprétabilité qui consiste à apprendre un « dictionnaire » de directions interprétables à partir des activations internes d'un réseau de neurones. Concrètement, on entraîne un auto-encodeur parcimonieux sur les activations d'une couche donnée : le décodeur apprend un ensemble de vecteurs (les entrées du dictionnaire) tels que chaque activation peut être réexprimée comme une combinaison parcimonieuse de ces vecteurs. Chaque entrée du dictionnaire correspond alors à un *trait* (*feature*) humainement interprétable. Cette méthode permet de découvrir des milliers de traits à partir de quelques centaines de neurones. Développé notamment par Bricken *et al.* (2023), il représente la réponse de l'interprétabilité mécaniste au problème de la superposition, en permettant une véritable décomposition fonctionnelle (§2.4, §3.2).

Fonction de perte (*loss function*)

Fonction mathématique qui quantifie l'écart entre la prédiction d'un modèle et la valeur cible attendue. C'est la boussole de l'entraînement : l'algorithme de descente de gradient cherche à minimiser cette fonction. Dans le cas des grands modèles de langage, la fonction de perte mesure typiquement l'erreur de prédiction du prochain token (*cross-entropy loss*). Le fait qu'elle ne soit qu'un *proxy* de l'objectif visé nourrit l'argument central sur l'indifférence mécanique des modèles (§3.1, §3.4).

Hypothèse de représentation linéaire

Hypothèse selon laquelle les traits (*features*) activés dans un réseau de neurones peuvent être modélisés comme des directions linéaires dans l'espace des activations. C'est-à-dire qu'un trait correspondrait à un vecteur fixe tel que son activation se mesure par le produit scalaire entre ce vecteur et le vecteur d'activation. Cette hypothèse est au fondement du *dictionary learning* et des méthodes de sondage (*probing*) linéaires. Elle est cependant contestée : certains travaux (Engels *et al.*, 2025) suggèrent que les représentations internes sont non linéaires, ce qui remettrait en cause la validité de ces méthodes. Sa validité est interrogée, car sa remise en cause par des travaux récents constitue l'une des principales limites actuelles du *dictionary learning* (§3.2).

Ingénierie conceptuelle

Programme philosophique associé à Herman Cappelen (2018) qui défend l'idée que les concepts philosophiques ne sont pas des données fixes à découvrir, mais des outils qui peuvent être révisés, remodelés ou remplacés lorsqu'ils ne rendent plus compte adéquatement de leurs objets. L'ingénierie conceptuelle vise l'*adaptation* des concepts à de nouveaux domaines plutôt que leur simple clarification. C'est sous cette bannière que s'inscrit la démarche globale : il ne s'agit pas d'appliquer mécaniquement les catégories du mécanisme, mais de les remodeler pour qu'elles épousent la spécificité des LLM (Conclusion).

Patching de l'espace latent

Méthode d'intervention causale centrale en interprétabilité mécaniste. Le principe est le suivant : on prend deux entrées différentes (par exemple « la capitale de la France est » et « la capitale de l'Allemagne est »), on remplace (*patch*) les activations d'un composant donné dans le premier passage par celles du second passage, puis on observe l'effet sur la sortie. Si la sortie change de manière significative (le modèle passe de « Paris » à « Berlin »), on en déduit que le composant patché encode une information causalement pertinente. Elle offre une traduction opérationnelle directe du cadre interventionniste de Woodward : isoler une variable, la modifier, et observer les conséquences (§2.4).

Projection itérative dans l'espace nul

Technique d'intervention développée par Ravfogel *et al.* qui consiste à retirer sélectivement l'information détectée par une sonde (*probe*) d'un vecteur d'ac-

tivation, en projetant itérativement ce vecteur dans l'espace nul de la sonde. L'idée est de « neutraliser » une propriété spécifique (par exemple le genre, la polarité) dans la représentation interne, puis de vérifier si cette neutralisation affecte le comportement du modèle. Cette méthode permet d'établir un lien causal entre une propriété détectée et la sortie, au-delà d'une simple corrélation. Elle complète le patching en proposant une approche par soustraction plutôt que par substitution (§2.4).

Proxy / objectif substitutif

Dans le contexte de l'entraînement des LLM, le *proxy* désigne l'objectif mathématique que le modèle optimise effectivement (par exemple la prédiction du prochain token), par opposition à la fonction intentionnelle que les concepteurs souhaitent voir réalisée (par exemple la capacité à raisonner moralement ou à répondre utilement). Le proxy est un *substitut* : il est choisi parce qu'il est mesurable et optimisable, mais il ne coïncide pas nécessairement avec la fonction visée. L'écart entre ce proxy et la fonction intentionnelle est identifié comme la source commune des trois limites de l'analogie mécaniste (§3.4, §3.5).

Steering d'auto-encodeur

Technique d'intervention qui consiste à modifier délibérément les activations d'un modèle en utilisant les directions apprises par un auto-encodeur parcimonieux. Concrètement, on identifie une direction du dictionnaire associée à un trait donné (par exemple « la structure morale »), puis on amplifie ou on atténue cette direction dans les activations du modèle pour observer l'effet sur le comportement. Cette méthode permet d'établir des liens causaux entre des traits abstraits et des comportements. C'est précisément cette technique que Li *et al.* (2026) ont employée pour démontrer expérimentalement l'indifférence morale des grands modèles (§3.4).

Superposition

Phénomène découvert par Elhage *et al.* (2022) selon lequel un réseau de neurones peut représenter plus de traits (*features*) qu'il ne possède de neurones, en encodant plusieurs traits dans des directions qui se recouvrent partiellement dans l'espace des activations. Chaque trait correspond alors à une direction (combinaison de neurones) plutôt qu'à un neurone individuel. Ce codage est efficace lorsque les traits sont rares (rarement actifs simultanément), car les interférences sont minimisées. La superposition implique la *polysémantité* des

neurones : un même neurone participe à l’encodage de plusieurs traits sans rapport apparent. Elle constitue le premier défi lancé au cadre mécaniste classique, en démontrant que les composants fonctionnels ne coïncident pas avec les parties physiques du réseau (§2.4, §3.2).

Tête d’induction

Composant spécifique d’un mécanisme d’attention identifié par Olsson *et al.* (2022) dans les architectures transformeur. Une tête d’induction est une tête d’attention qui détecte la répétition d’un token ou d’un motif dans le contexte, puis copie la suite qui a suivi la première occurrence pour la produire après la seconde. Elle est associée à une « tête de token précédent » qui pointe sur le token immédiatement précédent. Ensemble, ces deux têtes implémentent un algorithme de complétion de motif (*pattern completion*), qui est le mécanisme sous-jacent à l’apprentissage en contexte. Leur découverte sert de fil rouge pour illustrer concrètement les trois étapes de la MI : décomposer, localiser, puis valider par intervention (§2.4).

Bibliographie

Les références ci-dessous sont celles qui sont citées dans le corps du mémoire. Pour les publications en ligne sans pagination, notamment celles du Transformer Circuits Thread et de Distill, l'adresse de consultation tient lieu de localisation. Les preprints arXiv sont signalés par leur identifiant.

- Baumberger, C., Beisbart, C. et Brun, G. (2017). What is Understanding? An Overview of Recent Debates in Epistemology and Philosophy of Science. Dans S. R. Grimm, C. Baumberger et S. Ammon (dir.), *Explaining Understanding : New Perspectives from Epistemology and Philosophy of Science* (p. 1-34). New York, Routledge.
- Bechtel, W. et Abrahamsen, A. (2005). Explanation : A Mechanist Alternative. *Studies in History and Philosophy of Biological and Biomedical Sciences*, 36(2), 421-441.
- Bechtel, W. et Richardson, R. C. (1993). *Discovering Complexity : Decomposition and Localization as Strategies in Scientific Research*. Princeton, Princeton University Press.
- Beckers, S. et Halpern, J. Y. (2019). Abstracting Causal Models. *Proceedings of the AAAI Conference on Artificial Intelligence*, 33(1), 2678-2685.
- Beckers, S., Eberhardt, F. et Halpern, J. Y. (2020). Approximate Causal Abstractions. Dans *Proceedings of the 35th Uncertainty in Artificial Intelligence Conference (UAI)*, PMLR 115, 606-615.
- Branger, F. (2025). *L'agentivité artificielle à l'épreuve du vivant : repenser la pensée à l'ère de l'IA avec Daniel C. Dennett* (Mémoire de Master 1, sous la direction de Perceval Pillon). Caen, Université de Caen Normandie, UFR Humanités et Sciences sociales.
- Bricken, T., Templeton, A., Batson, J., Chen, B., Jermyn, A., Conerly, T., Turner, N. et al. (2023). Towards Monosemanticity : Decomposing Language Models With Dictionary Learning. *Transformer Circuits Thread*. <https://transformer-circuits.pub/2023/monosemantic-features>
- Burrell, J. (2016). How the Machine « Thinks » : Understanding Opacity in

- Machine Learning Algorithms. *Big Data & Society*, 3(1), 1-12.
- Cammarata, N., Goh, G., Carter, S., Schubert, L., Petrov, M. et Olah, C. (2020). Curve Detectors. *Distill*, 5(6). <https://distill.pub/2020/circuits/curve-detectors>
- Cammarata, N., Goh, G., Carter, S., Voss, C., Schubert, L. et Olah, C. (2021). Curve Circuits. *Distill*, 6(1). <https://distill.pub/2020/circuits/curve-circuits>
- Cappelen, H. (2018). *Fixing Language : An Essay on Conceptual Engineering*. Oxford, Oxford University Press.
- Cappelen, H. et Dever, J. (2021). *Making AI Intelligible : Philosophical Foundations*. Oxford, Oxford University Press.
- Chalmers, D. J. (2020). What is Conceptual Engineering and What Should It Be? *Inquiry*, publié en ligne en 2020 ; paru dans 68(9), 2902-2919 (2025).
- Chanin, D., Dulka, T. et Garriga-Alonso, A. (2025). Feature Hedging : Correlated Features Break Narrow Sparse Autoencoders. *arXiv :2505.11756*. Preprint arXiv.
- Clark, A. et Chalmers, D. J. (1998). The Extended Mind. *Analysis*, 58(1), 7-19.
- Cooper, A. (2004). *The Inmates Are Running the Asylum : Why High-Tech Products Drive Us Crazy and How to Restore the Sanity*. Indianapolis, Sams.
- Craver, C. F. (2007). *Explaining the Brain : Mechanisms and the Mosaic Unity of Neuroscience*. Oxford, Clarendon Press.
- Craver, C. F. et Kaplan, D. M. (2020). Are More Details Better? On the Norms of Completeness for Mechanistic Explanations. *The British Journal for the Philosophy of Science*, 71(1), 287-319.
- Creel, K. A. (2020). Transparency in Complex Computational Systems. *Philosophy of Science*, 87(4), 568-589.
- Cunningham, H., Ewart, A., Riggs, L., Huben, R. et Sharkey, L. (2023). Sparse Autoencoders Find Highly Interpretable Features in Language Models. *arXiv :2309.08600*. Preprint arXiv.
- Dennett, D. C. (1987). *The Intentional Stance*. Cambridge (Mass.), MIT Press.
- Dennett, D. C. (1995). *Darwin's Dangerous Idea : Evolution and the Meanings of Life*. New York, Simon & Schuster.
- Dennett, D. C. (1996). *Kinds of Minds : Toward an Understanding of Consciousness*. New York, Basic Books.
- Dorsch, J. et Moll, M. (2024). Explainable and Human-Grounded AI for

- Decision Support Systems : The Theory of Epistemic Quasi-Partnerships. *arXiv :2409.14839*. Preprint arXiv.
- Dretske, F. (1988). *Explaining Behavior : Reasons in a World of Causes*. Cambridge (Mass.), MIT Press.
- Elhage, N., Hume, T., Olsson, C., Schiefer, N., Henighan, T., Kravec, S., Hatfield-Dodds, Z. *et al.* (2022). Toy Models of Superposition. *Transformer Circuits Thread*. https://transformer-circuits.pub/2022/toy_model/index.html
- Engels, J., Liao, I., Michaud, E. J., Gurnee, W. et Tegmark, M. (2025). Not All Language Model Features Are One-Dimensionally Linear. *International Conference on Learning Representations (ICLR)*; preprint *arXiv :2405.14860* (2024).
- Freiesleben, T., König, G., Molnar, C. et Tejero-Cantero, A. (2024). Scientific Inference With Interpretable Machine Learning : Analyzing Models to Learn About Real-World Phenomena. *Minds and Machines*, 34, art. 32.
- Geiger, A., Lu, H., Icard, T. et Potts, C. (2021). Causal Abstractions of Neural Networks. *Advances in Neural Information Processing Systems (NeurIPS)*, 34, 9574-9586.
- Geiger, A., Wu, Z., Potts, C., Icard, T. et Goodman, N. D. (2023). Finding Alignments Between Interpretable Causal Variables and Distributed Neural Representations. *arXiv :2303.02536*. Preprint arXiv.
- Geiger, A., Ibeling, D., Zur, A., Chaudhary, M., Chauhan, S., Huang, J., Arora, A. *et al.* (2024). Causal Abstraction : A Theoretical Foundation for Mechanistic Interpretability. *arXiv :2301.04709*. Preprint arXiv.
- Geirhos, R., Jacobsen, J.-H., Michaelis, C., Zemel, R., Brendel, W., Bethge, M. et Wichmann, F. A. (2020). Shortcut Learning in Deep Neural Networks. *Nature Machine Intelligence*, 2, 665-673.
- González Barman, K. (2026). Inference to the Best Explanation in Explainable AI (XAI). Dans V. C. Müller, L. Dung, G. Löhr et A. Rumana (dir.), *Philosophy of Artificial Intelligence*. Cham, Springer.
- Gould, S. J. et Lewontin, R. C. (1979). The Spandrels of San Marco and the Panglossian Paradigm : A Critique of the Adaptationist Programme. *Proceedings of the Royal Society of London, Series B*, 205(1161), 581-598.
- Gould, S. J. et Vrba, E. S. (1982). Exaptation : A Missing Term in the Science of Form. *Paleobiology*, 8(1), 4-15.
- Hopster, J. et Löhr, G. (2023). Conceptual Engineering and Philosophy of Technology : Amelioration or Adaptation? *Philosophy & Technology*, 36(4),

art. 70, 1-17.

- Hubinger, E., van Merwijk, C., Mikulik, V., Skalse, J. et Garrabrant, S. (2019). Risks from Learned Optimization in Advanced Machine Learning Systems. *arXiv :1906.01820*. Preprint arXiv.
- Humphreys, P. (2009). The Philosophical Novelty of Computer Simulation Methods. *Synthese*, 169(3), 615-626.
- Jain, S. et Wallace, B. C. (2019). Attention is not Explanation. Dans *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics : Human Language Technologies (NAACL-HLT)* (vol. 1, p. 3543-3556). Minneapolis, ACL.
- Kaplan, D. M. et Craver, C. F. (2011). The Explanatory Force of Dynamical and Mathematical Models in Neuroscience : A Mechanistic Perspective. *Philosophy of Science*, 78(4), 601-627.
- Kästner, L. et Crook, B. (2024). Explaining AI Through Mechanistic Interpretability. *European Journal for Philosophy of Science*, 14, art. 52.
- Li, L., Teng, Y. et Wang, Y. (2026). Mechanistic Origin of Moral Indifference in Language Models. *arXiv :2603.15615*. Preprint arXiv.
- Lipton, P. (2009). Understanding Without Explanation. Dans H. W. de Regt, S. Leonelli et K. Eigner (dir.), *Scientific Understanding : Philosophical Perspectives* (p. 43-63). Pittsburgh, University of Pittsburgh Press.
- Machamer, P., Darden, L. et Craver, C. F. (2000). Thinking About Mechanisms. *Philosophy of Science*, 67(1), 1-25.
- Marr, D. (1982). *Vision : A Computational Investigation into the Human Representation and Processing of Visual Information*. San Francisco, W. H. Freeman.
- Méloux, M. et al. (2025). Everything, Everywhere, All at Once : Is Mechanistic Interpretability Identifiable? *International Conference on Learning Representations (ICLR)* ; *arXiv :2502.20914*.
- Miller, T. (2019). Explanation in Artificial Intelligence : Insights from the Social Sciences. *Artificial Intelligence*, 267, 1-38.
- Miller, T., Howe, P. et Sonenberg, L. (2017). Explainable AI : Beware of Inmates Running the Asylum. Or : How I Learnt to Stop Worrying and Love the Social and Behavioural Sciences. *IJCAI 2017 Workshop on Explainable AI* ; *arXiv :1712.00547*.
- Millière, R. et Buckner, C. (2024a). A Philosophical Introduction to Language Models. Part I : Continuity With Classic Debates. *arXiv :2401.03910*. Preprint arXiv.

- Millière, R. et Buckner, C. (2024b). A Philosophical Introduction to Language Models. Part II : The Way Forward. *arXiv :2405.03207*. Preprint arXiv.
- Millikan, R. G. (1984). *Language, Thought, and Other Biological Categories : New Foundations for Realism*. Cambridge (Mass.), MIT Press.
- Mitchell, M. et Krakauer, D. C. (2023). The Debate Over Understanding in AI's Large Language Models. *Proceedings of the National Academy of Sciences*, 120(13), e2215907120.
- Mitchell, S. D. (2002). Integrative Pluralism. *Biology and Philosophy*, 17(1), 55-70.
- Neander, K. (1991). Functions as Selected Effects : The Conceptual Analyst's Defense. *Philosophy of Science*, 58(2), 168-184.
- Olah, C., Cammarata, N., Schubert, L., Goh, G., Petrov, M. et Carter, S. (2020). Zoom In : An Introduction to Circuits. *Distill*, 5(3). <https://distill.pub/2020/circuits/zoom-in>
- Olsson, C., Elhage, N., Nanda, N., Joseph, N., DasSarma, N., Henighan, T., Mann, B. et al. (2022). In-context Learning and Induction Heads. *Transformer Circuits Thread*. <https://transformer-circuits.pub/2022/in-context-learning-and-induction-heads/index.html>
- Park, K., Choe, Y. J. et Veitch, V. (2024). The Linear Representation Hypothesis and the Geometry of Large Language Models. Dans *Proceedings of the 41st International Conference on Machine Learning (ICML)*, PMLR 235, 39643-39666; preprint *arXiv :2311.03658* (2023).
- Pearl, J. (2009). *Causality : Models, Reasoning, and Inference* (2^e éd.). Cambridge, Cambridge University Press.
- Piccinini, G. et Craver, C. F. (2011). Integrating Psychology and Neuroscience : Functional Analyses as Mechanism Sketches. *Synthese*, 183(3), 283-311.
- Preece, A., Harborne, D., Braines, D., Tomsett, R. et Chakraborty, S. (2018). Stakeholders in Explainable AI. *arXiv :1810.00184*. Preprint arXiv.
- Rabiza, M. (2024). A Mechanistic Explanatory Strategy for XAI. *arXiv :2411.01332*; chapitre à paraître, Springer (2026).
- de Regt, H. W. (2017). *Understanding Scientific Understanding*. Oxford, Oxford University Press.
- Rigotti, M., Barak, O., Warden, M. R., Wang, X.-J., Daw, N. D., Miller, E. K. et Fusi, S. (2013). The Importance of Mixed Selectivity in Complex Cognitive Tasks. *Nature*, 497, 585-590.
- Rudin, C. (2019). Stop Explaining Black Box Machine Learning Models for

- High Stakes Decisions and Use Interpretable Models Instead. *Nature Machine Intelligence*, 1, 206-215.
- Sharkey, L. *et al.* (2025). Open Problems in Mechanistic Interpretability. *arXiv : 2501.16496*. Preprint arXiv.
- Smart, P. R., Clowes, R. W. et Clark, A. (2025). ChatGPT, Extended : Large Language Models and the Extended Mind. *Synthese*, 205, art. 242.
- Sofroniew, N., Kauvar, I., Saunders, W., Chen, R., Henighan, T., Hydrie, S., Citro, C. *et al.* (2026). Emotion Concepts and their Function in a Large Language Model. *Transformer Circuits Thread*; miroir *arXiv :2604.07729*. <https://transformer-circuits.pub/2026/emotions/index.html>
- Sullivan, E. (2022). Understanding from Machine Learning Models. *The British Journal for the Philosophy of Science*, 73(1), 109-133.
- Templeton, A., Conerly, T., Marcus, J., Lindsey, J., Bricken, T., Chen, B., Pearce, A. *et al.* (2024). Scaling Monosemanticity : Extracting Interpretable Features from Claude 3 Sonnet. *Transformer Circuits Thread*. <https://transformer-circuits.pub/2024/scaling-monosemanticity/index.html>
- Turpin, M., Michael, J., Perez, E. et Bowman, S. R. (2023). Language Models Don't Always Say What They Think : Unfaithful Explanations in Chain-of-Thought Prompting. *Advances in Neural Information Processing Systems (NeurIPS)*, 36.
- Wiegrefe, S. et Pinter, Y. (2019). Attention is not not Explanation. Dans *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)* (p. 11-20). Hong Kong, ACL.
- Williams, I., Oldenburg, N., Dhar, R., Hatherley, J., Fierro, C., Rajcic, N., Schiller, S. R., Stamatiou, F. et Søgaard, A. (2025). Mechanistic Interpretability Needs Philosophy. *arXiv :2506.18852*. Preprint arXiv.
- Woodward, J. (2003). *Making Things Happen : A Theory of Causal Explanation*. Oxford, Oxford University Press.
- Wright, L. (1973). Functions. *The Philosophical Review*, 82(2), 139-168.
- Zednik, C. (2021). Solving the Black Box Problem : A Normative Framework for Explainable Artificial Intelligence. *Philosophy & Technology*, 34(2), 265-288.
- Zhong, Z., Liu, Z., Tegmark, M. et Andreas, J. (2023). The Clock and the Pizza : Two Stories in Mechanistic Explanation of Neural Networks. *Advances in Neural Information Processing Systems (NeurIPS)*, 36; *arXiv :2306.17844*.

Bibliographie secondaire

Les ouvrages et articles ci-dessous ont nourri notre réflexion sans être directement cités dans le corps du mémoire. Nous les distinguons des références primaires pour la clarté de l'appareil critique.

- Andler, D. (2023). *Intelligence artificielle, intelligence humaine : la double énigme*. Paris, Gallimard, coll. « NRF essais ».
- Barboule, C. (2025). Les approches d'explicabilité des LLMs. Billet de blog, https://camillebrl.github.io/blog/2025/explainability_llm_generation/ (consulté en 2025 ; page retirée depuis, citée avec l'autorisation de l'autrice).
- Mattioli, M., Cinà, A. E. et Pelillo, M. (2024). Understanding XAI Through the Philosopher's Lens : A Historical Perspective. Dans *ECAI 2024, Frontiers in Artificial Intelligence and Applications*, vol. 392 (p. 987-994). Amsterdam, IOS Press ; preprint *arXiv :2407.18782*.
- Menon, S., Todariya, S. et Agerwala, T. (dir.) (2024). *AI, Consciousness and The New Humanism : Fundamental Reflections on Minds and Machines*. Singapour, Springer.
- Millière, R. et Buckner, C. (à paraître). Interventionist Methods for Interpreting Deep Neural Networks. Dans G. Piccinini (dir.), *Neurocognitive Foundations of Mind*. Londres, Routledge.
- Pantsar, M., Stjernfelt, F., Gramelsberger, G. et Olteanu, A. (dir.) (2025). *Philosophy of Artificial Intelligence : Optimistic and Pessimistic Views*. Studies in Applied Philosophy, Epistemology and Rational Ethics, vol. 75. Cham, Springer.
- Pedrycz, W. et Chen, S.-M. (dir.) (2021). *Interpretable Artificial Intelligence : A Perspective of Granular Computing*. Studies in Computational Intelligence, vol. 937. Cham, Springer.
- Pégny, M. (2024). *Éthique des algorithmes et de l'intelligence artificielle*. Paris, Vrin, coll. « Pour demain ».
- Räuker, T., Ho, A., Casper, S. et Hadfield-Menell, D. (2023). Toward Trans-

- parent AI : A Survey on Interpreting the Inner Structures of Deep Neural Networks. *arXiv* :2207.13243. Preprint arXiv (présenté à IEEE SaTML 2023).
- Răz, T. (2023). Methods for Identifying Emergent Concepts in Deep Neural Networks. *Patterns*, 4(6), art. 100761.
- Sapkota, R., Roumeliotis, K. I. et Karkee, M. (2026). AI Agents vs. Agentic AI : A Conceptual Taxonomy, Applications and Challenges. *Information Fusion*, 126, art. 103599.
- Wagner, P. (dir.) (2025). *Logique et épistémologie*. Paris, Vrin, coll. «Didac-Philo».